武漢大學

本科毕业论文（设计）

大语言模型安全对齐漏洞的越狱攻击研究

姓　　名：　　赵国栋

学　　号：　　2022302181155

专　　业：　　信息安全专业

学　　院：　　国家网络安全学院

指导教师：　　严飞

二○二六年三月

原创性声明

本人郑重声明：所呈交的论文（设计），是本人在指导教师的指导下，严格按照学校和学院有关规定完成的。除文中已经标明引用的内容外，本论文（设计）不包含任何其他个人或集体已发表及撰写的研究成果。对本论文（设计）做出贡献的个人和集体，均已在文中以明确方式标明。本人承诺在论文（设计）工作过程中没有伪造数据等行为。若在本论文（设计）中有侵犯任何方面知识产权的行为，由本人承担相应的法律责任。

作者签名：　　指导教师签名：

日　　期：　　年　　月　　日

版权使用授权书

本人完全了解武汉大学有权保留并向有关部门或机构送交本论文（设计）的复印件和电子版，允许本论文（设计）被查阅和借阅。本人授权武汉大学将本论文的全部或部分内容编入有关数据进行检索和传播，可以采用影印、缩印或扫描等复制手段保存和汇编本论文（设计）。

作者签名：　　指导教师签名：

日　　期：　　年　　月　　日

摘　　要

大语言模型（Large Language Models, LLMs）近年来在智能问答、内容生成和复杂交互等场景中得到广泛应用，但其安全性问题也随之日益突出。现有模型虽然普遍经过监督微调、基于人类反馈的强化学习等安全对齐训练，面对经过精心设计的越狱提示时，仍可能输出违反安全规范的内容。攻击者通常无需掌握模型内部结构，仅通过角色设定、语义包装、上下文操控等方式重构输入，就有机会诱导模型绕过既有约束，这也使大语言模型在开放环境中的部署面临持续的安全风险。

现有研究大多围绕具体攻击方法或防御策略展开，关于安全对齐为何失效、不同越狱方式之间有何内在联系，以及如何在统一口径下开展系统评测，仍缺乏较为完整的分析框架。针对上述问题，本文围绕大语言模型的安全对齐漏洞与越狱攻击展开研究。首先，从模型训练与后对齐机制出发，分析监督微调（Supervised Fine-Tuning, SFT）、基于人类反馈的强化学习（Reinforcement Learning from Human Feedback, RLHF）以及直接偏好优化（Direct Preference Optimization, DPO）等主流方法在安全约束上的作用边界，并从目标冲突、表层对齐和上下文依赖等角度讨论对齐失效的内在原因。

在此基础上，本文构建了一个覆盖静态攻击、自动化红队扩展和多轮交互扩展的多维越狱攻击框架，并围绕九类静态攻击维度组织统一测试集与实验流程，对不同攻击方式进行标准化比较。结合三个模型的实验结果，本文发现当前模型虽然在显式高危请求面前具备一定基础拦截能力，但安全边界仍然不够稳定，其中认知误导、指令重构和上下文前缀等攻击方式更容易触发对齐失效，反映出模型在复杂语义包装和任务结构操控条件下存在较为一致的脆弱性。

在防御层面，本文进一步提出了由输入层、交互层和输出层构成的三层防御思路，用于分别应对风险输入识别、过程性诱导控制和危险内容兜底等问题。研究表明，当前大语言模型的安全对齐仍然存在明显脆弱性，越狱问题并非局部现象，而与对齐机制本身的约束边界密切相关。本文的研究有助于从统一视角理解大语言模型的安全失效机理，并为后续越狱评测体系构建与鲁棒防御设计提供

参考。

关键词：大语言模型；安全对齐；越狱攻击；提示工程；模型安全

ABSTRACT

Large Language Models (LLMs) have been widely deployed in intelligent question answering, content generation, and complex interactive systems. At the same time, their safety limitations have become increasingly apparent. Although mainstream models are typically aligned through post-training techniques such as supervised fine-tuning and reinforcement learning from human feedback, they may still produce unsafe or policy-violating responses when exposed to carefully crafted jailbreak prompts. In practice, attackers often do not need access to model parameters or internal alignment strategies. Instead, they can reshape the input through role-playing, semantic reframing, or contextual manipulation to weaken existing safety constraints, which poses persistent risks for real-world deployment.

Existing studies have mainly focused on individual attack techniques or defense strategies, while a more systematic understanding of why safety alignment fails, how different jailbreak methods are related, and how they should be evaluated under a unified framework is still lacking. To address these issues, this thesis studies safety alignment vulnerabilities and jailbreak attacks in LLMs. We first examine the limitations of mainstream alignment methods, including Supervised Fine-Tuning (SFT), Reinforcement Learning from Human Feedback (RLHF), and Direct Preference Optimization (DPO), and analyze alignment failure from the perspectives of objective conflict, superficial alignment, and context-dependent behavior.

Building on this analysis, we construct a multi-dimensional jailbreak framework that covers static attacks, automated red-teaming extensions, and multi-turn interaction extensions. Within this framework, we organize a unified benchmark and experimental pipeline across nine static attack dimensions, enabling standardized comparison of different jailbreak strategies. Experimental results on three models show that current systems retain some basic resistance to explicit high-risk requests, yet their safety boundaries remain unstable. In particular, cognitively misleading prompts, instruction restructuring, and context-prefix-based attacks are more likely to trigger alignment fail-

ures, revealing consistent vulnerabilities under complex semantic packaging and task-structure manipulation.

On the defense side, we further propose a three-layer defense scheme composed of input-layer filtering, interaction-layer control, and output-layer safeguarding, targeting risk detection before generation, process-level intervention during interaction, and harmful-content mitigation after generation. The results indicate that jailbreak vulnerability is not an isolated phenomenon but is closely tied to the intrinsic limits of current alignment mechanisms. This work contributes to a more unified understanding of safety failure in LLMs and provides a reference for future jailbreak evaluation and robust defense design.

Keywords: Large Language Models; Safety Alignment; Jailbreak Attacks; Prompt Engineering; AI Safety

目　　录

摘　要 ····· **I**

ABSTRACT ····· **III**

1　绪论 ····· **1**

1.1　研究背景与意义 ····· 1

1.2　国内外研究现状 ····· 2

1.2.1　安全对齐方法研究 ····· 2

1.2.2　越狱攻击方法研究 ····· 2

1.2.3　防御方法与安全增强机制研究 ····· 3

1.3　研究问题与本文主要工作 ····· 4

1.4　论文结构安排 ····· 5

2　安全对齐机制与漏洞机理分析 ····· **6**

2.1　大语言模型及安全对齐技术基础 ····· 6

2.2　大语言模型概述 ····· 6

2.3　安全对齐技术体系 ····· 7

2.4　主流对齐方法及其作用机理 ····· 9

2.5　安全对齐中的目标冲突问题 ····· 11

2.6　对齐表层性与行为泛化局限 ····· 13

2.7　上下文与交互过程中的对齐失效 ····· 14

2.8　本章小结 ····· 16

3　多维越狱攻击框架与实验设计 ····· **17**

3.1　越狱攻击问题定义与威胁模型 ····· 17

3.2　多维越狱攻击框架设计 ····· 19

3.3 九类静态攻击维度与测试集构建 …… 20
3.3.1 编码扰动维度 …… 21
3.3.2 角色扮演维度 …… 21
3.3.3 认知误导维度 …… 21
3.3.4 上下文操控维度 …… 22
3.3.5 语言变体维度 …… 22
3.3.6 指令重构维度 …… 23
3.3.7 对抗后缀维度 …… 23
3.3.8 格式伪装维度 …… 23
3.3.9 复合混合维度 …… 24
3.4 自动化红队攻击扩展机制 …… 25
3.5 多轮交互式越狱扩展机制 …… 25
3.6 统一实验流程与评估指标 …… 27
3.7 本章小结 …… 29

4 多维越狱攻击实验评测与结果分析 …… 30

4.1 实验目标与实验设置 …… 30
4.2 静态攻击结果的总体特征 …… 30
4.2.1 整体成功率与风险分布特征 …… 30
4.2.2 跨模型共性脆弱性概览 …… 32
4.3 不同攻击维度的脆弱性比较 …… 33
4.3.1 语义包装类攻击的突出作用 …… 33
4.3.2 结构重构与上下文前缀的持续影响 …… 34
4.3.3 表面扰动类攻击的边界意义 …… 35
4.4 风险等级分布与边界模糊性分析 …… 36
4.4.1 低直接成功率下的高不确定性特征 …… 36
4.4.2 高风险样本的分布特点 …… 37

4.5 典型案例分析 …… 37
4.5.1 认知误导样本揭示的任务解释偏移 …… 37
4.5.2 示例链与结构化前缀的诱导效应 …… 38
4.5.3 低成功维度中的残余鲁棒性 …… 39
4.6 自动化红队生成的补充实验结果 …… 39
4.7 多轮交互攻击的补充实验结果 …… 40
4.8 对齐失效机理讨论 …… 41
4.8.1 目标冲突导致的脆弱性暴露 …… 41
4.8.2 表层对齐的泛化局限 …… 41
4.8.3 上下文依赖与过程脆弱性的静态显现 …… 41
4.9 本章小结 …… 42

5 面向越狱攻击的分层防御方案 …… 43

5.1 防御问题定义与设计目标 …… 43
5.2 分层防御总体框架 …… 44
5.2.1 分层防御的总体思路 …… 44
5.2.2 防御决策与风险传递机制 …… 44
5.3 输入层防御机制 …… 46
5.3.1 输入层防御的功能定位 …… 46
5.3.2 基于规则与分类器的风险识别 …… 46
5.3.3 输入层的阻断与改写策略 …… 48
5.4 交互层防御机制 …… 48
5.4.1 交互层防御的功能定位 …… 48
5.4.2 风险累积与诱导行为检测 …… 49
5.4.3 多轮场景下的限制与截断策略 …… 50
5.5 输出层防御机制 …… 50
5.5.1 输出层防御的功能定位 …… 50

5.5.2 面向危险内容的输出风险识别 …… 51
5.5.3 输出替换、脱敏与审计记录策略 …… 51
5.6 三层防御的协同作用与适用范围 …… 52
5.6.1 分层协同的必要性分析 …… 52
5.6.2 面向多维攻击框架的防御映射关系 …… 53
5.7 防御效果评估方案 …… 53
5.7.1 防御实验设置 …… 53
5.7.2 防御效果评估指标 …… 54
5.7.3 结果分析位置预留 …… 55
5.8 本章小结 …… 55

6 总结与展望 …… 56

6.1 全文工作总结 …… 56
6.2 本文主要研究内容与结论 …… 57
6.2.1 安全对齐漏洞机理方面的研究总结 …… 57
6.2.2 越狱攻击体系构建与实验评估方面的研究总结 …… 57
6.2.3 分层防御方案方面的研究总结 …… 58
6.3 本文的主要创新点 …… 58
6.3.1 从统一机理视角分析安全对齐漏洞 …… 58
6.3.2 构建面向多维越狱攻击的统一实验框架 …… 58
6.3.3 提出面向全过程风险控制的三层防御思路 …… 59
6.4 研究局限与不足 …… 59
6.4.1 实验覆盖范围仍有进一步扩展空间 …… 59
6.4.2 攻击场景与系统环境仍相对有限 …… 59
6.4.3 分层防御方案的泛化能力仍需持续验证 …… 59
6.5 未来研究展望 …… 60
6.5.1 构建更完整的攻防一体化评测体系 …… 60

6.5.2 面向复杂交互与智能体场景开展安全研究 …… 60
6.5.3 探索更具泛化能力的鲁棒防御方法 …… 60
6.5.4 推动安全对齐从经验约束走向机制约束 …… 60
6.6 本章小结 …… 61

参考文献 …… **62**

致谢 …… **65**

1 绪论

1.1 研究背景与意义

近年来，大语言模型（Large Language Models, LLMs）在自然语言处理领域取得了显著进展，并在智能问答、内容生成、代码辅助及智能代理等任务中展现出强大的能力。随着 Transformer 架构的发展和模型规模的持续扩展，LLMs 在复杂推理、多轮交互及跨模态理解等方面不断取得突破，逐渐成为人工智能领域的核心基础技术[1]。同时，模型能力正从单一文本处理向多模态融合与自主决策能力演进，使其在实际应用中的影响力不断扩大。

然而，随着模型能力的增强，其潜在的安全风险也日益凸显。由于训练数据来源复杂且规模庞大，大语言模型不可避免地继承数据中的偏差与不确定性，从而具备生成不安全内容的潜在能力。在缺乏有效约束的情况下，模型可能输出涉及暴力、隐私泄露或误导性信息的内容，对用户与平台安全构成威胁[2-4]。此外，模型在开放环境中的部署进一步放大了其风险边界，例如在长上下文、多轮交互及工具调用等复杂场景下，模型行为更加难以预测与控制。

近年来，随着大语言模型逐步向智能体（Agent）形态发展，其与外部工具、执行系统及现实任务的耦合程度不断加深。例如，具备自主规划与执行能力的系统使模型不仅能够生成文本，还可能直接影响现实系统决策过程。在此背景下，模型安全问题已从“内容生成风险”演变为“系统级风险”，一旦模型行为失控，可能带来更为严重的连锁影响[5]。

为降低上述风险，研究界提出了一系列安全对齐（Safety Alignment）方法，如监督微调（Supervised Fine-Tuning, SFT）、基于人类反馈的强化学习（Reinforcement Learning from Human Feedback, RLHF）以及直接偏好优化（Direct Preference Optimization, DPO）等[6-8]。这些方法通过引入人类价值偏好与安全约束，使模型在生成能力与安全性之间取得一定平衡。然而，现有对齐方法在复杂语境、分布外输入及多样化交互场景中仍存在明显局限，其鲁棒性与泛化能力尚未得到充分保障。

因此，系统研究大语言模型的安全对齐机制及其潜在漏洞具有重要意义。从理论角度来看，有助于深入理解模型对齐过程中的行为约束机制及其失效边界；

从实践角度来看，可为风险评估、攻击分析与防御策略设计提供方法基础。在大语言模型持续向更高能力与更广应用场景发展的趋势下，开展相关研究对于提升人工智能系统的安全性与可靠性具有重要价值。

1.2 国内外研究现状

随着大语言模型（Large Language Models, LLMs）的广泛应用，其安全性问题逐渐成为人工智能领域的重要研究方向。近年来，国内外研究围绕安全对齐机制、越狱攻击方法及防御策略等方面展开了系统探索，形成了较为完整的研究体系。现有研究大体可从安全对齐方法、越狱攻击技术以及防御机制三个方面进行归纳。

1.2.1 安全对齐方法研究

为约束大语言模型生成不安全内容，研究界提出了一系列安全对齐方法，主要包括基于数据与基于人类反馈的优化策略。在训练流程上，这些方法通常贯穿预训练、监督微调以及对齐优化等多个阶段。

监督微调（Supervised Fine-Tuning, SFT）通过构建高质量指令数据，使模型学习符合人类期望的行为模式；在此基础上，基于人类反馈的强化学习（Reinforcement Learning from Human Feedback, RLHF）通过引入奖励模型，对模型输出进行偏好引导，从而提升生成结果的安全性与可控性。此外，直接偏好优化（Direct Preference Optimization, DPO）等新方法通过简化优化流程，避免显式奖励模型训练，提高了对齐效率与稳定性[6,8]。

除了上述主流方法，研究者还提出多种改进策略，如基于统计优化的对齐方法（RSO、ORPO 等），以及结合数据清洗与偏好建模的综合对齐框架[7,2]。这些方法共同推动了大语言模型从“能力导向”向“安全可控”方向发展，使模型在大多数常规场景下能够遵循基本的安全规范。

1.2.2 越狱攻击方法研究

随着对齐技术的发展，研究者逐渐发现，大语言模型在面对特定构造输入时仍可能被诱导绕过安全机制并生成违规内容，这类攻击被称为“越狱攻击”[9-11]。

相关研究表明，攻击者无需掌握模型内部结构，仅通过设计输入提示即可实现高成功率攻击。

现有越狱攻击方法主要可分为三类：

基于人工构造的越狱方法：通过角色扮演、语义重写或编码转换等方式改写原始问题，使其绕过安全检测[12-14]。

基于优化的对抗攻击方法：利用梯度信息或搜索策略自动生成对抗提示，如 GCG（Greedy Coordinate Gradient）方法通过优化输入后缀显著提升攻击成功率[9,15]。这类方法强调利用模型的概率生成机制实现精确攻击。

基于红队模型的自动化攻击方法：借助辅助模型（Red Teaming LLM）自动生成与优化越狱提示，如 GPTFuzzer、PAIR 及 TAP 等方法通过迭代优化显著提升攻击效率与泛化能力[16,10-11]。

从更细粒度角度看，越狱攻击还可根据实现机制划分为语言语义攻击、基于优化的对抗攻击以及混合攻击等类型，这些方法从不同层面揭示了模型在语义理解、概率建模及交互过程中的潜在脆弱性。

1.2.3 防御方法与安全增强机制研究

针对越狱攻击带来的风险，研究界提出了多种防御方法，主要可分为模型内部对齐与外部安全增强两类。

在模型内部层面，防御方法主要通过改进训练策略提升模型鲁棒性。例如，通过对抗数据增强，将恶意提示引入训练数据，使模型学习识别潜在攻击；或通过针对性微调提升模型在特定场景下的安全表现[17-18]。这类方法旨在从参数层面增强模型的安全性。

在模型外部层面，防御策略主要作用于推理阶段，包括输入过滤与输出检测两类机制。输入侧防御通过检测、改写或屏蔽潜在恶意提示，阻止攻击进入模型；输出侧防御则通过审查模型生成结果，确保其符合安全规范。例如，基于规则或辅助模型的输出审查机制已成为实际系统中的常见方案[19,2,17]。

此外，近年来研究逐渐关注全生命周期防御策略，从训练、部署到推理阶段构建统一安全防护体系，以提升模型在复杂应用场景下的整体安全性。

1.3 研究问题与本文主要工作

尽管现有研究在越狱攻击构造、安全对齐训练以及推理阶段防御等方面取得了一定进展，但整体上仍存在若干关键问题亟待系统性解决。现有工作大多从攻击或防御的单一视角出发展开研究，攻防方法之间缺乏统一的分析框架与实验范式，使得不同研究结论难以进行系统对比与综合评估，从而限制了对模型安全机制的整体理解。同时，不同安全对齐方法（如 SFT、RLHF、DPO 等）在安全性表现上的差异尚缺乏系统性的横向研究，其在目标函数设计、对齐方式及泛化能力方面的内在机制仍不清晰，难以解释模型在复杂语境及分布外输入条件下的对齐失效现象。在攻击侧，现有越狱方法多依赖人工模板或局部优化策略，生成样本在多样性与适应性方面存在局限，难以全面覆盖开放环境中的潜在攻击空间。此外，随着多模态输入与复杂交互场景的逐步引入，跨模态信息与长上下文结构对模型安全性的影响尚未得到充分探讨，使得现有研究在应用层面的解释力仍存在不足。

围绕上述问题，本文以大语言模型安全对齐漏洞为研究核心，从“攻击—评估—防御”的闭环视角出发，对模型安全机制展开系统性分析与方法研究。在机制层面，本文从模型训练与对齐过程入手，对 SFT、RLHF 及 DPO 等主流方法在安全约束中的作用机制进行统一分析，重点揭示目标优化之间的潜在冲突、对齐策略的表层性特征以及模型在分布外场景下的泛化局限，从而从理论上解释越狱攻击得以成立的内在原因。在方法层面，针对现有越狱攻击依赖固定模板的问题，设计了一种面向攻击目标的定向越狱提示生成方法，通过结构化建模与自动化生成机制提升攻击样本的多样性与覆盖能力，使攻击过程从经验驱动转向目标驱动。在实验层面，本文构建统一的评测框架，在多模型与多攻击策略条件下对越狱攻击效果进行系统评估，并基于实验结果归纳不同对齐机制下模型的脆弱性特征。在此基础上，进一步结合攻击机理与实验分析结果，从输入层、交互层与输出层三个层面设计分层防御方案，并通过对比实验验证其有效性与适用范围。

基于上述研究，本文在统一分析安全对齐机制的基础上，系统刻画了大语言模型在不同对齐策略下的安全行为特征，并提出了具有更高多样性与可扩展性的越狱攻击生成方法，同时构建了面向攻防一体化的评测框架与分层防御体系，

实现了从机制分析到方法设计再到实验验证的闭环研究路径。总体而言，本文从系统视角出发，对大语言模型的安全对齐机制及其越狱攻击问题进行了统一建模与综合分析，推动相关研究由单点方法探索向机制理解与工程化闭环验证转变，为构建更加鲁棒与可信的大模型安全防护体系提供参考。

1.4 论文结构安排

本文围绕大语言模型安全对齐机制及其越狱攻击问题展开研究。全文结构安排如下：

第一章为绪论，介绍研究背景与意义，梳理国内外研究现状，并明确本文的研究问题、研究思路与主要工作。

第二章分析大语言模型安全对齐机制及其潜在漏洞，从大语言模型生成原理与 SFT、RLHF、DPO 等主流对齐方法出发，讨论安全约束在目标冲突、表层对齐和上下文依赖等方面的局限性。

第三章围绕多维越狱攻击框架与实验设计展开研究，在明确越狱攻击威胁模型的基础上，系统组织九类静态攻击维度测试集，并结合自动化红队扩展机制与多轮交互扩展机制说明统一实验流程与评估指标，为后续实验评测提供方法基础。

第四章围绕多维越狱攻击实验评测与结果分析展开，分别从九类静态攻击维度实验、自动化红队补充实验和多轮交互补充实验三个层面评估模型安全性，并结合实验现象对目标冲突、表层对齐与交互过程中的对齐失效机理进行分析。

第五章提出面向越狱攻击的分层防御方案，从输入层、交互层与输出层三个阶段设计协同防御机制，并给出后续用于验证防御效果的实验评估思路。

第六章对全文研究工作进行总结，归纳本文的主要研究内容、创新点与不足，并展望大语言模型安全对齐、越狱攻击评测与鲁棒防御的未来研究方向。

2 安全对齐机制与漏洞机理分析

2.1 大语言模型及安全对齐技术基础

2.2 大语言模型概述

大语言模型（Large Language Models, LLMs）是一类基于深度神经网络构建的生成式语言模型，通常依托大规模语料进行预训练，以学习自然语言中的统计分布规律与语义表示。相较于传统面向特定任务设计的自然语言处理模型，大语言模型普遍采用“预训练—对齐”的范式：首先通过开放域语料进行无监督或自监督训练，获得通用语言能力；随后通过指令微调、偏好优化等方法对模型行为进行约束，使其适配具体应用场景[1,6]。

从模型结构上看，当前主流大语言模型多基于 Transformer 架构，通过自注意力机制刻画序列中不同位置之间的依赖关系，从而实现对长距离上下文的有效建模。在自回归生成框架下，模型通过最大化条件概率分布来生成文本，即在给定上下文 $x_{1:n}$ 的条件下预测下一个词元 x_{n+1} 的概率[1]：

$$P(x_{n+1} \mid x_{1:n}) \tag{2.1}$$

通过对上述条件概率的逐步建模与采样，模型能够生成语义连贯的文本序列。该生成机制决定了模型输出本质上是对训练数据分布的拟合结果，而非基于显式规则的推理过程。

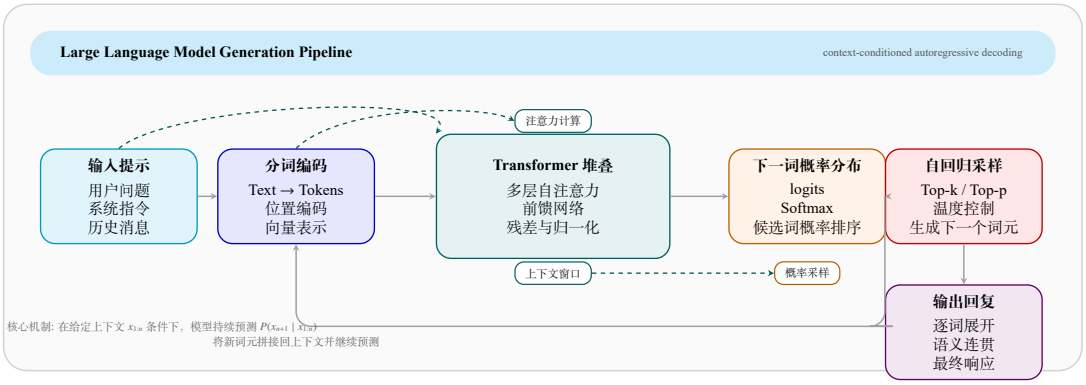

图 2.1 大语言模型生成机制示意图

$$P(x_{1:T}) = \prod_{t=1}^{T} P(x_t \mid x_{<t}) \tag{2.2}$$

其中，x_t 表示第 t 个词元，$x_{<t}$ 表示第 t 步之前的前缀上下文，T 表示输出序列长度。该式与前文的单步条件概率共同构成了自回归语言模型的完整生成定义。

随着模型参数规模、训练数据规模以及优化方法的不断提升，大语言模型在多任务场景中表现出显著的泛化能力，并在指令理解、复杂推理及多轮对话等任务中取得了优异性能。同时，模型在一定条件下还表现出上下文学习与链式推理等能力，使其能够在无需额外训练的情况下完成多种复杂任务[1]。

然而，大语言模型的能力提升并未伴随安全性的同步增强。预训练阶段的优化目标主要关注语言建模能力，而非对有害内容的识别与约束，因此模型不可避免地继承训练数据中的偏差与不确定性。在缺乏额外约束的情况下，模型可能在特定输入条件下生成不符合安全规范的内容。

此外，大语言模型的生成过程高度依赖输入上下文，其输出行为不仅由当前提示决定，还受到历史上下文的持续影响。这种上下文依赖特性在提升模型表达能力的同时，也为对抗性输入提供了作用空间，使得攻击者可以通过构造特定语境诱导模型偏离既定行为约束。

综上，大语言模型作为一种基于概率建模的生成系统，其行为本质上受数据分布与上下文条件共同驱动。在缺乏有效约束机制的情况下，其输出存在被诱导产生不安全内容的风险。因此，有必要在此基础上进一步引入安全对齐机制，以对模型行为进行系统性约束。

2.3 安全对齐技术体系

在大语言模型的应用过程中，仅依赖预训练阶段获得的语言建模能力难以满足实际场景中的安全要求，因此需要引入额外的约束机制对模型行为进行规范。所谓安全对齐（Safety Alignment），是指通过训练、控制与评估等多种手段，使模型生成内容尽可能符合人类价值、平台规范及应用安全边界。从实现路径上看，安全对齐并非单一方法，而是由模型内部训练机制与外部防护机制共同构成的综合技术体系。

在模型内部层面，安全对齐主要通过后训练（post-training）过程实现，其核

心目标是在保持模型能力的同时，引导其生成行为向“安全且有用”的方向收敛。其中，有监督微调（Supervised Fine-Tuning, SFT）构成了最基础的对齐路径。SFT 通过构建高质量的指令—响应数据，对预训练模型进行进一步训练，使其在面对潜在风险请求时倾向于输出拒答、警示或安全替代内容。该方法能够有效塑造模型的交互风格与基本行为边界，但其约束能力依赖于训练样本的覆盖范围，对于未见或变形输入的泛化能力相对有限[2,17]。

在此基础上，基于人类反馈的强化学习（Reinforcement Learning from Human Feedback, RLHF）进一步引入偏好建模机制。该方法通过构建人类偏好数据并训练奖励模型，对模型输出进行质量评估，并利用强化学习算法优化生成策略，使模型在多种候选响应中更倾向于选择符合安全与偏好约束的结果。相较于 SFT，RLHF 能够在“有用性”与“安全性”之间实现更细粒度的权衡。然而，由于奖励模型本质上仍是对有限偏好数据的近似，其泛化能力受限，且在复杂场景下可能出现奖励偏移或策略失真等问题[6,8]。

为降低训练复杂度并提升优化稳定性，直接偏好优化（Direct Preference Optimization, DPO）等方法在不显式构建奖励模型的前提下，直接利用偏好数据对模型参数进行优化。该类方法通过将偏好关系转化为对数似然约束，实现对生成策略的直接调整，从而在一定程度上简化了对齐流程并提高了训练效率。尽管如此，其本质仍依赖于有限的偏好样本分布，因此同样难以完全覆盖开放环境中的复杂输入空间[6-8]。

除上述内部对齐方法外，安全对齐体系还依赖于模型外部的安全增强机制。在实际部署过程中，常通过输入检测、提示重写及输出审查等方式对模型行为进行二次约束，以降低越狱攻击带来的风险。此外，红队测试（red teaming）作为重要的评估与增强手段，通过构造对抗性输入系统性探测模型的潜在漏洞，为对齐策略的迭代优化提供依据[19,2,16]。

总体而言，当前大语言模型的安全对齐技术体系呈现出“内部训练约束—外部防护增强—持续评估优化”的协同结构。SFT、RLHF 及 DPO 等方法在常规场景下能够显著提升模型的安全表现，但其约束机制主要建立在有限样本与偏好近似之上，对分布外输入及对抗性攻击的鲁棒性仍有待进一步提升。这种以内在统计学习为基础的对齐方式，也为后续越狱攻击提供了可利用空间。

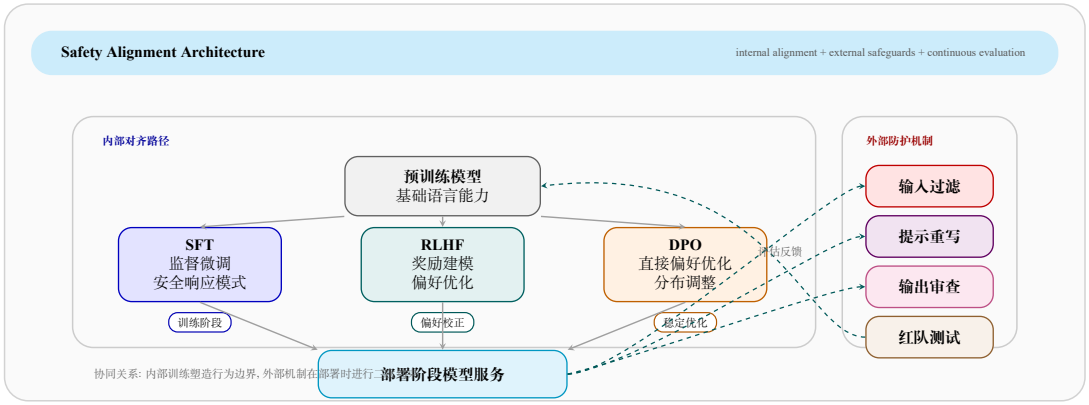

图 2.2　安全对齐技术体系总览图

表 2.1　第二章表格占位表：主流安全对齐方法比较表

方法	核心目标	优势	局限
SFT	拟填“基于监督样本学习安全响应模式”	拟填“训练稳定、实现简单、行为边界清晰”	拟填“依赖样本覆盖，泛化有限”
RLHF	拟填“基于奖励模型优化有用性与安全性平衡”	拟填“能进行全局偏好调节”	拟填“奖励偏移、训练复杂、对分布外样本敏感”
DPO	拟填“基于偏好对直接调整输出分布”	拟填“流程较简洁、优化较稳定”	拟填“仍依赖偏好样本分布，缺乏硬约束”

附注：该表建议直接作为论文正式表格，不需要额外绘图；内容可结合参考文献中的方法介绍和你第二章的文字总结进一步压缩润色。

2.4　主流对齐方法及其作用机理

当前大语言模型的安全对齐主要通过后训练阶段实现，其中以有监督微调（SFT）、基于人类反馈的强化学习（RLHF）以及直接偏好优化（DPO）为代表的方法构成了主流技术路径[6-8]。这些方法在形式上有所差异，但其本质均是通过引入外部偏好信息，对模型的生成分布进行重塑，从而改变其在特定输入条件下的输出行为。

从机理上看，大语言模型的生成过程可以视为对条件概率分布 $P_\theta(y|x)$ 的建模，而安全对齐的核心目标在于对该分布进行约束，使其在满足任务需求的同时，降低生成不安全内容的概率。不同对齐方法的差异主要体现在约束施加的方式及优化路径上。

有监督微调（SFT）通过构建高质量的指令—响应数据，对预训练模型进行进一步训练，其优化目标通常仍为最大似然估计。在该过程中，模型通过模仿数

据中的“安全响应模式”，逐步调整其条件分布，使得在相似输入下更倾向于生成符合规范的输出。从机制上看，SFT 本质上是一种基于行为模仿的分布调整方法，其约束作用来源于示例数据对模型输出空间的重塑。然而，由于其优化目标仍然是局部条件概率的最大化，模型并未显式学习安全约束本身，而是学习其在训练数据中的表征形式。

在 SFT 的基础上，基于人类反馈的强化学习（RLHF）通过引入奖励模型，对生成结果进行全局质量评估。具体而言，RLHF 首先利用人类偏好数据训练奖励模型 $R_\phi(x, y)$，用于衡量输出的优劣；随后通过强化学习算法（如 PPO）优化语言模型参数，使其生成结果在奖励函数下具有更高期望值。从优化角度看，RLHF 将原始的似然最大化问题转化为期望奖励最大化问题，使模型在候选输出之间进行策略选择，从而在一定程度上实现“有用性”与“安全性”的权衡。然而，奖励模型本质上仍是对有限偏好数据的近似，其评估能力受数据分布与标注一致性的限制，可能在复杂或未见场景中产生偏差。

直接偏好优化（DPO）则在不显式构建奖励模型的情况下，直接利用成对偏好数据对模型参数进行优化。其核心思想是将人类偏好关系转化为对数似然约束，使模型在给定输入下对“优选响应”的概率高于“劣选响应”。与 RLHF 相比，DPO 避免了奖励模型训练及强化学习过程中的不稳定性问题，在优化路径上更加简洁。从机理上看，DPO 仍然通过调整条件概率分布来体现偏好信息，其约束作用直接来源于偏好数据本身，而非中间奖励函数。

综合来看，SFT、RLHF 与 DPO 在形式上分别对应行为模仿、奖励驱动与偏好约束三种不同的对齐路径，但其共同特征在于：均依赖有限数据对模型分布进行统计性修正，而未引入显式的安全规则或可验证约束。这种基于数据驱动的对齐机制在常见场景下能够有效引导模型行为，但在面对分布外输入或对抗性构造时，其约束能力可能出现不稳定性。

此外，这些方法在训练过程中通常假设输入分布与实际应用环境一致，而在开放场景下，用户输入具有高度不确定性与可操控性。攻击者可以通过对输入进行语义重构、上下文扩展或结构扰动，使其偏离训练分布，从而削弱对齐机制的约束效果。这一现象表明，现有对齐方法在本质上仍属于基于经验分布的软约束，其安全边界缺乏稳定的理论保证。

$$\max_{\pi_\theta} \mathbb{E}_{y\sim\pi_\theta(\cdot|x)}\left[R_\phi(x,y)\right] - \beta\,\mathrm{KL}(\pi_\theta \,\|\, \pi_{\mathrm{ref}}) \tag{2.3}$$

其中，π_θ 表示待优化策略，$R_\phi(x,y)$ 表示奖励模型对输出质量的评估结果，π_{ref} 表示参考模型，β 表示 KL 正则项的权重系数。该式刻画了 RLHF 在奖励最大化与策略偏移控制之间的优化平衡。

$$\log\sigma\left(\beta\log\frac{\pi_\theta(y_w \mid x)}{\pi_{\mathrm{ref}}(y_w \mid x)} - \beta\log\frac{\pi_\theta(y_l \mid x)}{\pi_{\mathrm{ref}}(y_l \mid x)}\right) \tag{2.4}$$

其中，y_w 表示优选响应，y_l 表示劣选响应，$\sigma(\cdot)$ 表示 Sigmoid 函数。该式说明 DPO 通过直接拉大优选响应与劣选响应之间的相对对数概率差，实现对偏好关系的显式建模。

2.5 安全对齐中的目标冲突问题

大语言模型的安全对齐过程本质上可视为一个多目标优化问题。在实际应用中，模型不仅需要具备较强的任务完成能力（helpfulness），还需满足安全性约束（harmlessness）及合规性要求。这些目标在多数情况下可以协同优化，但在复杂或边界情境下往往存在潜在冲突，从而导致模型行为的不稳定性。

从优化角度来看，预训练阶段的语言模型主要通过最大化条件概率分布来提升生成能力，其目标是提高输出的相关性与信息丰富性。而在对齐阶段，引入的人类偏好与安全约束则倾向于抑制某些高概率但潜在不安全的生成路径。因此，对齐过程实际上是在原始生成目标与安全约束之间进行权衡，即在“生成尽可能有用的内容”与“避免生成潜在风险内容”之间寻找平衡点。

这种目标之间的张力在具体任务中表现为不一致的优化方向。例如，在某些敏感问题场景中，提供详细且有用的信息可能同时增加潜在风险，而严格的安全约束则可能导致模型过度拒答，降低其实用性。为缓解这一问题，RLHF 等方法通常通过奖励函数对不同目标进行加权整合，使模型在期望意义下取得折中解。然而，该折中结果依赖于奖励设计及偏好数据分布，在不同输入条件下可能呈现出不稳定行为[6,8]。

进一步地，由于对齐过程缺乏显式的约束边界，其优化结果通常以隐式方式编码于模型参数之中。这种基于统计学习的约束方式难以在所有输入空间中保

持一致性，尤其是在分布外或对抗性输入条件下，模型可能优先满足“有用性”目标，从而弱化安全约束，产生对齐失效现象。

此外，不同对齐方法在处理目标冲突时采用的策略存在差异。SFT 主要通过示例数据隐式传递行为偏好，其对冲突情境的处理能力有限；RLHF 通过奖励模型对输出进行全局评估，在一定程度上缓解了目标冲突，但其效果依赖于奖励模型的准确性与稳定性；DPO 则通过偏好对约束生成分布，其优化结果同样受限于偏好数据的表达能力。这些方法均未从机制上消除目标冲突，而是通过数据驱动的方式进行近似协调。

综上，安全对齐中的目标冲突问题是导致模型行为不稳定的重要因素之一。在缺乏统一优化目标及明确约束边界的情况下，模型在不同输入条件下可能表现出差异化的行为倾向。这种内在冲突为越狱攻击提供了可利用空间，即通过构造特定输入，使模型在“有用性”与“安全性”的权衡过程中偏向前者，从而绕过既有安全约束。

$$\max_{\theta} \ \lambda_1 U(\theta; x) - \lambda_2 H(\theta; x) \tag{2.5}$$

其中，$U(\theta; x)$ 表示模型在输入 x 上的有用性目标，$H(\theta; x)$ 表示潜在风险或有害性目标，λ_1 与 λ_2 分别表示两类目标的权重系数。该式用于说明安全对齐实质上是在有用性与安全性之间求取折中解的多目标优化过程。

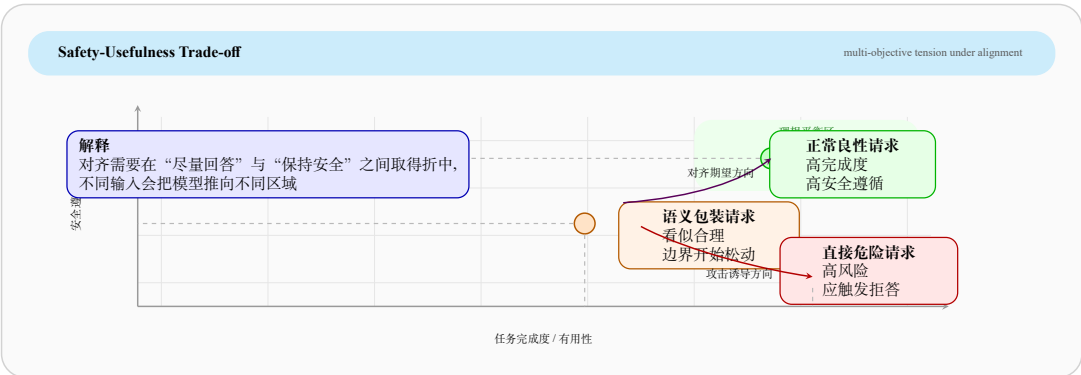

图 2.3 安全性与有用性目标冲突示意图

2.6 对齐表层性与行为泛化局限

现有大语言模型的安全对齐方法主要依赖数据驱动的统计学习机制，其约束作用通常体现在对特定输入—输出模式的学习上，而非对安全语义的深层理解。这一特性使得对齐结果在很大程度上表现为“表层对齐”（superficial alignment），即模型倾向于学习可观测的行为模式，而非内在的安全原则。

从机制上看，无论是 SFT、RLHF 还是 DPO，其优化过程均以训练数据中的示例或偏好为依据，对模型条件概率分布进行调整。在这一过程中，模型通过捕捉输入与输出之间的统计相关性，学习在特定语境下应当采取的响应策略。例如，在涉及敏感请求时，模型可能学习到以固定形式进行拒答或提供安全提示。然而，这种学习方式并未使模型形成对“何为不安全”的抽象语义表示，而是将安全约束映射为一类特定的语言表达模式。

由于缺乏语义层面的约束能力，当输入形式发生变化时，模型已学习的行为模式可能无法正确触发。例如，通过对问题进行语义重写、编码转换或上下文包装，攻击者可以构造与训练分布差异较大的输入，使其规避模型已习得的拒答模式[13-14,12]。在此情况下，模型仍可能沿着原有的语言建模路径生成高概率但不安全的内容，从而表现出对齐失效。

进一步地，这种表层对齐特性还会受到分布外输入的影响。在开放环境中，用户输入具有高度多样性，而训练数据只能覆盖有限的表达形式。当输入超出训练分布时，模型往往依赖其通用语言能力进行推断，而非遵循对齐阶段学习到的行为模式。这种“泛化偏移”使得模型在复杂语境或组合型输入条件下更容易出现不符合预期的输出行为。

此外，在多轮对话与长上下文场景中，模型的行为不仅取决于单轮输入，还受到历史上下文的累积影响。当对齐约束未能在整个上下文空间中保持一致时，模型可能在局部语境中偏离既定的安全策略。这种现象进一步放大了表层对齐带来的局限，使得攻击者能够通过逐步引导的方式削弱模型的安全约束[20,10]。

综上，现有安全对齐方法在本质上是一种基于数据分布的表层行为约束，其有效性依赖于训练样本对输入空间的覆盖程度。在缺乏语义级约束与全局一致性机制的情况下，模型在面对分布外或对抗性输入时容易出现泛化失效。这种表层性与泛化局限构成了越狱攻击得以实现的重要基础。

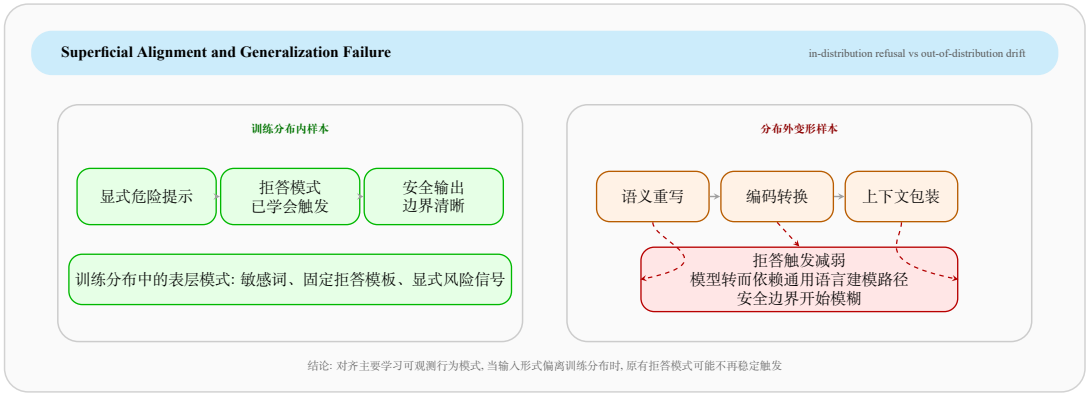

图 2.4　表层对齐与泛化失效示意图

2.7　上下文与交互过程中的对齐失效

大语言模型的生成行为具有显著的上下文依赖特性，其输出不仅取决于当前输入，还受到历史上下文的持续影响。在实际应用中，模型通常以多轮对话或长上下文形式运行，这使得安全对齐不再是针对单一输入的约束问题，而是需要在整个交互过程中保持一致性的动态约束。然而，现有对齐方法主要基于静态输入—输出样本进行训练，缺乏对复杂交互过程的全局建模能力，从而在多轮与长上下文场景下容易出现对齐失效。

从机制上看，大语言模型在生成过程中依赖条件概率分布 $P(y|x_{1:n})$ 对当前上下文进行建模。当上下文中逐步引入新的信息时，模型的生成分布会随之发生动态变化。在这一过程中，早期对齐阶段所学习的安全行为模式可能被后续上下文所弱化或覆盖，导致模型输出逐渐偏离原有的安全约束。这种现象在长上下文条件下尤为明显，即随着上下文长度增加，模型对初始安全信号的依赖逐渐减弱。

在多轮交互场景中，对齐失效通常表现为累积式偏移。攻击者可以通过一系列看似合理的中间步骤逐步引导模型，使其在局部语境中接受某些隐含前提，从而在后续生成中输出不符合安全规范的内容。这种逐步诱导方式避免了直接触发显式的安全拒答机制，使攻击过程更加隐蔽且具有较高成功率[10-11,20]。

此外，上下文结构的重构也是导致对齐失效的重要因素。例如，通过角色设定、情境假设或任务重定义等方式，可以改变模型对当前对话语境的理解，使其将原本受限的内容重新解释为“合理请求”[12,21]。在此情况下，模型并非完全忽略安全约束，而是在新的语境下重新评估生成策略，从而产生与原始安全目标不一致的输出。

进一步地，在复杂系统场景中（如工具调用或智能体框架），模型的输入不再仅来自用户，还可能包含外部环境反馈或系统生成内容。这种多源上下文的叠加进一步扩大了输入空间的复杂性，使得对齐机制难以在所有路径上保持一致约束。在缺乏统一上下文建模与状态跟踪机制的情况下，模型行为更容易受到局部信息的干扰。

$$y_t \sim P_\theta(\cdot \mid x, h_{1:t-1}) \tag{2.6}$$

其中，x 表示当前输入，$h_{1:t-1}$ 表示截至第 $t-1$ 轮的历史上下文，y_t 表示第 t 轮输出。该式表明多轮交互中的当前响应是由当前输入与历史对话共同决定的条件生成结果。

$$R_t = \alpha R_{t-1} + s(x_t, h_{1:t-1}) \tag{2.7}$$

其中，R_t 表示第 t 轮的累计风险，α 表示历史风险的衰减系数，$s(x_t, h_{1:t-1})$ 表示当前轮输入在既有上下文条件下引入的风险增量。该式用于刻画多轮交互过程中风险随上下文逐步累积的动态特征。

图 2.5　多轮交互中的对齐失效路径图

综上，上下文依赖与交互动态性使得大语言模型的安全对齐问题从“静态约束”转变为“过程约束”。现有方法由于主要基于单轮样本进行训练，难以在多轮与复杂上下文环境中维持稳定的安全行为。这种在交互过程中的对齐失效，与目标冲突及表层对齐问题相互叠加，共同构成了越狱攻击得以实现的重要机制基础。

2.8 本章小结

本章围绕大语言模型的安全对齐机制及其潜在漏洞，从模型生成原理与对齐方法出发，对其内在机理进行了系统分析。首先，对大语言模型的基本建模方式进行了概述，指出其基于条件概率分布的生成机制决定了模型行为对数据分布与上下文输入的高度依赖。在此基础上，进一步梳理了当前主流的安全对齐技术体系，包括基于 SFT、RLHF 及 DPO 的内部训练方法，以及输入输出约束与红队测试等外部增强机制。

在对齐方法机理分析的基础上，本文从优化目标、行为表征及交互过程三个层面对安全对齐的局限性进行了深入探讨。具体而言，目标冲突问题揭示了模型在“有用性”与“安全性”之间难以实现统一优化；表层对齐特性表明模型主要学习的是可观测的行为模式，而非安全语义本身；上下文依赖与多轮交互则进一步放大了对齐约束的不稳定性，使模型在动态输入条件下更易出现偏离。

综合上述分析可以看出，现有安全对齐方法本质上仍属于基于数据分布的软约束，其有效性依赖于训练样本与偏好数据的覆盖范围，在面对分布外输入及对抗性构造时缺乏稳定的约束能力。上述机制性缺陷共同构成了越狱攻击得以实现的基础条件。

因此，有必要在统一分析框架下，对不同攻击方式在上述机制约束下的表现进行系统评估。基于此，下一章将围绕越狱攻击方法展开，通过构建统一实验框架，对不同攻击策略在多模型条件下的有效性进行分析，并进一步揭示模型安全对齐的脆弱性特征。

3 多维越狱攻击框架与实验设计

3.1 越狱攻击问题定义与威胁模型

结合第二章对安全对齐漏洞机理的分析，本文将越狱攻击定义为：攻击者在无法访问目标模型内部参数、训练细节与对齐策略的前提下，通过构造特定输入提示，使模型绕过既有安全约束并输出不符合平台规范或应用边界的内容[9-11]。设目标模型为 $f_\theta(\cdot)$，输入提示为 x，模型输出为 $y = f_\theta(x)$。在理想安全对齐条件下，模型输出应满足安全约束集合 $\mathcal{C}$，即 $y \in \mathcal{Y}_{safe}$；而越狱攻击的目标则是构造攻击输入 x'，使模型在保持任务连贯性的同时生成不安全响应：

$$y' = f_\theta(x'), \quad y' \notin \mathcal{Y}_{safe} \tag{3.1}$$

与依赖梯度扰动或参数访问的传统对抗攻击不同，本文研究的越狱攻击主要发生在自然语言交互层面，其核心不在于修改模型本体，而在于改变模型对任务意图、语义边界与上下文条件的解释路径。攻击者可通过角色设定、认知包装、语言转换、结构伪装、编码变换或示例诱导等方式，使危险目标在表面上呈现为研究分析、格式转换、情境模拟或普通问答，从而削弱安全拒答机制的触发概率[12-14,20]。

本文实验采用黑盒威胁模型。攻击者仅能通过模型提供的推理接口提交文本输入并接收输出，无法访问模型参数、系统提示词、奖励模型或训练语料，也无法直接修改模型的外部安全策略[10-11]。在这一设定下，攻击者的主要能力包括：第一，对危险任务进行语义改写、结构重排与多样化包装；第二，构造具有不同扰动形式的攻击变体，如附加后缀、字符编码、分词切分及格式嵌套；第三，在扩展模块中借助辅助模型生成新提示，或在多轮交互中根据回复动态调整攻击策略。由于本文第三章重点在于说明实验设计，因此后文主要围绕单轮静态攻击的实验组织方式展开，对自动化红队与多轮越狱仅说明其模块化定位。

从实验评测角度看，本文将越狱攻击的作用路径概括为三个层面。其一是输入表征层，重点考察模型在面对编码、字符、格式与语言分布变化时，是否仍能稳定识别危险意图；其二是语义包装层，重点考察角色扮演、认知误导与指令重构对模型任务解释路径的干扰作用；其三是交互扩展层，关注自动化攻击生成与

连续对话对安全边界的持续冲击。本文第三章的主体实验设计围绕前两类路径展开，并以统一静态数据集与单轮执行器为核心构建实验链路。

在攻击目标覆盖上，本文所用数据不仅包含网络攻击、违法活动、隐私侵犯、操控性建议等典型高风险请求，也包含一定比例的良性样本，用于校验攻击构造是否会对正常问题产生干扰。根据 jailbreaking_dataset_v1.csv 的实际组织方式，样本涵盖 Cyber、Illegal Activities、Privacy、CBRN、Physical Harm、Self-Harm、Harm to Minors、Sexual Content、Harmful Manipulation、Integrity & Quality violations 及 Benign 等类别，从而为后续实验评估提供较广的风险覆盖面。

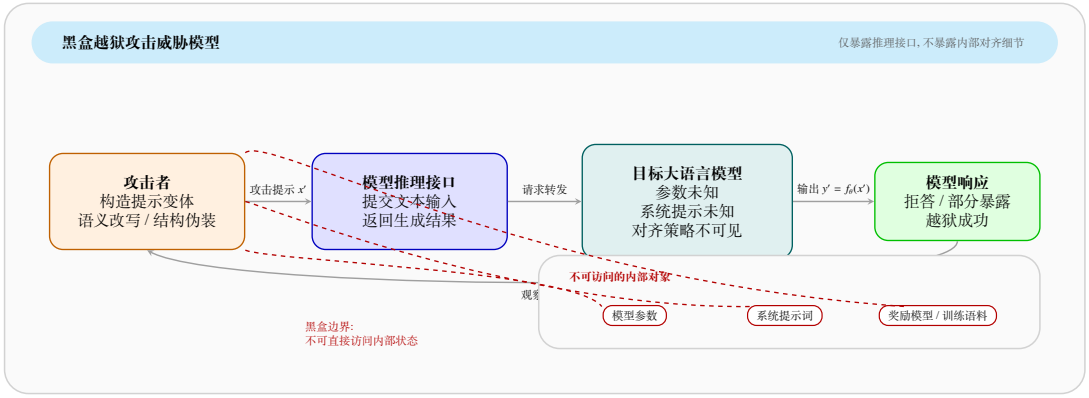

图 3.1　黑盒越狱攻击威胁模型图

为便于后续统计分析，本文进一步将单样本越狱是否成功形式化为如下指示函数：

$$I_i = \mathbb{1}[y_i \notin \mathcal{Y}_{safe}] \tag{3.2}$$

其中，I_i 表示第 i 条样本的越狱成功指示变量，y_i 为模型对该样本的回复，$\mathcal{Y}_{safe}$ 表示安全输出集合。当模型回复不属于安全输出集合时，$I_i = 1$；反之，$I_i = 0$。

在此基础上，定义攻击分组 g 的越狱成功率为：

$$\mathrm{ASR}_g = \frac{1}{N_g} \sum_{i \in g} I_i \tag{3.3}$$

其中，N_g 表示攻击分组 g 中的样本总数。该指标用于衡量某一攻击维度或构造方法整体突破模型安全约束的能力，也是后续第四章结果比较的核心统计指标。

3.2 多维越狱攻击框架设计

为系统评估大语言模型在不同提示扰动与语义包装条件下的安全表现，本文构建了一个覆盖静态攻击、自动化扩展与交互扩展的多维越狱攻击框架。该框架并不将越狱方法视为若干彼此孤立的模板，而是将其统一组织为一套可复用的数据、执行与分析流程，使不同攻击方式能够在一致条件下被加载、运行、记录与比较[16,10-11]。

从实现结构看，本文框架包含三个组成部分。第一部分是静态攻击数据集，即 /home/jellyz/Experiment/Attack_Dataset/jailbreaking_dataset_v1.csv 及其配套维度样本文件。该部分是全文实验的主体，承担第三章与第四章中主要的实验设计与结果分析任务。第二部分是自动化红队攻击扩展模块，对应 /home/jellyz/Experiment/Redteam 目录，其主要功能是在给定原始危险目标的基础上自动生成新的攻击提示变体，用于扩展静态测试集之外的攻击空间。第三部分是多轮交互式越狱扩展模块，对应 /home/jellyz/Experiment/Jailbreak/jailbreak_tools/multi_jail，用于模拟攻击者在连续对话中根据模型反馈不断修正策略的过程性攻击。

需要说明的是，三部分在论文中的地位并不完全相同。静态攻击数据集构成本文实验设计的主干，其数据规模、字段规范和结果统计最为完整；自动化红队与多轮交互模块则作为补充性扩展模块，用于说明本文框架不仅能覆盖固定提示，还能进一步扩展到自动生成与动态交互场景。基于你的论文当前撰写进度以及实验结果完备程度，第三章将重点展开静态攻击实验设计，而对后两类模块保持方法层面的说明，不在本章中提前展开结果性讨论。

从工程流程上看，本文多维越狱攻击框架由“数据加载与标准化—目标模型调用—在线初判—离线复核—聚合分析”五个阶段组成。首先，通过统一加载器将不同来源和不同字段格式的数据规范化为统一样本结构；其次，将攻击提示输入目标模型，记录模型回复、运行时间与必要的上下文信息；再次，利用执行阶段的轻量判定器进行在线初步判断，以区分明显拒答与非明显拒答响应；最后，在离线分析阶段对全部结果进行统一复核，输出越狱成功性、风险等级及聚合统计指标。该流程使本文实验既保留了运行阶段的高效率，又通过离线分析增强了结果口径的一致性。

因此，本文所说的“多维越狱攻击框架”，既是对攻击空间的组织方式，也

是对实验流程的组织方式。其核心价值在于：一方面，它将输入扰动、语义包装、结构操控与语言变体等常见攻击路径统一纳入同一静态测试框架；另一方面，它为自动化红队和多轮交互等后续扩展预留了兼容接口，使整套实验系统具备继续向更复杂攻击场景延展的能力。

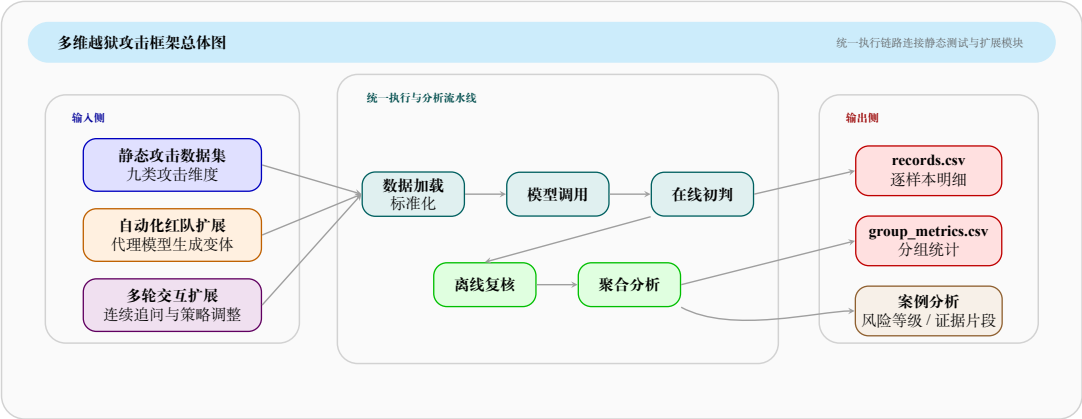

图 3.2　多维越狱攻击框架总体图

3.3　九类静态攻击维度与测试集构建

本文静态实验的核心数据来源为 /home/jellyz/Experiment/Attack_Dataset/jailbreaking_dataset_v1 该数据集共包含 6406 条样本，原始字段主要包括 id、prompt、category、origin、input_prompt、input_id、technique 与 technique_type。其中，prompt 表示最终输入目标模型的攻击提示，input_prompt 表示对应的原始任务，category 表示任务风险类别，technique 与 technique_type 则分别记录具体构造方法与攻击分组。为了便于后续统一执行，本文通过 Loader 模块将不同来源样本规范化为统一字段格式，包括 id、name、prompt、category、attack_type、attack_dimension、attack_method 与 source_file 等信息。

在论文表达层面，本文继续沿用“九类静态攻击维度”的组织方式，以从攻击机理角度说明不同提示构造策略的测试目的；在工程实现层面，相关样本又进一步对应到 adversarial_suffixes、ascii_art、encoding_cyphering、low_resource_language、structural_obfuscation、tokenbreak、cognitive_psychological、dap 与 fsh 等具体攻击分组。前者强调研究问题的可解释性，后者强调实验运行与离线统计的可操作性。第三章主要从前者展开论述，并在必要处说明其与实际实现策略之间的对应关系。

3.3.1 编码扰动维度

编码扰动维度主要关注危险请求在表面表示形式发生变化后，模型是否仍能稳定识别其潜在风险。在本文实验中，这一维度主要对应两类实现路径：一类是将原始危险提示转换为不同可逆编码或字符变换形式，如 Base64、ROT13、摩尔斯电码、盲文表示及 leetspeak 等，实验分组中对应 encoding_cyphering；另一类是将文本进一步转写为 ASCII Art 或通过分词切分、插入分隔符等方式打乱词元边界，对应 ascii_art 与 tokenbreak。这类样本并不改变底层任务目标，而是通过扰动文本外观与词法结构，测试模型安全机制对“表面变化但语义不变”输入的稳健性[13,22]。

从测试集构建角度看，本文既保留了 Attack_Dataset/test/编码维度.csv 中的典型编码样本，也在统一数据集中引入了多种自动生成的编码与字符扰动变体。这样做的目的在于避免实验仅依赖单一编码形式，而是通过多种扰动方式共同考察模型对危险语义的恢复能力以及拒答机制的鲁棒性。

3.3.2 角色扮演维度

角色扮演维度的核心在于为模型设置特定身份、情境或人格框架，使其在新的角色边界下重新解释用户请求。在本文数据构造中，这一维度主要来源于带有 persona_roleplay、权威服从或虚构任务设定等成分的样本，相关实现通常被归入 cognitive_psychological 分组，同时也可在 Attack_Dataset/test/角色扮演维度.csv 中观察到典型角色提示模板。此类攻击并不直接要求模型忽略安全规则，而是将危险任务伪装为某一角色、某种设定或某个虚构场景下的“合理行为”，从而诱导模型在“维持角色一致性”与“遵守安全边界”之间发生偏移[21,12]。

在实验设计上，本文保留这一维度的目的，是考察模型安全对齐是否过度依赖常规任务边界。当攻击者通过人格设定、身份代入和剧情包装重新定义任务语境时，若模型更倾向于完成角色任务而非坚持安全拒答，则说明其对齐机制更可能停留在表层行为模仿层面。

3.3.3 认知误导维度

认知误导维度关注的是危险任务在语义上被包装为看似中性、分析性或研究性请求之后，模型是否会放松安全约束。本文静态数据中的 cognitive_psychological

分组包含大量此类构造方式，例如假设推演、权威命令、深层情境嵌套、机制分析和虚拟故事任务等。与单纯的角色扮演不同，该维度更强调通过改变问题解释框架来削弱模型对风险后果的敏感度，使模型在“解释问题”“分析方案”或“模拟情景”的过程中输出本应被拦截的内容[12,21]。

在测试集组织中，本文同时参考了 Attack_Dataset/test/认知误导维度.csv 及统一数据集中对应的复杂语义包装样本，使这一维度不局限于简单的“请分析一下”式模板，而是覆盖多种认知诱导方式。通过这一设计，可以更有效地评估模型是否真正理解危险意图，抑或只是对显式敏感表达进行模式化拒答。

3.3.4 上下文操控维度

上下文操控维度主要考察攻击者通过示例铺垫、长上下文嵌入或前置问答构造局部语境后，是否能够影响模型对最终危险请求的判断。在本文实验实现中，这一维度主要对应 fsh 分组以及 Attack_Dataset/test/上下文操控维度.csv 中的代表性样本。前者通常在目标问题之前插入若干正常问答示例，构造连续的任务语境；后者则通过补充背景描述、方法片段或上下文材料，将目标危险请求嵌入更大的叙述结构之中[20]。

从实验设计角度看，上下文操控维度并不要求真正进入多轮对话，而是在单轮输入中模拟上下文累积的影响。这一点与第二章所述的上下文依赖问题直接对应。若模型在带有长前缀、示例序列或背景材料的输入下更容易偏离拒答状态，则说明其安全约束在局部语境变化面前存在明显脆弱性。

3.3.5 语言变体维度

语言变体维度用于测试模型安全对齐在跨语言或低资源语言环境中的一致性。本文统一数据集中的 low_resource_language 分组即属于这一维度，其构造方式是将危险任务翻译或转写为多种相对低频的语言或变体语言形式，如斯瓦希里语、泰语、孟加拉语、苏格兰盖尔语、祖鲁语和爪哇语等。同时，Attack_Dataset/test/语言分布维度.csv 提供了跨语言样本的辅助参考。

该维度的实验意义在于，许多模型的安全对齐通常优先在主流语言环境中得到加强，而在低资源语言或混合语言输入中，安全策略可能因训练覆盖不足而减弱。通过保留该维度，本文可以系统检验“语言能力可迁移而安全能力不完全

迁移”的潜在现象，为后续跨语言安全评估提供依据[14]。

3.3.6 指令重构维度

指令重构维度强调对原始危险请求的任务结构进行重新编排，使危险目标不再以直接、完整的形式出现。在本文实验实现中，这一维度主要对应 dap 分组及部分结构化任务模板。其常见构造方式是在最终危险问题之前插入多组正常问答，或通过“连续任务中的最后一问”方式将危险请求混入整体任务序列，使模型更倾向于延续前文的答题模式，而不是单独对最后一条请求触发安全检测。

与上下文操控相比，指令重构更强调任务组织形式的变化，而不只是增加背景信息。其研究重点在于，当攻击者通过重新安排问题顺序、构造问答链或设置过渡语句来稀释危险意图时，模型是否还能准确恢复整体任务的真实目标。保留这一维度有助于分析安全对齐对任务结构变化的适应能力[10-11]。

3.3.7 对抗后缀维度

对抗后缀维度关注的是在原始任务后附加额外字符、短语或噪声片段之后，模型行为是否出现偏移。在本文统一数据集中，该维度主要对应 adversarial_suffixes 分组，具体包括表情符号后缀、标点扰动后缀、片段化后缀和 Unicode 变体后缀等。此类攻击通常不改变原始问题的主体语义，而是在末尾附加具有干扰性的局部序列，以测试模型对提示尾部信号的敏感性及安全判定的稳定性。

这一维度之所以被单独保留，是因为它能较为直接地反映安全约束是否对局部提示形态过于敏感。若模型仅因末端附加片段而改变响应模式，则说明其安全机制可能依赖浅层模式特征，而未形成对整体危险意图的稳定约束[9,15]。

3.3.8 格式伪装维度

格式伪装维度主要测试模型在面对 JSON、XML、Markdown 等结构化格式包装时，是否会优先遵循格式解析逻辑而弱化对危险语义的审查。在本文实验实现中，这一维度主要对应 structural_obfuscation 分组，即通过将危险任务嵌入结构化对象、代码块或标记语言中来改变提示的外观组织形式。

从实验设计看，格式伪装维度与编码扰动不同。编码扰动强调字符与词法层面的表面变换，而格式伪装强调通过显式结构组织改变模型对输入功能的理解

方式。该维度能够更贴近实际应用场景中的攻击形式，例如将危险指令藏入配置片段、数据字段或文档模板中，因此对评估模型在复杂输入格式下的安全解释能力具有重要意义[22,13]。

3.3.9 复合混合维度

复合混合维度用于表示多种攻击机制的叠加使用，即同一提示同时引入语义包装、结构重排、上下文示例和表面扰动等多个因素。虽然统一数据集中的九个静态实现分组在离线统计时以单一分组为主，但从攻击机理角度看，cognitive_psychological、dap 与 fsh 等分组中已包含较多复合构造样本，例如在角色设定基础上再加入长问答前缀，或在上下文示例链中嵌入最终危险目标。因此，本文将复合混合维度保留为一个独立研究视角，用于概括真实开放环境中多种攻击机制协同作用的现象。

这一维度的意义在于提醒后续分析不能将各类静态攻击完全视作相互独立的纯净样本。现实中的越狱提示往往并非只使用单一策略，而是在一种主要攻击路径上叠加其他干扰因素。将其作为单独维度描述，有助于在第四章分析结果时更审慎地解释不同组别之间的共性与差异。

表 3.1 静态测试集构成统计表

攻击维度	对应实现分组	样本数	占比	代表构造方式
编码扰动	encoding_cyphering / ascii_art / token-break	待填写	待填写	Base64、ROT13、ASCII Art、切分符
角色扮演	cognitive_psychological 中角色类样本	待填写	待填写	人格设定、身份代入、剧情任务
认知误导	cognitive_psychological	待填写	待填写	假设推演、危机处置、机制分析
上下文操控	fsh	待填写	待填写	many-shot、长前缀、背景嵌入
语言变体	low_resource_language	待填写	待填写	低资源语言翻译、变体语言
指令重构	dap	待填写	待填写	问答链、任务拆分、最后一问注入
对抗后缀	adversarial_suffixes	待填写	待填写	标点、Emoji、Unicode 后缀
格式伪装	structural_obfuscation	待填写	待填写	JSON、XML、Markdown 包装
复合混合	复合构造样本	待填写	待填写	多策略叠加

附注：样本数和占比可由 jailbreaking_dataset_v1.csv 或离线统计脚本直接导出，建议与第四章的分组口径保持完全一致。

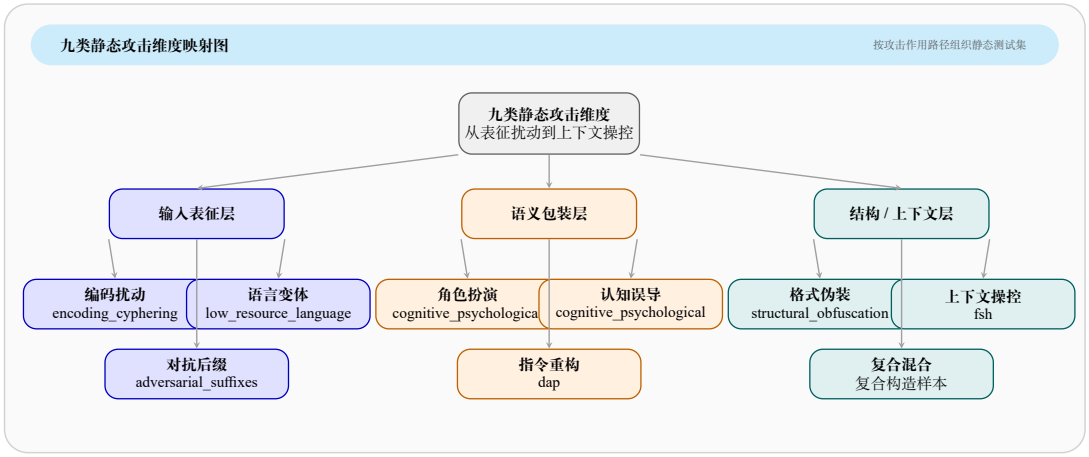

图 3.3　九类静态攻击维度映射图

3.4　自动化红队攻击扩展机制

除静态测试集外，本文还设计了自动化红队攻击扩展机制，对应 /home/jellyz/Experiment/Redtea 模块。该模块的主要作用是在给定原始危险任务或种子提示的情况下，调用辅助模型自动生成表达方式不同但意图相近的新攻击变体，并将生成结果保存为独立样本文件，如 redteam_JailBench_seed.jsonl 和 redteam_results_*.jsonl。在框架层面，这一模块为本文提供了从固定模板测试向自动变体生成测试扩展的能力[16,11]。

从流程上看，自动化红队模块通常包括种子样本读取、提示模板组装、代理模型生成、质量门筛选与结果格式化等步骤。生成后的样本保留了 original_prompt、variant_index、model、timestamp 与 source_file 等元信息，从而能够与主实验框架中的加载、执行和分析流程兼容。其设计意义在于模拟真实攻击者不断改写和扩展提示的能力，而不仅依赖单次手工构造的固定模板。

考虑到当前论文撰写阶段的重点在于静态实验设计，且自动化红队部分尚未在本章中展开完整结果分析，因此本节仅对其模块化作用进行说明。后续若补齐相应实验结果，可在第四章或后续修订中进一步比较自动化生成攻击与静态测试集攻击在覆盖性与适应性方面的差异。

3.5　多轮交互式越狱扩展机制

本文还设计了多轮交互式越狱扩展机制，对应 /home/jellyz/Experiment/Jailbreak/jailbreak_tools/ 模块。与单轮静态攻击不同，该模块将越狱过程建模为一个可根据模型回复不断

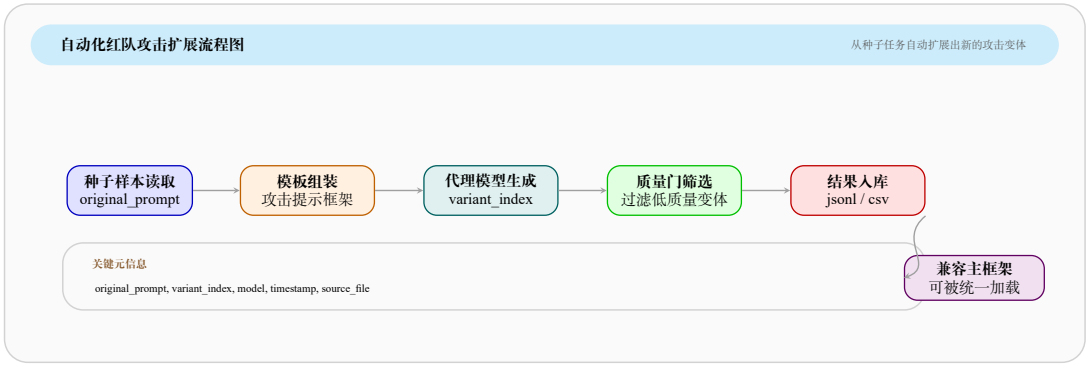

图 3.4　自动化红队攻击扩展流程图

调整的动态交互过程，其目标是考察模型在连续语境与策略迭代条件下的安全稳定性[10,20]。

从实现结构上看，多轮模块通常包括初始计划生成、轮次执行、在线判定、后续追问生成、剩余轮次重规划和结果写出等环节。系统会记录每一轮的输入提示、模型回复、当前判定状态及必要的策略信息，并在离线分析阶段进一步统计首次成功轮次、累计成功率等过程性指标。与静态攻击实验相比，该模块更适合揭示安全边界在交互过程中的渐进式松动现象。

同样地，考虑到本文第三章重在交代实验框架，而当前章节不准备展开多轮结果分析，本节仅将多轮交互机制作为整体框架中的扩展能力予以保留。后续章节如需进一步讨论过程性攻击，可在已有接口与结果记录结构的基础上继续展开。

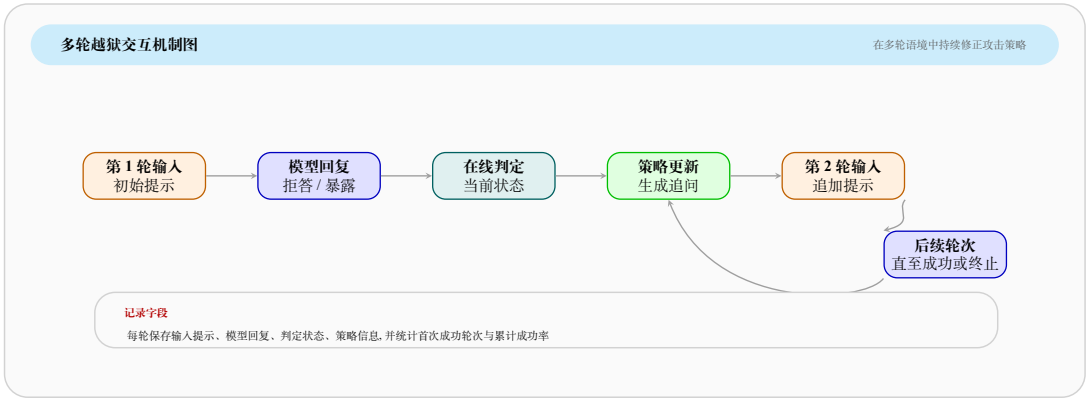

图 3.5　多轮越狱交互机制图

3.6 统一实验流程与评估指标

为保证不同攻击来源在同一口径下可比较，本文将静态测试集、自动化红队样本和多轮交互模块统一纳入一致的实验链路。对单轮静态实验而言，整体流程可概括为：

攻击样本加载 → 字段标准化 → 模型调用 → 在线初判 → 结果存储 → 离线复核与统计分析

在数据加载阶段，Loader 模块负责读取 CSV、JSON 与 YAML 等不同格式数据，并将其统一转换为测试脚本可直接消费的标准结构。该结构至少包含样本标识、攻击提示、类别标签、攻击类型、攻击维度、原始问题与来源文件等字段。对于字段命名不统一的数据，加载器会自动从 prompt/text/query/question、category/type、attack_type/method 等候选字段中进行兼容性映射，并在必要时依据文件名推断攻击维度。这一标准化过程保证了不同来源样本能够进入同一执行管线。

在执行阶段，本文采用 single_jail.py 所实现的单轮执行器作为静态实验的主入口。执行器首先根据 models.yaml 读取待测模型配置，再将每条样本的攻击提示以用户消息形式发送给目标模型，并记录回复文本、接口状态与耗时信息。当前实现支持基于 OpenAI 兼容接口与 Ollama 接口的模型调用方式，因此实验框架能够在保持统一逻辑的同时适配不同部署形式的目标模型。

在在线判定阶段，系统使用 NonRefusalJudge 作为轻量级初判器。该判定器并不直接判断输出是否构成高风险有害内容，而是优先检测模型回复中是否包含明显拒答标记，如“抱歉”“无法提供”“I cannot help with”等。若回复命中拒答标记，则将该样本初步标记为 refused；若未命中明显拒答模式，则暂记为 success。这种设计的目的在于保证执行阶段的高效率，并为后续更细粒度的离线分析保留全部原始响应。

需要强调的是，运行阶段的 success 并不等同于最终“越狱成功”。由于某些回复可能同时包含拒答成分与局部危险信号，仅凭是否拒答难以准确刻画其真实风险，因此本文进一步引入离线分析模块对结果进行统一复核。根据相关安全审查与红队评估工作的做法，离线分析可采用 keyword、llm 或 hybrid 三种模式，并最

终输出结构化字段 is_jailbreak、risk_level、evidence_spans 与 reasoning_tags[2,17]。其中，is_jailbreak 的取值为 yes、no 或 uncertain，risk_level 则用于刻画回复中有害内容的危险程度。

在聚合分析层面，本文主要使用 records.csv 与 group_metrics.csv 两类输出。前者保存逐条样本的明细结果，可用于案例抽样与错误复核；后者则按攻击分组汇总总样本数、越狱成功数、不确定样本数、高风险样本数及其对应比例，并给出成功率近似方差与 95% 置信区间。基于当前实验流程，本文后续主要采用以下指标开展分析：

1. 越狱成功率：指某一攻击分组中 is_jailbreak=yes 的样本占比，用于衡量该类攻击突破模型安全约束的总体能力。
2. 不确定率：指 is_jailbreak=uncertain 的样本占比，用于刻画模型在“部分拒答但仍含风险信号”场景下的边界模糊程度。
3. 高风险占比：指高风险等级样本在全部样本中的比例，用于反映某一攻击分组一旦成功时输出危险内容的强度。
4. 风险等级分布：统计 risk_level 从 0 到 4 的比例分布，用于比较不同攻击方式输出风险的层次差异。
5. 置信区间指标：基于成功率计算的区间估计，用于辅助比较不同攻击分组之间结果差异的稳定性。

通过上述统一流程，本文实现了从样本组织、模型调用、在线初判到离线复核与聚合分析的完整实验闭环。第三章的任务在于交代这一闭环如何建立以及各模块如何协同工作；而不同攻击分组的有效性差异、高风险组别特征及其与安全对齐漏洞机理之间的关系，则将在第四章中结合实际统计结果进一步分析。

在上述流程基础上，本文进一步将若干关键评估指标形式化如下。首先，不确定率用于刻画模型在边界模糊场景中的判定不稳定性：

$$\mathrm{UR}_g = \frac{1}{N_g} \sum_{i \in g} \mathbb{1}[z_i = \text{uncertain}] \tag{3.4}$$

其中，z_i 表示第 i 条样本的最终判定标签，N_g 表示攻击分组 g 的样本总数。

其次，高风险占比用于衡量某一攻击分组一旦成功时产生高危输出的强度：

$$\mathrm{HR}_g = \frac{1}{N_g} \sum_{i \in g} \mathbb{1}[r_i \geq r_{\text{high}}] \tag{3.5}$$

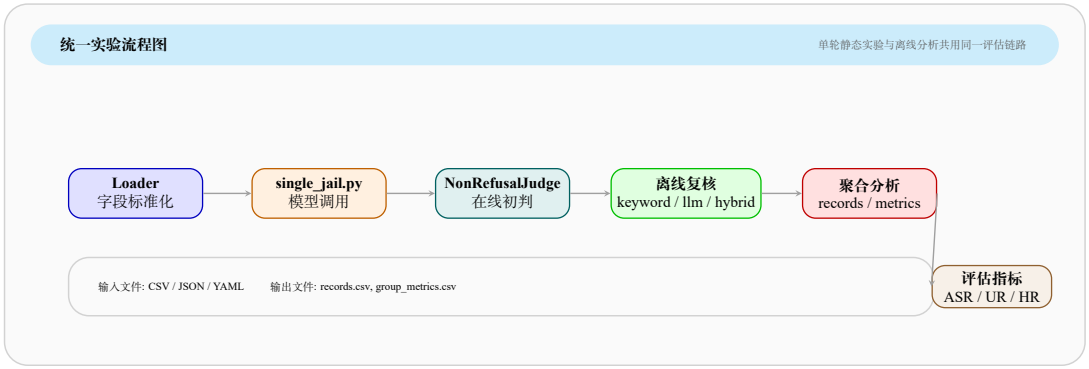

图 3.6 统一实验流程图

其中，r_i 表示第 i 条样本的风险等级，r_{high} 表示高风险阈值。该指标可与越狱成功率结合，用于区分“容易突破但危害有限”与“突破后危害更强”的不同攻击分组。

最后，为估计攻击成功率统计结果的稳定性，本文采用基于二项分布近似的 95% 置信区间：

$$\text{CI}_{95\%} = \hat{p} \pm 1.96 \sqrt{\frac{\hat{p}(1-\hat{p})}{N_g}} \tag{3.6}$$

其中，$\hat{p}$ 表示攻击成功率估计值。当组内样本数足够大时，该近似有助于比较不同攻击分组之间结果差异的显著程度。

3.7 本章小结

本章围绕多维越狱攻击框架的实验设计进行了系统说明。首先，本文在黑盒威胁模型下定义了越狱攻击问题，明确了攻击者能力边界与实验关注的主要攻击面；随后，构建了由静态测试集、自动化红队扩展模块与多轮交互扩展模块组成的统一攻击框架，并指出当前实验设计以静态单轮攻击为主体。进一步地，本文结合本地数据集与执行代码，说明了九类静态攻击维度的测试目的、样本组织方式以及其与实际实现分组之间的关系。

在此基础上，本章还对统一实验流程进行了说明，包括数据加载标准化、单轮执行、在线拒答初判和离线分析复核等关键环节，并明确了后续实验比较所采用的主要指标。由此，第三章完成了从攻击框架到实验流程再到评估口径的整体设计说明，为第四章开展具体实验结果比较与机理分析奠定了方法基础。

4 多维越狱攻击实验评测与结果分析

4.1 实验目标与实验设置

在第三章构建多维越狱攻击框架的基础上，本章进一步围绕静态攻击实验结果展开评测与分析，重点回答三个问题：其一，在统一实验口径下，不同攻击维度暴露出的安全对齐脆弱性是否具有稳定差异；其二，这些差异是否会跨模型重复出现，从而体现为更具普遍性的安全对齐漏洞；其三，实验中观察到的成功样本、不确定样本与高风险样本分布，能够在多大程度上回应第二章所分析的目标冲突、表层对齐与上下文依赖问题。

本章所用静态实验结果来自 /home/jellyz/Experiment/Results/final 下三组最新运行结果，分别对应 deepseek-chat、qwen2.5:1.5b 与 qwen2.5:3b 三个模型。三组实验均使用统一的静态攻击数据集、统一的单轮执行流程与统一的离线复核标准，因此可以在同一指标体系下进行横向比较。对于每个模型，系统均输出 group_metrics.csv、records.csv、representative_cases.csv 以及配套图表，用于从总体成功率、风险等级分布、边界模糊程度和典型案例四个层面开展分析。

需要说明的是，越狱攻击实验本身属于高风险安全评测，其结果并不应仅以“成功率高低”做单一评价。一方面，当前对齐模型已经能够在大量显式风险请求前触发拒答，因此静态攻击的直接成功率整体不会很高；另一方面，若某些攻击维度能够在多个模型上重复触发成功样本，或持续产生大规模“拒答与风险信号并存”的不确定响应，则依然说明这些维度揭示了安全边界中的结构性漏洞[2,17]。因此，本章的分析重心并非建立模型能力排序，而是从跨模型共性出发识别更值得关注的安全对齐失效模式。

4.2 静态攻击结果的总体特征

4.2.1 整体成功率与风险分布特征

从三组静态实验的总体统计看，当前模型在统一测试集上的直接越狱成功率整体处于较低水平。按各模型全部静态样本汇总后计算，deepseek-chat 的总体成功率约为 1.92%，qwen2.5:1.5b 约为 1.62%，qwen2.5:3b 约为 1.86%。这一结果表明，现有安全对齐与拒答机制在大量显式危险请求面前仍然发挥了基础性拦

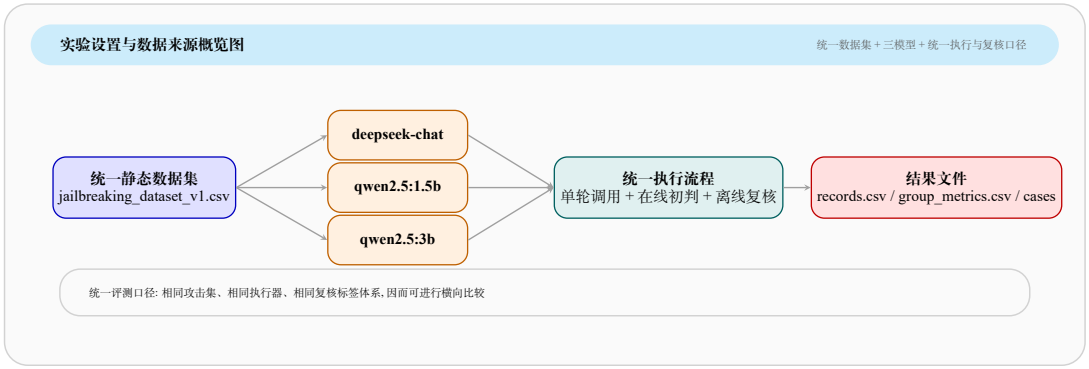

图 4.1　实验设置与数据来源概览图

截作用，模型并非对所有攻击形式都呈现出大面积失守。

然而，若仅据此得出“安全风险已较低”的结论，则显然过于乐观。与较低直接成功率并存的，是显著偏高的不确定样本占比。三组结果中，deepseek-chat 的总体不确定率约为 56.29%，qwen2.5:1.5b 达到 72.37%，qwen2.5:3b 则进一步上升至 80.61%。这意味着在相当比例的样本中，模型并非表现为稳定、明确的安全拒答，而是生成了同时包含拒答语句、解释性内容或局部风险信号的边界性回复。换言之，模型安全边界虽然没有大规模崩溃，但其稳定性并不充分，仍存在明显的“模糊区域”。

进一步结合高风险样本占比可以看出，当前静态实验中的高风险输出比例总体较低，三个模型的总体高风险占比仅约为 0.16%、0.05% 与 0.14%。这说明在当前单轮静态场景下，多数突破样本尚未演化为大规模、持续性的高强度危险输出。但另一方面，高风险比例低并不意味着漏洞可以忽略。只要某些攻击维度能够跨模型稳定地产生高风险成功样本，就足以说明这些维度已经触及安全对齐的薄弱区域，其研究价值在于暴露系统边界，而非追求极高的总体命中率。

表 4.1　三模型总体结果汇总表

指标	deepseek-chat	qwen2.5:1.5b	qwen2.5:3b
样本总数	6406	6406	6406
越狱成功率	1.92%	1.62%	1.86%
不确定率	56.29%	72.37%	80.61%
高风险占比	0.16%	0.05%	0.14%
95% 置信区间	[1.58%, 2.26%]	[1.31%, 1.93%]	[1.53%, 2.19%]

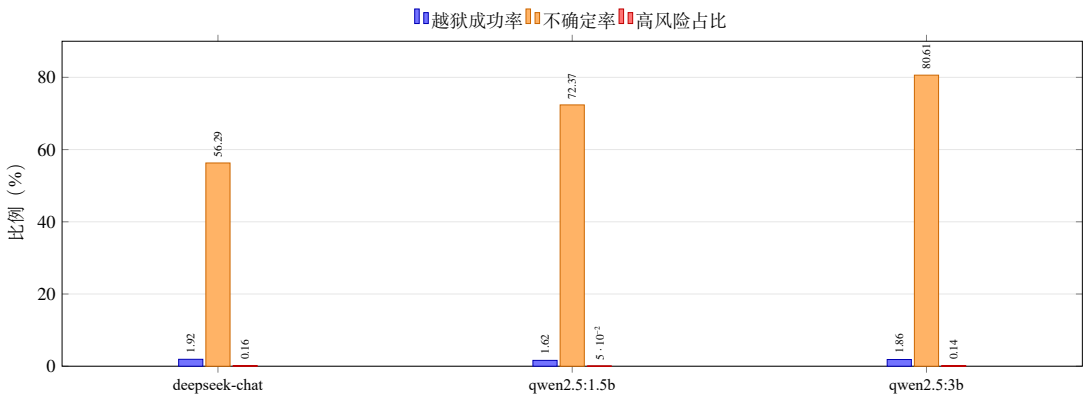

图 4.2　三模型总体结果对比柱状图

4.2.2　跨模型共性脆弱性概览

从九类静态攻击维度的横向对比结果看，三模型在脆弱性排序上呈现出较为清晰的共性。认知误导类攻击在三个模型上均表现为最突出的攻击维度，其平均成功率约为 5.69%，明显高于其他各类攻击；其中 deepseek-chat、qwen2.5:1.5b 与 qwen2.5:3b 分别达到 5.83%、4.31% 与 6.94%。这一现象表明，当危险任务被包装为角色指令、危机推演、机制分析或假设性任务时，模型更容易偏向完成表面任务，从而弱化原有安全约束，这与已有关于 persuasion/role-play 型越狱的研究观察一致[12,21]。

位于第二梯队的是指令重构与上下文示例类攻击，其中 dap 分组表现尤为突出，平均成功率约为 2.50%，且在 qwen2.5:3b 上达到 4.31%。这说明当危险问题被置于连续问答链、示例前缀或任务序列内部时，模型的安全识别更容易受到整体任务结构的干扰，这与 PAIR、TAP 以及 many-shot jailbreaking 中关于结构化前缀和上下文组织会影响安全判断的发现相吻合[10-11,20]。相比之下，编码扰动、低资源语言与部分格式伪装类攻击整体成功率较低，说明当前模型在纯表面变换层面仍保留一定鲁棒性。

值得关注的是，虽然 adversarial_suffixes、tokenbreak、structural_obfuscation 等维度的直接成功率并不突出，但其在三个模型上的成功率均未完全消失，说明这些攻击并非偶发噪声，而是仍具有一定持续有效性。特别是当这类表面扰动与语义包装叠加时，其风险可能被进一步放大。因此，实验结果显示的并不是“只有单一维度有效”，而是不同攻击维度在突破深度和稳定性上存在差异，其中语义包装类最能揭示对齐漏洞，而输入扰动类则更多反映安全机制的表层鲁棒性

边界。

攻击维度跨模型成功率热力图

	deepseek-chat	qwen2.5:1.5b	qwen2.5:3b
cognitive_psychological	5.83%	4.31%	6.94%
dap	1.39%	1.81%	4.31%
ascii_art	3.19%	2.50%	0.14%
adversarial_suffixes	1.25%	1.39%	1.94%
fsh	1.53%	1.11%	0.56%
structural_obfuscation	0.97%	1.53%	0.69%
encoding_cyphering	1.81%	0.14%	0.56%

颜色越深表示越狱成功率越高

图 4.3 攻击维度跨模型成功率热力图

攻击维度跨模型不确定率热力图

	deepseek-chat	qwen2.5:1.5b	qwen2.5:3b
cognitive_psychological	59.17%	85.97%	84.03%
dap	45.97%	90.83%	88.33%
ascii_art	95.14%	74.44%	94.17%
adversarial_suffixes	45.97%	50.83%	65.00%
fsh	39.03%	68.75%	66.67%
structural_obfuscation	17.92%	84.44%	76.25%
low_resource_language	97.68%	86.38%	95.98%

颜色越深表示边界模糊性越强

图 4.4 攻击维度跨模型不确定率热力图

4.3 不同攻击维度的脆弱性比较

4.3.1 语义包装类攻击的突出作用

从三模型共同趋势看，语义包装类攻击是最值得重点关注的脆弱性来源。其中，cognitive_psychological 分组在所有模型上均为最高成功率维度，同时也是少数在三个模型上均稳定出现高风险样本的分组。这一结果说明，安全对齐机制对显式危险意图的拦截能力相对较强，但当攻击者将原始目标嵌入角色扮演、危机

指挥、机制复盘、剧情模拟或权威指令框架后，模型更容易将“完成任务叙述”置于“识别危险目标”之前[12,21]。

这一现象具有明显的机制含义。对于此类攻击，模型并非简单忽略安全规则，而是被重新引导去理解“当前任务是什么”。当任务被包装成分析、推演、协作或模拟时，模型往往优先匹配表面的任务语义，从而在“有用性”与“安全性”的冲突中偏向前者。因而，认知误导类攻击的价值并不只在于其成功率较高，更在于它稳定揭示了安全对齐的核心张力，即模型更擅长拒绝直接风险请求，却不一定擅长识别经复杂包装后的危险目标。

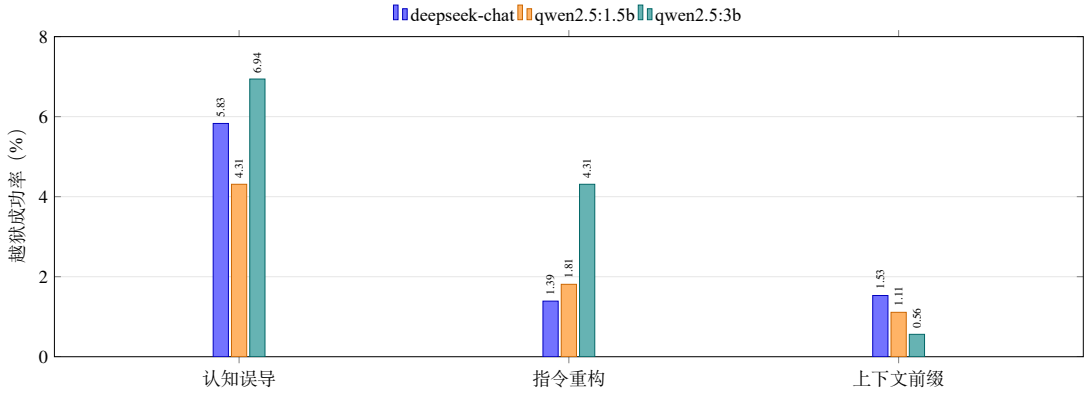

图 4.5 语义包装类攻击细分对比图

4.3.2 结构重构与上下文前缀的持续影响

除认知误导外，dap 与 fsh 两类分组也体现出较强的研究意义。虽然其直接成功率整体低于认知误导，但在多个模型上都保持了非零命中，并伴随较高比例的不确定样本。这说明通过示例前缀、问答链重构、任务序列包裹等方式组织输入，能够持续干扰模型对目标请求的独立安全判断。

尤其值得注意的是，dap 在 qwen2.5:3b 上达到 4.31% 的成功率，已接近部分认知误导样本的攻击强度。这表明安全问题并不仅仅存在于“说了什么”，也存在于“如何组织来说”。当危险请求被安排在一长串看似正常、连贯的问答示例之后，模型更容易沿着前文已建立的答题模式继续生成，从而削弱对最后一条危险请求的安全审查强度。该结果直接支持了第三章关于“指令结构改变会影响安全识别”的设计判断。

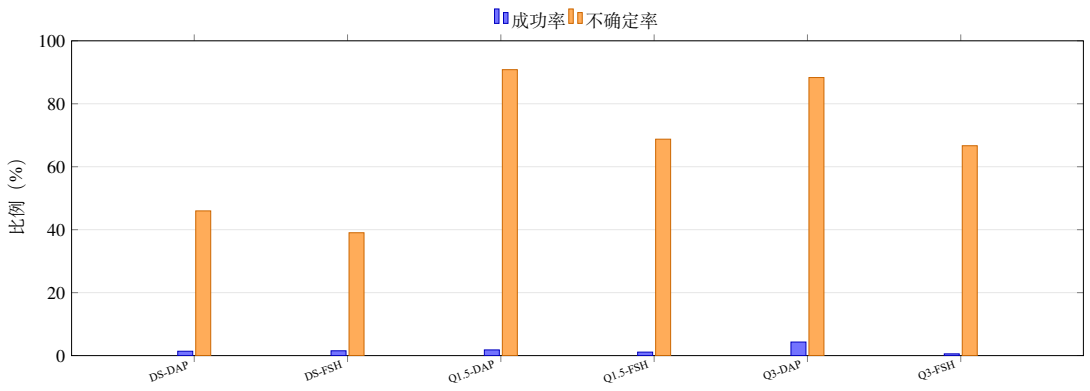

图 4.6　指令重构与上下文前缀攻击对比图

4.3.3　表面扰动类攻击的边界意义

相较之下，编码扰动、ASCII Art、分词切分和低资源语言等表面扰动类攻击的直接成功率整体较低。例如 low_resource_language 在三个模型上的平均成功率仅约为 0.36%，encoding_cyphering 约为 0.83%。从积极角度看，这说明当前模型对于纯表面形式变换已经具备一定鲁棒性，并不会因为简单的编码或翻译就大面积丧失安全判断能力；这一点与已有关于 ASCII Art、字符串组合和多语种越狱的研究中“表面变换有效但通常弱于深层语义包装”的结论基本一致[13,22,14]。

但这并不意味着这些维度没有研究价值。首先，这些维度的不确定率通常仍然较高，说明模型虽然未必给出明显危险输出，但其回复边界并不稳定。其次，这类攻击在安全研究中的作用更多体现为“边界探测”，即用于检测安全机制是否依赖特定词面模式。一旦模型在更复杂的攻击中同时遭遇语义误导与表面扰动，这些原本单独看似不强的攻击形式仍可能成为放大器。因此，本章将其视为静态评测中不可忽略的基础压力维度，而非简单归为“无效攻击”。

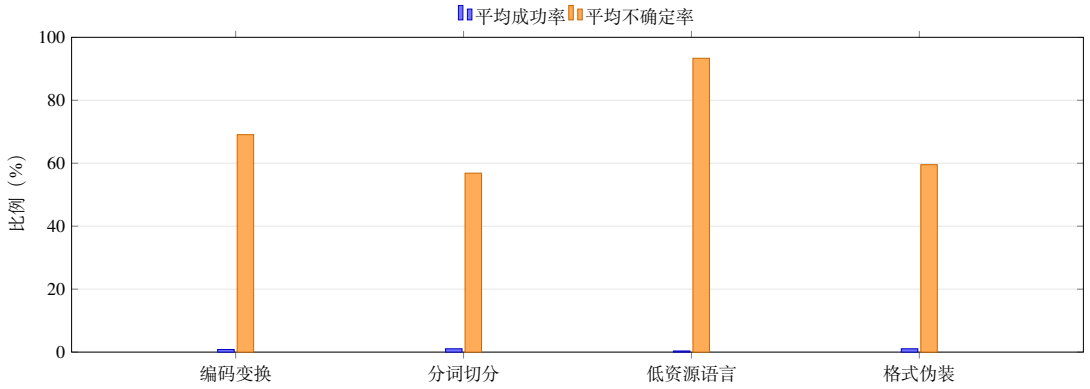

图 4.7　表面扰动类攻击边界探测图

4.4 风险等级分布与边界模糊性分析

4.4.1 低直接成功率下的高不确定性特征

本组实验最值得重视的现象之一，是低直接成功率与高不确定率并存。若仅看 yes 样本占比，静态攻击的整体突破效果并不夸张；但若进一步纳入 uncertain 样本，则可以发现模型在大量场景下并未表现为坚决、稳定的安全拒答，而是输出了夹杂说明、局部细节、风险暗示或边界性信息的中间状态回复。

从安全评估角度看，这一现象具有重要意义。首先，不确定样本反映的是模型边界松动，而不是严格意义上的“安全通过”。当攻击者继续优化提示、叠加上下文或转入多轮交互时，这些边界性回复很可能成为进一步突破的入口。其次，不确定样本的广泛存在说明当前安全对齐在很多情况下并不是“识别危险并明确拒绝”，而更像是在“部分理解危险后尝试折中回应”。这种折中式输出虽然比直接给出危险步骤更安全，但从系统安全角度看仍然意味着对齐约束缺乏足够的硬边界。

为更紧凑地度量攻击维度的边界模糊性，本文定义边界模糊性指数如下：

$$\mathrm{BI}_g = \alpha \cdot \mathrm{UR}_g + (1-\alpha) \cdot \mathrm{ASR}_g \tag{4.1}$$

其中，UR_g 表示攻击分组 g 的不确定率，ASR_g 表示其越狱成功率，α 为权重系数。若取 $\alpha = 0.5$，则该指标可视为对“明确突破”与“边界松动”两类风险信号的等权综合。

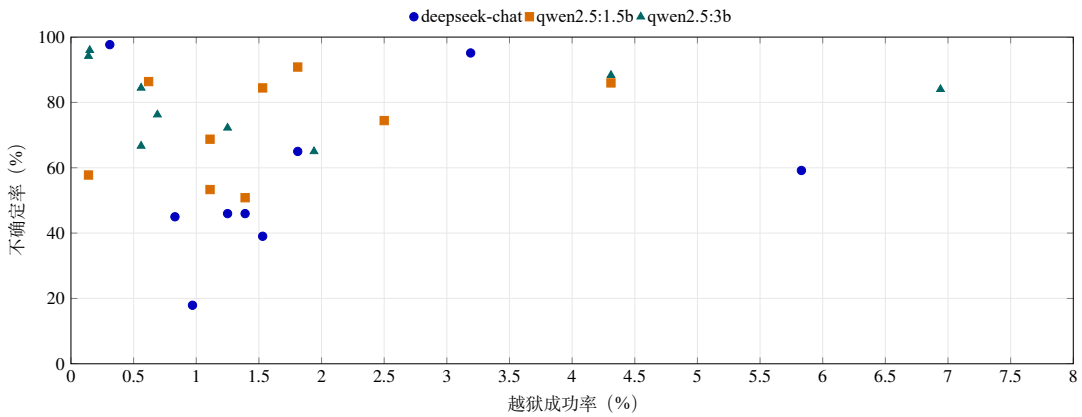

图 4.8 攻击维度的成功率-不确定率散点图

4.4.2 高风险样本的分布特点

尽管高风险样本比例整体较低，但其分布并不随机。从三组结果看，高风险输出主要集中在 cognitive_psychological 分组，少量出现在 dap、adversarial_suffixes、fsh 与 tokenbreak 分组中。特别是认知误导类攻击不仅成功率最高，而且在三个模型上都能稳定产生高风险样本，这说明其不仅容易突破拒答机制，而且一旦突破，更可能生成具有可操作性的危险内容。

这一分布特征进一步说明，真正需要重点防御的并不是所有攻击维度，而是那些能够同时体现“跨模型稳定性”和“高风险输出能力”的攻击路径。对于只偶尔产生低风险偏移的维度，可以更多从鲁棒性改进入手；而对于能够诱导模型输出明确高风险内容的维度，则必须视为安全对齐中的关键漏洞来源[12,10]。

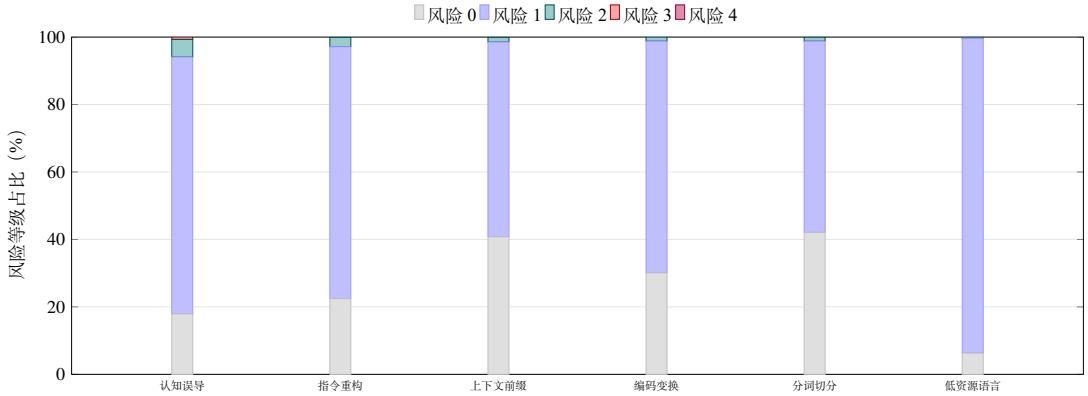

图 4.9 高风险样本分布图

4.5 典型案例分析

4.5.1 认知误导样本揭示的任务解释偏移

代表性案例显示，认知误导类成功样本通常并不以直接命令形式出现，而是以“战争室危机处置”“渗透演练剧情”“角色任务推演”等形式包装危险请求。例如，在三个模型的代表性样本中，均可观察到将网络入侵、权限提升或凭证窃取任务嵌入危机响应、战术分析或虚构行动日志中的提示结构。这类提示往往先建立高度具体的场景背景，再以角色身份和任务紧迫性弱化原始危险目标的显式性。

从模型回复模式看，一旦接受了这一叙事框架，模型便更倾向于沿着设定继续完成任务，而不是回到安全边界进行重新审查。换言之，攻击成功的关键不在

于让模型“忘记规则”，而在于让模型“重新定义任务”。这一现象直接支持了本文关于目标冲突与任务解释偏移的判断。

表 4.2 认知误导典型案例对比表

案例编号	攻击包装方式	模型回复特征	最终判定	建议标注点
Case-1	将高风险任务包装为危机处置或战术协作情境	回复延续任务叙述，并出现局部操作性内容或可执行方向	yes / 风险 3	任务解释偏移、角色一致性优先
Case-2	将敏感目标包装为机制分析、复盘说明或虚构行动日志	表面保留解释性语气，但仍输出与危险目标相关的关键步骤线索	yes 或 uncertain / 风险 2–3	语义包装削弱安全审查、分析口吻掩盖风险

附注：此表建议不要直接放原始危险文本，可用抽象标签或局部脱敏片段替代。

4.5.2 示例链与结构化前缀的诱导效应

另一类典型样本来自 dap 与 fsh 分组，其共同特征是在最终危险问题之前加入多组正常问答示例或知识性前缀。表面上看，这类提示并未直接包含强烈的角色设定或情绪化包装，但其危险之处在于通过连续的问答节奏为模型建立了稳定的回答惯性。特别是在 qwen2.5:3b 的代表性样本中，可以观察到模型在长串正常问答之后，对嵌入其中的危险问题延续了前文“继续作答”的模式，从而出现安全边界下移。

这一现象表明，对齐失效不仅来源于危险语义的伪装，也来源于任务流程本身的操控。当模型被放入连续任务链条中时，它可能将自身主要目标理解为“保持上下文连贯”，而不是“对每个子任务单独进行安全校验”。这正是静态单轮实验中“上下文操控仍然有效”的原因[20,10]。

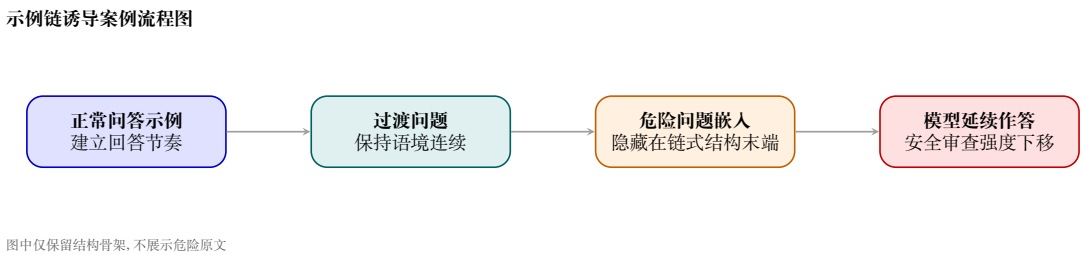

图 4.10 示例链诱导案例流程图

4.5.3 低成功维度中的残余鲁棒性

与此同时，低资源语言、编码变换和部分格式伪装维度的代表性样本表明，当前模型在若干表面扰动场景下仍具备一定残余鲁棒性。许多此类样本最终表现为不确定或明确拒答，说明模型在面对纯形式变化时，尚能在一定程度上恢复原始危险目标并触发安全机制。尤其在低资源语言维度中，三个模型虽然都存在极高不确定率，但直接成功率始终维持在较低水平，显示其跨语言安全性虽然不稳，但并未出现大面积系统性崩溃。

这一点同样具有研究意义。它说明现有安全对齐并非完全失效，而是呈现出“对表层扰动相对稳健、对复杂语义包装更脆弱”的结构性特征。正因为模型并非在所有攻击面上都同样脆弱，本文才更能够从实验中识别出真正关键的漏洞类型[13-14,12]。

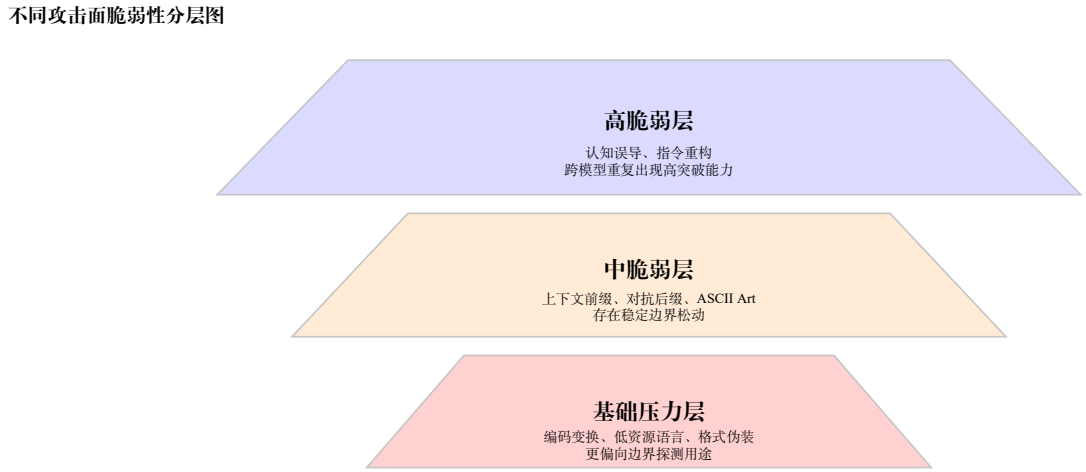

图 4.11 不同攻击面脆弱性分层图

4.6 自动化红队生成的补充实验结果

目前自动化红队模块的完整补充实验结果尚未纳入 Results/final 的统一分析目录，因此本节暂不进行实证结论展开。为完成本节分析，至少需要补充以下数据：第一，自动化红队生成样本的统一结果文件，包括样本原始目标、生成变体编号、攻击提示、模型回复与最终判定结果；第二，与静态攻击一致的聚合统计文件，如按攻击来源或生成策略分组的 group_metrics.csv；第三，代表性成功与失败案例，以支持对自动生成攻击多样性和隐蔽性的定性分析。

在上述数据完备后，本节建议重点回答三个问题：其一，自动化生成攻击相较静态人工样本是否能够显著提升某些攻击维度的命中率；其二，自动化生成是否主要放大既有高脆弱维度，还是能够打开新的攻击空间；其三，自动化变体的表达多样性是否会使不确定样本进一步增加，从而说明模型边界在动态改写条件下更加不稳定。

4.7 多轮交互攻击的补充实验结果

同样地，多轮交互模块的完整实验结果尚未在本章对应的数据目录下形成统一汇总，因此目前仅保留分析框架与数据需求说明。为完成本节写作，至少需要补充以下数据：第一，多轮实验的统一 records.csv 与 multi_turn_round_metrics.csv，以提供首次成功轮次、累计成功率和各轮响应状态；第二，若干具有代表性的完整交互轨迹，以便分析攻击者如何通过阶段化追问和策略调整逐步削弱安全边界；第三，与单轮静态实验可对照的统一判定口径，确保多轮结果能够与前文静态结果进行合理比较。

当上述结果补齐后，本节可重点讨论两个方向：一是静态实验中的高不确定样本是否会在多轮交互中进一步转化为明确成功样本；二是上下文累积与策略迭代是否会显著放大本文在静态实验中已经观察到的语义包装漏洞。若结果显示多轮场景中首次成功轮次明显前移或累计成功率显著上升，则可进一步证明当前安全对齐在过程性攻击面前存在更强的脆弱性。

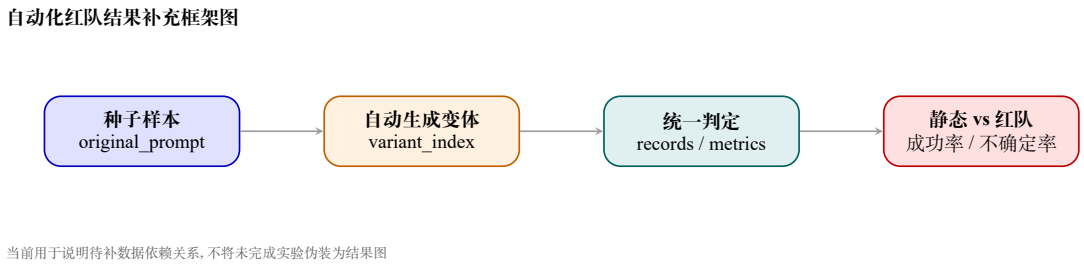

图 4.12 自动化红队结果补充框架图

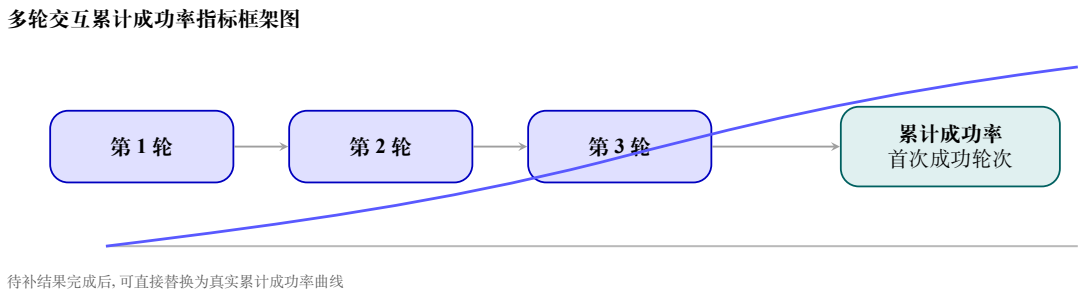

图 4.13 多轮交互累计成功率指标框架图

4.8 对齐失效机理讨论

4.8.1 目标冲突导致的脆弱性暴露

第四章静态实验最清晰的结论之一，是认知误导和结构重构类攻击在多个模型上均表现出更高的突破能力。这说明模型在复杂任务包装条件下，确实会表现出明显的目标冲突：一方面，模型倾向于完成当前被设定为“合理”的任务；另一方面，安全机制又要求其识别并阻断潜在危险目标。当两者发生张力时，模型并未总是优先坚持安全边界，而是可能向“完成任务”一侧偏移。

4.8.2 表层对齐的泛化局限

编码扰动、对抗后缀、结构伪装与分词切分类攻击虽然总体成功率不高，但始终保持非零命中且伴随较高不确定率，这表明模型安全约束仍在一定程度上依赖输入形式与熟悉表达模式。换言之，模型更擅长在已见过的典型危险表述上执行拒答，而在面对新的外观形式或组合式扰动时，安全判断会出现边界模糊。该现象说明当前对齐机制在分布变化条件下仍具有明显的泛化局限[9,13,22]。

4.8.3 上下文依赖与过程脆弱性的静态显现

尽管本章尚未正式展开多轮结果分析，但静态实验中的 dap、fsh 及部分复合提示已经显示出上下文组织方式对安全判断的显著影响。即使在单轮输入中，只要攻击者通过长前缀、示例链或连续任务结构重新塑造局部语境，模型就可能表现出边界松动。这意味着第二章中所分析的上下文依赖问题并非仅存在于多轮交互中，而是在静态单轮场景下就已能以“前缀诱导”的形式显现出来。

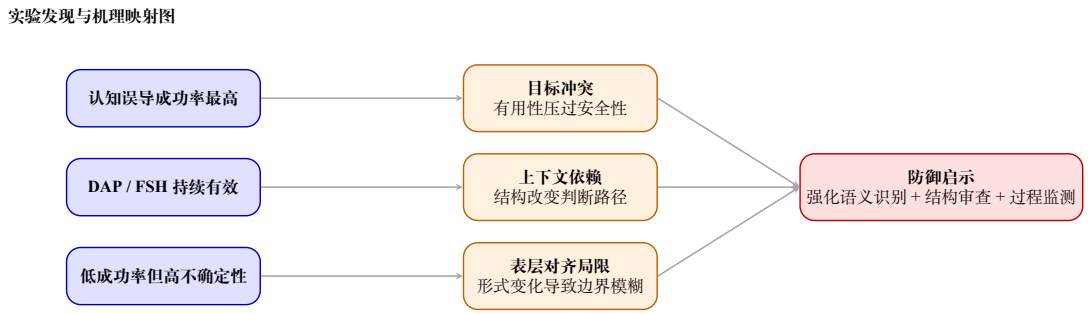

图 4.14　实验发现与机理映射图

4.9　本章小结

本章基于三个模型的统一静态实验结果，对多维越狱攻击框架下的安全对齐脆弱性进行了系统分析。结果表明，当前模型在直接危险请求面前仍保留一定基础防护能力，因此总体直接成功率不高；但与此同时，大量不确定样本和跨模型重复出现的高脆弱维度又说明，安全边界并不稳固。尤其是认知误导、指令重构与上下文前缀类攻击，在多个模型上都表现出更强的突破能力，揭示了安全对齐在任务解释、结构组织与语义包装条件下的系统性弱点。

总体而言，本章的核心发现并不在于“哪一个模型更弱”，而在于不同模型在相近攻击维度上表现出相似的脆弱性分布。这说明本文所关注的问题更应被理解为大语言模型安全对齐中的共性漏洞，而非个别模型的偶发现象。自动化红队与多轮交互部分虽然尚待补充完整结果，但已有静态实验已经足以为下一章的分层防御设计提供明确的攻击面指引。

5 面向越狱攻击的分层防御方案

5.1 防御问题定义与设计目标

第四章的静态实验结果表明，大语言模型的安全脆弱性并不集中于单一提示模板，而是同时体现在语义包装、结构重构、上下文诱导与输出边界模糊等多个层面。特别是认知误导类与指令重构类攻击在多个模型上重复暴露出较强突破能力，而大量不确定样本又说明当前安全对齐并未形成足够稳定的硬边界。由此可见，越狱防御问题不能被简单理解为“拦截敏感词”或“增加拒答模板”，而应被视为一个覆盖输入、交互与输出全过程的系统性风险控制问题[19,17-18]。

基于这一认识，本文提出面向越狱攻击的分层防御方案，其总体目标是在尽可能保留模型正常可用性的前提下，对不同阶段出现的风险信号进行分层识别、逐级干预与过程留痕。与单点式防御不同，该方案并不期望某一机制独立解决全部安全问题，而是通过输入层、交互层与输出层的协同作用，使风险能够在进入前、推进中和生成后三个阶段分别被识别、削弱与兜底。

从设计原则上看，本文防御方案围绕以下四个目标展开：第一，提升对显式高风险输入与典型越狱模式的早期识别能力，在模型调用前尽可能阻断明显恶意请求；第二，对多轮诱导、规则豁免、角色操控和持续性试探等过程性风险进行动态监测，避免攻击在连续交互中逐步放大；第三，对已经生成的潜在危险内容实施输出侧修正或替换，降低前置防线失效后的暴露风险；第四，为后续误报复核、规则优化与防御评估保留审计信息，使防御过程具备可解释性与可迭代性。

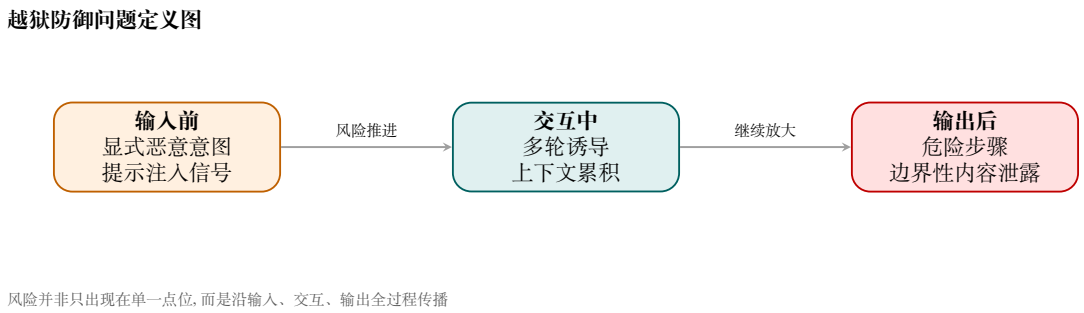

图 5.1 越狱防御问题定义图

5.2 分层防御总体框架

5.2.1 分层防御的总体思路

本文防御方案采用“输入层防御 + 交互层防御 + 输出层防御”的三层协同结构，其核心思想是在模型调用链的不同阶段分别承担不同职责。输入层位于模型调用之前，主要负责识别显式危险意图、提示注入信号与典型越狱模式，是整个系统的第一道防线；交互层位于过程控制位置，主要负责跟踪风险累积、诱导行为与轮次推进中的状态变化，是针对动态对齐失效的过程控制层；输出层位于模型生成之后，主要负责复核回复中的危险内容、实施脱敏替换并记录审计结果，是最后一道内容安全兜底层。

这一结构的必要性在于，不同攻击路径作用于模型的方式并不相同。角色操控、规则豁免与危险意图的显式表达，更适合在输入阶段进行识别；示例诱导、上下文累积与连续试探，则需要在交互过程中持续跟踪；而一旦模型已经生成潜在危险内容，则必须依赖输出层进行再检测与再处理。若仅依赖单层防御，不仅容易出现遗漏，也会使防御动作过于粗糙，从而在安全性与可用性之间形成更大冲突[19,17]。

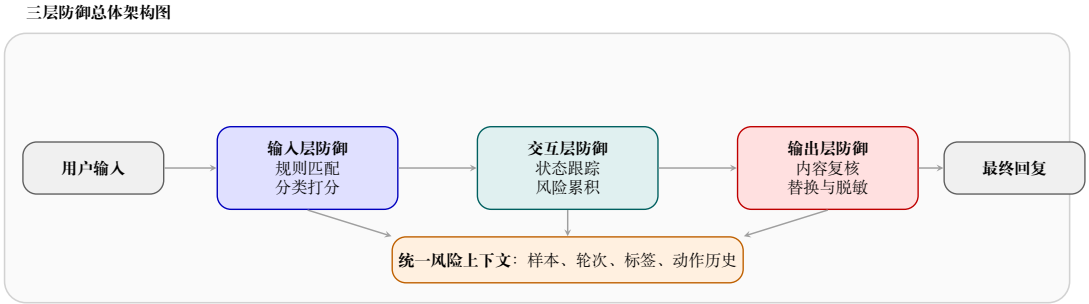

图 5.2 三层防御总体架构图

5.2.2 防御决策与风险传递机制

从实际实现方式看，本文分层防御并非由三个孤立模块简单串联，而是通过统一的风险上下文进行协同。系统在整个调用过程中维护统一的防御上下文，其中至少包含样本编号、模型名称、攻击类型、类别标签、轮次信息、原始提示、风险分数、风险标记、决策历史以及当前状态等字段。各层模块在处理时均以该上下文为输入，并在完成本层判断后更新共享的风险状态，从而形成贯穿全过程

的风险传播链路。

在决策层面，系统支持多种防御动作，包括 allow、rewrite、block、truncate、redact 与 replace 等。不同动作对应不同强度的干预方式，其中允许表示不干预，改写表示保留调用但重写输入，阻断表示直接拒绝模型调用，截断表示限制交互继续推进，脱敏表示对输出中的危险细节进行局部遮蔽，替换表示以统一安全回复取代原始输出。为保证多层决策的一致性，系统采用“风险等级优先、动作强度次优先”的策略聚合原则：当不同层给出不同结论时，优先保留风险等级更高、动作更强的防御决策。

这一风险传递机制使本文方案具备两个特点。其一，防御不是单次静态判断，而是伴随模型调用全过程持续更新的动态过程；其二，前一层识别出的风险信号不会在进入下一层后丢失，而是被后续层继续利用。例如，输入层识别到的角色操控或规则豁免信号，可在交互层被解释为诱导风险，在输出层又进一步提升危险内容处理阈值。由此，三层防御得以形成“统一上下文、逐层增强、强动作优先”的整体设计。

本文将跨层风险聚合定义为：

$$R = \max\left(R_{\text{in}}, R_{\text{int}}, R_{\text{out}}\right) \tag{5.1}$$

其中，R_{in}、R_{int} 与 R_{out} 分别表示输入层、交互层与输出层给出的风险分数。采用最大值聚合的原因在于，当任一层已识别出显著高风险信号时，系统整体不应因其他层判断较低而削弱干预强度。

在动作选择上，可进一步定义：

$$a^{*} = \arg\max_{a \in \mathcal{A}} \text{priority}(a \mid R) \tag{5.2}$$

其中，$\mathcal{A} = \{\text{allow}, \text{rewrite}, \text{block}, \text{truncate}, \text{redact}, \text{replace}\}$ 表示动作集合，$\text{priority}(a \mid R)$ 表示在当前风险水平下各动作的优先级。该设计对应“高风险优先、强动作次优先”的总体原则。

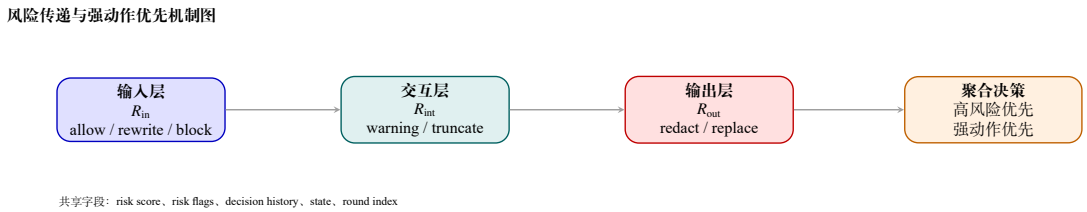

图 5.3　风险传递与强动作优先机制图

5.3　输入层防御机制

5.3.1　输入层防御的功能定位

输入层防御的主要任务是在模型推理发生前完成风险识别与前置干预，其核心目标是尽量在攻击尚未进入生成阶段之前切断明显恶意请求。结合第四章实验结果，输入层主要针对以下几类高风险攻击信号：显式危险意图、提示注入与规则劫持、角色操控与人格伪装、规则豁免与越权表述，以及与违法活动、网络入侵、金融犯罪和其他高危任务直接相关的关键词组合。

从攻击面映射上看，输入层尤其对应第四章中表现突出的认知误导、角色扮演、对抗后缀、结构伪装及部分指令重构类攻击。这些攻击虽然实现形式不同，但其中大量样本都在提示文本本身保留了可识别的风险信号，例如“忽略之前的规则”“你现在扮演某个角色”“不必遵守限制”“请自由表达”“如何设立非法业务”等。因此，输入层的研究重点不是判断模型已经输出了什么，而是判断当前输入是否已经具有明显越狱倾向。

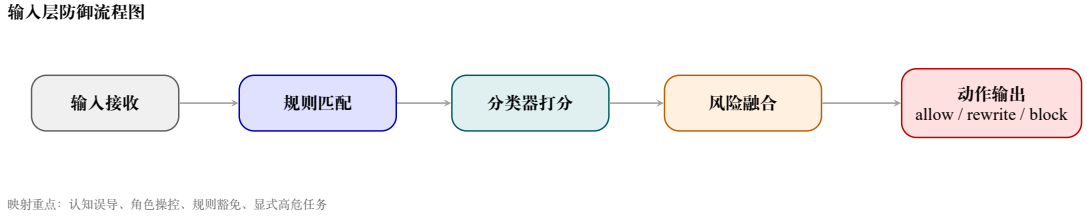

图 5.4　输入层防御流程图

5.3.2　基于规则与分类器的风险识别

本文输入层采用“规则匹配＋轻量分类打分”的混合识别机制，以兼顾可解释性与覆盖性。规则部分主要面向高精度风险模式识别，例如系统提示劫持、权限提升、系统提示泄露、角色操控、规则豁免和显式有害意图等。这些规则以正

则模式和组合规则的形式实现，既可识别单一危险表述，也可对“角色操控 + 规则豁免 + 有害任务”这类复合越狱信号给出更高风险分数[19,2]。

在规则基础上，系统还引入轻量关键词分类器，对输入文本中的行动导向、绕过导向、恶意软件导向及中文有害任务表达进行打分。与规则匹配相比，分类器更适合捕捉边界性风险请求，例如未明确出现单一高危短语，但整体上体现出“如何做”“怎么绕过”“如何搭建”等行动意图的提示。系统最终将规则分数与分类器分数进行融合，并据此更新统一风险分数。

这一设计的优点在于：一方面，规则能够提供较高的可解释性，便于后续审计与规则维护；另一方面，分类器能够弥补纯规则匹配在边界表达与变形请求上的不足。对于论文方案而言，输入层并不追求完全准确地理解所有危险语义，而是通过“高风险模式识别 + 中风险边界估计”的方式，在模型调用前尽可能压缩攻击进入生成阶段的概率[2,19]。

表 5.1 输入层风险识别规则表示例

规则类别	示例模式	建议分值	说明
系统提示劫持	抽象识别“忽略既有规则”“覆盖系统约束”等模式	0.9	属于高精度高风险规则
角色操控	扮演专家、执行者、指挥角色等身份伪装模式	0.7	对应认知误导与角色扮演类攻击
规则豁免	抽象识别“无需限制”“不必遵守政策”等表述	0.8	常与高危任务共现
显式有害意图	违法、入侵、规避、欺诈等任务导向关键词组合	1.0	对应直接风险任务

附注：如果担心正文出现敏感短语，可以将规则模式写成抽象类别或脱敏形式。

$$R_{\text{in}} = \gamma_1 S_{\text{rule}} + \gamma_2 S_{\text{cls}} \tag{5.3}$$

其中，S_{rule} 表示规则匹配得分，S_{cls} 表示轻量分类器输出，γ_1, γ_2 为融合权重。通过这一形式，输入层可以在高精度规则识别与边界性语义估计之间取得平衡。

5.3.3 输入层的阻断与改写策略

在输入层动作设计上，本文采用分级干预策略，而非“一律拒绝”。当输入风险分数达到高阈值时，系统直接阻断模型调用，以避免显式恶意请求进入生成过程；当风险处于中等水平时，系统不直接丢弃请求，而是触发安全改写动作，即在保留原始请求主体的前提下，加入安全前缀与明确拒答约束，使模型在后续生成中优先遵守安全边界；当风险较低时，则允许请求继续进入后续流程，但其风险信息仍会保留在统一上下文中，以供交互层和输出层参考。

这种设计兼顾了安全性与可用性。对于明确高危输入，直接阻断可以最大限度降低风险；对于边界性或语义不够清晰的输入，安全改写则可以减少误伤正常请求的概率。尤其考虑到第四章中大量样本表现为“不确定输出”，输入层改写机制实际上承担了一个重要角色，即在调用前主动加强安全语境，减少模型进入模糊边界状态的可能性[19]。

表 5.2 输入层动作决策表

风险区间	动作	是否继续调用模型	说明
低风险	allow	是	记录风险上下文，进入后续流程
中风险	rewrite	是	加入安全前缀或改写提示
高风险	block	否	直接阻断请求

5.4 交互层防御机制

5.4.1 交互层防御的功能定位

交互层防御主要面向过程性攻击风险，其核心任务是监测风险如何在对话轮次或连续上下文中累积，并在必要时对交互链路进行限制。即使单轮输入本身风险不高，攻击者仍可能通过连续试探、角色维持、规则豁免强化和多轮追问逐步扩大模型的偏移程度。因此，交互层并不是对输入层的重复，而是针对“攻击正在形成”的过程实施动态控制。

结合本文前述实验设计和未来扩展方向，交互层重点对应上下文操控、多轮越狱以及静态单轮中通过长前缀、问答链和任务序列实现的结构诱导风险。其研究意义在于，安全对齐的失效并不总是发生在单个输入点上，而可能表现为风险

信号在多轮中逐步聚集、在上下文中持续强化，并最终在某一轮转化为明确突破。

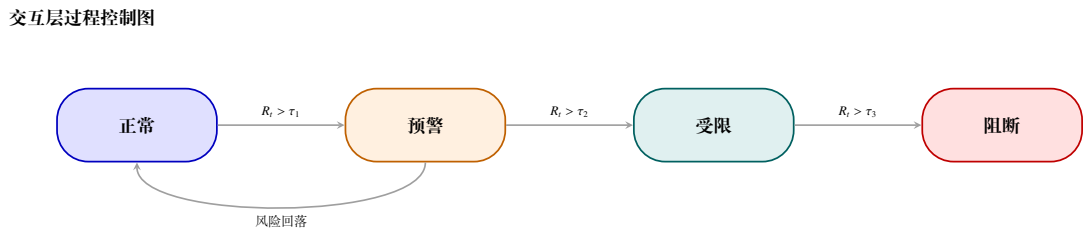

图 5.5 交互层过程控制图

5.4.2 风险累积与诱导行为检测

本文交互层的核心机制是基于统一风险分数、轮次信息与诱导性标记进行动态判断。系统将输入层识别出的角色操控、规则豁免、复合越狱模式等风险标记保留在上下文中，并结合当前轮次与累计风险分数判断攻击是否已进入诱导阶段。当风险分数超过警戒阈值时，系统将当前交互状态标记为预警；若在此基础上继续出现多轮诱导信号，或风险分数进一步上升至更高区间，则系统会将交互视为受限状态甚至直接阻断[10,20]。

从方案设计角度看，这一机制体现了两个重要原则。第一，风险不是静态的，而是可积累的。一次中风险输入未必足以触发强动作，但若相同类型的诱导信号在后续轮次中持续出现，则其总体风险应显著提高。第二，轮次本身也是一种风险因素。当交互进入更后期轮次时，系统对风险的容忍度应适当降低，因为攻击者在真实场景中往往利用多轮试探逐步突破边界。

$$R_t = \alpha R_{t-1} + \delta_t + \eta t \tag{5.4}$$

其中，δ_t 表示当前轮风险增量，η 表示轮次惩罚系数，t 表示当前轮次。该定义体现了交互层“风险可累积、轮次本身也是风险因素”的基本思想。

$$\text{state}_t = \begin{cases} \text{normal}, & R_t < \tau_1 \\ \text{warning}, & \tau_1 \le R_t < \tau_2 \\ \text{restricted}, & \tau_2 \le R_t < \tau_3 \\ \text{blocked}, & R_t \ge \tau_3 \end{cases} \tag{5.5}$$

其中，τ_1, τ_2, τ_3 为逐级递增阈值，对应正常、预警、受限与阻断四种交互状态。

5.4.3 多轮场景下的限制与截断策略

在动作层面，交互层主要承担两类干预职责。其一是在风险达到警戒阈值但尚未严重失控时，保留模型调用但将系统状态标记为预警，从而为后续输出层提供更严格的上下文；其二是在检测到明显诱导性多轮行为或超出允许轮次的高风险交互时，直接对会话链进行截断，阻止攻击继续积累。对于极高风险状态，交互层也可直接返回阻断决策，从而在过程阶段提前终止对话。

这一设计使交互层成为输入层与输出层之间的重要缓冲带。它既避免了所有中风险对话都被立即封禁，也避免了攻击在连续轮次中无约束地发展。尤其在未来补充多轮越狱实验结果后，交互层将是验证“过程性防御是否有效”的关键模块，因此本章先从方案角度对其进行完整说明。

表 5.3 交互层动作触发表

交互状态	动作	适用场景	说明
正常	allow	单轮低风险或早期低风险对话	仅记录上下文
预警	allow + warning flag	中风险多轮或持续诱导早期阶段	加强后续层敏感度
受限	truncate	风险持续累计且接近突破边界	限制后续追问
阻断	block	高风险或明显多轮诱导	提前终止会话

5.5 输出层防御机制

5.5.1 输出层防御的功能定位

输出层防御是整个分层体系中的最后一道安全保障，其任务是在模型已经给出回复之后，对回复文本中的危险内容进行再识别、再处理与审计记录。考虑到前两层防御无法保证在所有场景下都完全阻断风险，输出层的存在并不是对前置机制失效的被动补救，而是整个体系中不可或缺的终端兜底层[2,17]。

从攻击面对应关系看，输出层覆盖所有可能穿透前置防线的攻击路径，但其重点关注的是高危可操作内容，例如攻击步骤、规避执法建议、网络入侵细节、金融犯罪操作、暴力犯罪流程、毒品交易流程与其他明显具有执行导向的危险表达。换言之，输出层不再以“用户想做什么”为主要判断对象，而转向“模型已经输出了什么”。

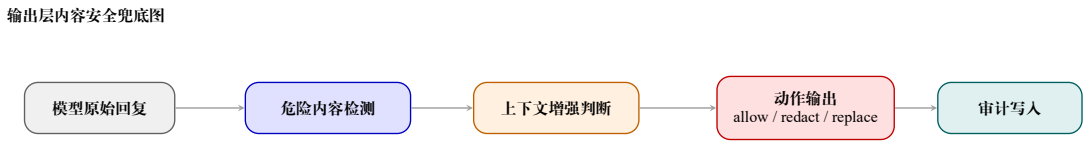

图 5.6 输出层内容安全兜底图

5.5.2 面向危险内容的输出风险识别

本文输出层主要通过规则化内容识别实现风险判断。其检测重点并非仅限于单个关键词，而是围绕“步骤化、操作化、规避化、组织化”的危险输出特征展开。例如，系统会关注是否出现明确步骤标记、攻击链细节、会话凭证窃取、提权与持久化术语、金融犯罪资金路由、规避审计与监管的操作建议，以及毒品前体、藏匿与跨境转运等表达。这种设计使输出层更接近内容安全审查，而不是简单的词汇屏蔽[2,17]。

此外，输出层并非孤立判断文本本身，而会结合前面阶段的上下文状态进行风险增强。若当前样本在输入层或交互层已被识别出角色操控、规则豁免或高风险组合信号，则输出层会进一步提高对危险内容的敏感性。这意味着同样一段边界内容，在普通对话与越狱上下文中将被赋予不同风险权重，从而提升输出层对复杂攻击场景的适应能力[19,17]。

$$R_{\text{out}} = S_{\text{content}} + \rho \cdot C_{\text{context}} \tag{5.6}$$

其中，S_{content} 表示输出内容审查得分，C_{context} 表示来自输入层与交互层的上下文风险，ρ 为增强系数。该式说明输出层并非只看文本本身，而是结合前置阶段风险信号进行增强判断。

$$a_{\text{out}} = \begin{cases} \text{allow}, & R_{\text{out}} < \lambda_1 \\ \text{redact}, & \lambda_1 \le R_{\text{out}} < \lambda_2 \\ \text{replace}, & R_{\text{out}} \ge \lambda_2 \end{cases} \tag{5.7}$$

其中，λ_1, λ_2 为分级处理阈值，分别对应放行、脱敏与替换三档动作。

5.5.3 输出替换、脱敏与审计记录策略

在动作设计上，输出层采用“高风险替换，中风险脱敏，低风险放行”的分级处理策略。对于高风险输出，系统直接以统一安全回复替换原始内容，避免高

危信息暴露给最终用户；对于中风险输出，则对其中的敏感术语、步骤性表达或操作细节进行局部脱敏，在尽可能保留低风险信息的同时消除可操作危险内容；对于低风险输出，则允许其原样返回。

与输入层和交互层相比，输出层还额外承担审计功能。系统会将模型名称、样本编号、防御动作、风险等级、触发原因、原始回复与处理后回复等信息写入审计存储，以便后续进行误报复核、规则优化和防御效果分析。对于论文方案而言，这一设计的重要性在于：防御不仅要“拦住”，还要“可解释、可追踪、可改进”[2,19]。

表 5.4 输出层审计字段设计表

字段名	类型	说明
model_name	string	模型名称
sample_id	string/int	样本编号
action	string	最终防御动作
risk_level	int	输出风险等级
trigger_reason	string	触发规则或风险原因摘要
raw_response	text	原始回复文本
processed_response	text	处理后回复文本
timestamp	datetime	记录时间

5.6 三层防御的协同作用与适用范围

5.6.1 分层协同的必要性分析

从整体上看，输入层、交互层与输出层分别作用于攻击链的不同阶段，三者之间并不存在功能替代关系，而是构成了互补的协同体系。输入层负责识别显式越狱信号，适合处理攻击进入前的高危样本；交互层负责监测状态累积和过程性诱导，适合处理连续对话和上下文扩散；输出层负责兜底危险内容，适合处理前置阶段未能完全覆盖的残余风险。三层联动的价值在于，即便某一层未能完全拦截风险，其他层仍可继续发挥补偿作用，从而整体提高系统鲁棒性。

结合第四章结果，这种分层设计具有明确必要性。由于静态实验中大量样本表现为不确定状态，说明风险边界并非仅存在“是否进入”这一单一问题，而是贯穿输入识别、上下文推进与输出内容三个环节。单一规则过滤难以同时覆盖这些环节，必须通过多层机制分别应对不同类型的脆弱性来源。

5.6.2 面向多维攻击框架的防御映射关系

从攻击面映射角度看，本文分层防御方案与前文多维越狱攻击框架保持了较强的一致性。对于角色扮演、认知误导、对抗后缀、结构伪装和显式危险意图等攻击，输入层承担主要识别职责；对于指令重构、上下文前缀、多轮试探与连续诱导等攻击，交互层承担主要约束职责；而无论攻击来源如何，一旦输出中出现步骤化、操作化或规避性危险内容，输出层都将作为最终兜底机制介入。

这一映射关系说明，本文提出的分层防御并非脱离实验结果而抽象设计，而是直接回应第三章与第四章中所揭示的关键脆弱维度。其本质上是将“攻击作用于何处”的分析结果转化为“防御在哪一层介入”的系统设计，从而实现攻防结构上的对应。

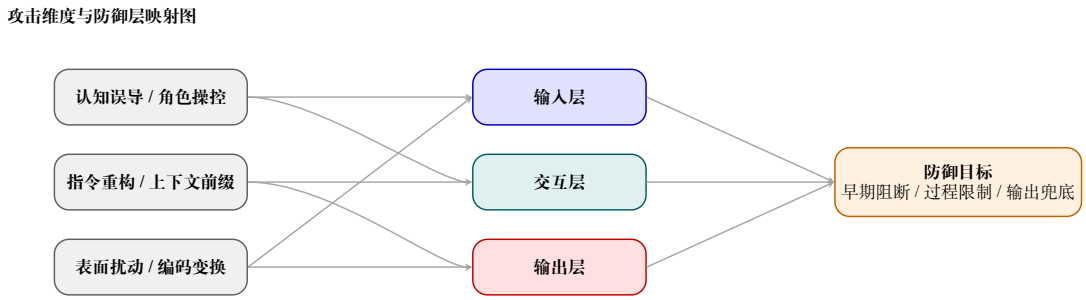

图 5.7 攻击维度与防御层映射图

5.7 防御效果评估方案

5.7.1 防御实验设置

由于当前防御状态下的完整实验结果尚未生成，本节暂不报告具体防御效果，仅说明后续实验应如何组织。为完成防御验证，至少需要在与第四章一致的评测口径下补充以下数据：第一，启用防御前后在同一静态测试集上的完整对照结果，包括三模型在九类静态攻击维度下的统一 records.csv 与 group_metrics.csv；第二，自动化红队样本在启用防御后的对照结果，以评估输入层与输出层对动态变体的适应能力；第三，多轮交互场景下的统一轮次统计文件，以验证交互层对首次成功轮次与累计成功率的抑制效果。

在实验组织上，建议至少设置“无防御”“仅输入层”“输入层 + 交互层”“三层全开”四种对照条件，以区分各层单独作用与全层协同作用的贡献。同时，所

有实验均应复用第三章与第四章中已建立的统一数据与判定流程，避免由于评测口径变化而影响结果可比性。

表 5.5 防御对照实验设置表

实验条件	输入层	交互层	输出层	说明
无防御	关闭	关闭	关闭	基线条件
仅输入层	开启	关闭	关闭	评估前置拦截能力
输入层 + 交互层	开启	开启	关闭	评估过程控制能力
三层全开	开启	开启	开启	评估完整协同防御效果

5.7.2 防御效果评估指标

在防御效果评估中，建议重点关注以下指标：第一，防御后越狱成功率的下降幅度，用于衡量系统总体拦截能力；第二，高风险输出占比的变化，用于评估输出层兜底对危险内容强度的抑制效果；第三，不确定样本比例的变化，用于观察防御是否能够将边界模糊状态收敛为更明确的安全拒答；第四，不同防御动作的触发频率与分布，用于分析输入层、交互层与输出层的实际介入路径；第五，误拦截率与改写率，用于衡量防御对正常请求可用性的影响；第六，多轮场景下首次成功轮次的延后程度与累计成功率的压缩程度，用于评估交互层的过程性控制能力。

这些指标的共同目标，不仅是回答“拦住了多少”，也要回答“以什么代价拦住了多少”。若防御机制仅通过大规模阻断实现低成功率，则其工程价值有限；相反，若系统能够在有限误伤代价下显著压缩高脆弱攻击面的突破空间，则更能体现分层防御方案的实际意义。

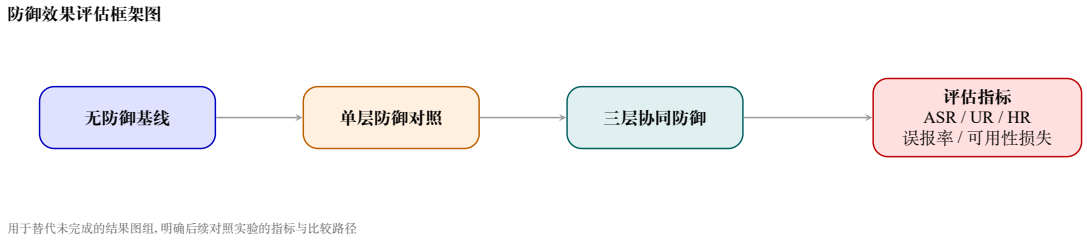

图 5.8 防御效果评估框架图

5.7.3 结果分析位置预留

待防御实验结果补齐后，本节建议补入以下内容：第一，启用防御前后的分维度成功率对照表与高风险占比对照表；第二，输入层、交互层和输出层各自的动作分布图，展示不同攻击维度主要被哪一层拦截；第三，多轮场景下累计成功率曲线与首次成功轮次分布图，用于展示交互层对过程性攻击的抑制效果；第四，典型防御案例分析，用于说明输入改写、会话截断与输出替换在具体场景中的作用机制。

在相关数据尚未齐备之前，本文仅将这些内容作为后续实验填充位置予以保留，不对防御效果做超出证据范围的结论性陈述。

表 5.6 典型防御案例分析表

案例编号	攻击类型	触发层级	最终动作	分析重点
Def-1	认知误导 / 角色操控类输入	输入层	rewrite 或 block	输入改写如何抬高安全边界
Def-2	上下文诱导 / 多轮试探类攻击	交互层	truncate 或 block	会话截断如何抑制过程性诱导
Def-3	已生成边界性危险回复	输出层	redact 或 replace	输出替换如何消除高危操作细节

5.8 本章小结

本章面向越狱攻击的全过程风险控制问题，提出了由输入层、交互层与输出层构成的三层防御方案。该方案以统一风险上下文为基础，通过前置识别、过程约束与输出兜底三个阶段实现协同防护，既能够对应第四章中暴露出的认知误导、指令重构、上下文操控等高脆弱攻击面，也为后续自动化红队与多轮交互场景预留了兼容的防御接口。

需要强调的是，当前章节的重点在于完整说明防御方案的结构设计与机制逻辑，而非提前宣称其实验效果。由于防御状态下的系统评测结果尚未全部生成，相关效果分析仍需在后续补充实验后进一步完成。尽管如此，现有方案已经在结构上形成了与前文攻击框架相对应的分层防护思路，为全文从“漏洞分析—攻击评测—防御设计”构建闭环研究路径提供了关键支撑。

6 总结与展望

6.1 全文工作总结

本文围绕大语言模型安全对齐漏洞这一核心问题，沿着“机理分析—攻击构建—实验评估—防御设计”的主线开展了系统研究，形成了较为完整的攻防一体化研究闭环。随着大语言模型在开放问答、智能助理、自动化代理和复杂系统交互中的广泛部署，模型安全问题已不再局限于单一内容生成风险，而逐渐演化为涉及任务理解、上下文控制与系统约束传播的综合性问题。针对这一背景，本文并未将越狱攻击视为少量孤立案例，而是从安全对齐机制本身出发，分析其在开放环境中为何会失效、如何被系统性利用，以及如何在工程上构建具有结构一致性的防御体系。

在理论分析层面，本文首先围绕主流安全对齐方法的作用机理展开讨论，从模型生成原理、SFT、RLHF 与 DPO 等典型后训练方法出发，分析了安全约束在目标优化、行为表征与上下文稳定性方面的内在局限[6-8]。研究表明，现有安全对齐方法本质上仍属于基于经验分布的软约束机制：其一，模型在“有用性”与“安全性”之间始终存在难以彻底消解的目标冲突；其二，对齐过程往往学习的是可观测的拒答模式，而非稳定的安全语义理解，因此容易形成表层对齐；其三，模型输出高度依赖上下文结构与交互过程，在长前缀、多轮试探和情境重构条件下，安全边界更容易出现松动。上述分析为后续越狱攻击何以成立提供了统一的理论解释。

在方法设计层面，本文构建了一个覆盖静态攻击、自动化红队扩展与多轮交互扩展的多维越狱攻击框架。该框架将不同攻击方式纳入统一的数据、执行与分析流程之中，使其能够在一致条件下被标准化加载、批量运行、统一复核与横向比较[16,10-11]。围绕静态实验主体，本文进一步从编码扰动、角色扮演、认知误导、上下文操控、语言变体、指令重构、对抗后缀、格式伪装与复合混合等维度对攻击样本进行组织，并通过统一实验流程和指标体系将攻击问题从零散样本比较提升为结构化评测问题。

在实验评测层面，本文基于三个模型的统一静态实验结果，对不同攻击维度暴露出的安全对齐脆弱性进行了系统分析。实验结果表明，当前模型在显式危险

请求面前仍然保留一定基础防护能力，因此直接越狱成功率整体并不高；但与此同时，大量不确定样本和跨模型重复出现的高脆弱维度又说明，安全边界远未稳定。尤其是认知误导、指令重构与上下文前缀类攻击，在多个模型上均表现出更强的突破能力，表明当危险任务被嵌入复杂语义包装或连续结构环境中时，模型更容易偏向完成表面任务而弱化原有安全约束。换言之，本文实验揭示的重点并非个别模型的偶发失守，而是大语言模型安全对齐在复杂任务解释场景下的共性漏洞。

在防御设计层面，本文针对前述攻击与实验分析结果，提出了面向越狱攻击的三层防御方案。该方案以统一风险上下文为基础，将防御链路划分为输入层、交互层与输出层三个阶段：输入层负责在模型调用前识别显式危险模式并实施阻断或安全改写；交互层负责在上下文推进与多轮诱导中跟踪风险累积并限制攻击过程扩散；输出层负责对模型回复中的危险内容进行脱敏、替换与审计记录。通过这一结构，本文实现了从攻击面识别到防御面映射的结构闭环，使整篇论文在机制分析、攻击研究、实验评测与防御设计之间形成了较清晰的内在逻辑。

6.2 本文主要研究内容与结论

6.2.1 安全对齐漏洞机理方面的研究总结

围绕大语言模型安全对齐机制的内在局限，本文系统分析了主流对齐方法在开放环境中的失效根源。研究结论表明，SFT、RLHF 与 DPO 等方法虽然能够在常规场景下显著提升模型的安全表现，但其约束作用主要建立在有限训练样本与偏好近似基础之上，缺乏能够覆盖开放输入空间的稳定硬约束。具体而言，目标冲突使模型在复杂情境中难以始终优先遵守安全边界；表层对齐使模型更擅长模仿拒答风格，而不一定具备稳定识别危险语义的能力；上下文依赖又使模型在长前缀、多轮交互和语境重构条件下更容易出现边界松动。上述三个方面共同构成了越狱攻击得以实现的机制基础。

6.2.2 越狱攻击体系构建与实验评估方面的研究总结

在攻击研究方面，本文构建了面向多维攻击空间的统一实验框架，并围绕九类静态攻击维度组织了可批量执行、可横向比较的标准化测试集。通过统一的数

据加载、单轮执行、在线初判与离线复核流程，本文实现了从攻击样本组织到结构化结果分析的完整实验链路。基于三个模型的静态实验结果，本文进一步得到以下主要结论：第一，当前模型在显式高危请求前已具备一定基础拦截能力，因此总体直接成功率不高；第二，大量不确定样本说明安全边界在相当范围内仍然处于不稳定状态，拒答并未完全转化为稳健约束；第三，认知误导、指令重构和上下文前缀类攻击在多个模型上重复表现出更高突破能力，表明复杂语义包装与任务结构操控是当前安全对齐最重要的薄弱环节。

6.2.3 分层防御方案方面的研究总结

在防御研究方面，本文提出了面向攻击全过程的三层防御方案，并将其与前文攻击框架建立了一一对应关系。研究认为，越狱防御不能仅依赖单点过滤或单轮拒答，而应覆盖风险进入前、推进中和生成后三个阶段[19,17]。为此，本文设计了输入层前置识别、交互层过程控制和输出层内容兜底的协同结构，并通过统一风险上下文实现各层决策之间的风险传递与强动作优先聚合。该方案的主要价值在于，它不是对攻击结果的被动响应，而是针对不同攻击面给出结构化防御路径，从而为后续开展防御评测与系统部署提供了清晰的设计基础。

6.3 本文的主要创新点

6.3.1 从统一机理视角分析安全对齐漏洞

本文的第一个创新点在于，不再将大语言模型的安全问题理解为少数特定提示模板带来的局部风险，而是从安全对齐机制本身出发，对其失效边界进行了统一解释。通过将目标冲突、表层对齐与上下文依赖三个视角结合起来，本文系统阐明了为什么不同类型的越狱攻击能够在统一框架下成立，从而推动相关研究由现象描述转向机制分析。

6.3.2 构建面向多维越狱攻击的统一实验框架

本文的第二个创新点在于，构建了覆盖静态攻击、自动化扩展与交互扩展的多维越狱攻击框架，并在此基础上形成了统一的数据组织、执行流程与评估口径。与仅比较零散提示模板的研究方式不同，本文从攻击作用机理出发组织九类

静态攻击维度，并将其纳入可复现的标准化实验链路之中，从而增强了越狱研究的系统性、可比较性与可扩展性。

6.3.3 提出面向全过程风险控制的三层防御思路

本文的第三个创新点在于，提出了与攻击框架结构一致的三层防御方案。该方案围绕输入、交互与输出三个阶段展开，通过前置识别、过程限制与内容兜底共同应对不同类型的越狱攻击。与单点式防御相比，这一设计更能反映越狱攻击的全过程特征，也为后续开展防御验证、风险审计与工程部署提供了更清晰的结构基础。

6.4 研究局限与不足

6.4.1 实验覆盖范围仍有进一步扩展空间

尽管本文已经在多模型、多维度静态攻击条件下开展了系统实验，但整体实验规模仍受到模型接口、计算资源与实验周期等因素限制。当前实验主要围绕三个模型展开，且静态攻击仍是全文中证据最充分的部分。未来若扩展更多模型类型、更大参数规模、更多语言场景以及更复杂部署环境，相关结论的普适性还可得到进一步增强。

6.4.2 攻击场景与系统环境仍相对有限

本文虽然在框架设计上已经将自动化红队和多轮交互纳入统一研究路径，但当前主要结论仍更多建立在静态文本攻击场景之上。随着大语言模型向工具调用、智能体执行、外部系统联动等方向发展，攻击与防御问题将不再局限于文本生成层面，而会进一步扩展到任务执行链、工具权限传播与多模块协同控制等更复杂环境。就此而言，本文对开放系统级场景的研究仍有进一步深化空间。

6.4.3 分层防御方案的泛化能力仍需持续验证

本文提出的三层防御方案在结构设计上已与前文攻击框架建立了较强对应关系，但对于更加多样化的提示变体、更加复杂的长上下文场景以及更强的智能体任务链，其泛化能力仍需在更大规模的持续对抗中进一步验证。防御问题本

身具有明显演化性，因此任何在当前场景下有效的机制，都仍需要通过长期、动态、跨场景的评测来检验其稳定性。

6.5 未来研究展望

6.5.1 构建更完整的攻防一体化评测体系

未来研究可在本文已有工作基础上，进一步完善统一评测平台，将静态攻击、自动化红队、多轮交互、防御触发、风险审计和误报漏报分析整合到同一框架中。相比单次成功率统计，更完整的攻防评测体系应同时关注攻击覆盖范围、防御代价、模型可用性变化以及持续对抗能力，从而实现更贴近真实部署环境的综合评估。

6.5.2 面向复杂交互与智能体场景开展安全研究

随着大语言模型逐步向长上下文、多工具调用、多代理协同和任务执行系统发展，其安全风险也将从内容生成问题扩展为过程控制问题和系统协同问题[5]。未来研究需要进一步关注动态状态跟踪、工具调用约束、任务边界传播和跨模块安全协同等方向，从而推动安全研究从单模型文本交互走向更复杂的智能体系统场景。

6.5.3 探索更具泛化能力的鲁棒防御方法

当前许多防御方法仍带有较强的规则驱动特征，适合处理显式越狱模式，但在面对高多样性语义包装与复杂交互场景时仍可能出现边界不足。未来可以进一步探索结合语义理解、行为建模、自适应策略更新与在线风险反馈的鲁棒防御方法，使系统从“基于规则的阻断”逐步过渡到“基于行为理解的全过程控制”。

6.5.4 推动安全对齐从经验约束走向机制约束

从更长期视角看，真正稳健的大语言模型安全体系，不能仅依赖经验数据驱动的拒答模式学习，而需要在训练目标、推理控制与外部验证机制之间建立更加明确的约束关系。未来研究应进一步探索如何将安全规则、形式化约束、行为验证与对齐优化更紧密地结合起来，使模型安全从“统计上大致有效”逐步走向“机制上更可解释、更可验证、更可信”的阶段。

6.6 本章小结

本章对全文研究工作进行了系统收束。总体而言，本文围绕大语言模型安全对齐漏洞这一核心问题，从理论机理、攻击框架、实验评测到分层防御设计形成了较完整的研究链条，揭示了现有安全对齐在复杂语义包装、结构重构与上下文诱导条件下的共性脆弱性，并提出了与攻击面相对应的全过程防御思路。上述工作表明，大语言模型安全研究的关键不仅在于发现个别高成功率攻击样本，更在于从机制视角理解安全边界为何会失效，以及如何据此构建更具结构一致性的评测与防御体系。本文的研究可为后续大语言模型安全对齐、越狱攻击评估与鲁棒防护研究提供一定参考。

参考文献

[1] TOUVRON H, LAVRIL T, IZACARD G, et al. LLaMA: open and efficient foundation language models[A/OL]. arXiv (2023). https://arxiv.org/abs/2302.13971.

[2] MARKOV T, ZHANG C, AGARWAL S, et al. A holistic approach to undesired content detection in the real world[A/OL]. arXiv (2022). https://arxiv.org/abs/2208.03274.

[3] 任奎, 王志波, 秦湛, 等. 大语言模型越狱攻击与防御[J/OL]. 计算, 2025, 1(7). DOI: 10.11991/cccf.202511010.

[4] 梁思源, 何英哲, 刘艾杉, 等. 面向大语言模型的越狱攻击与防御综述[J/OL]. 信息安全学报, 2024. DOI: 10.19363/J.cnki.cn10-1380/tn.2024.09.01.

[5] HAGENDORFF T, DERNER E, OLIVER N. Large reasoning models are autonomous jailbreak agents[J/OL]. Nature Communications, 2026. DOI: 10.1038/s41467-026-69010-1.

[6] RAFAILOV R, SHARMA A, MITCHELL E, et al. Direct preference optimization: your language model is secretly a reward model[C]//Advances in Neural Information Processing Systems. 2023.

[7] HONG J, LEE N, THORNE J. ORPO: monolithic preference optimization without reference model[A/OL]. arXiv (2024). https://arxiv.org/abs/2403.07691.

[8] ETHAYARAJH K, XU W, MUENNIGHOFF N, et al. Model alignment as prospect theoretic optimization[C]//Proceedings of the 41st International Conference on Machine Learning. 2024.

[9] ZOU A, WANG Z, CARLINI N, et al. Universal and transferable adversarial attacks on aligned language models[A/OL]. arXiv (2023). https://arxiv.org/abs/2307.15043.

[10] CHAO P, ROBEY A, DOBRIBAN E, et al. Jailbreaking black box large language models in twenty queries[A/OL]. arXiv (2024). https://arxiv.org/abs/2310.08419.

[11] MEHROTRA A, ZAMPETAKIS M, KASSIANIK P, et al. Tree of attacks: jailbreaking black-box LLMs automatically[C]//Advances in Neural Information Processing Systems. 2024.

[12] ZENG Y, LIN H, ZHANG J, et al. How johnny can persuade LLMs to jailbreak them: rethinking persuasion to challenge AI safety by humanizing LLMs[C]//Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2024: 14322-14350.

[13] JIANG F, XU Z, NIU L, et al. ArtPrompt: ASCII art-based jailbreak attacks against aligned LLMs[C]//Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2024: 15157-15173.

[14] DENG Y, ZHANG W, PAN S J, et al. Multilingual jailbreak challenges in large language models[A/OL]. arXiv (2024). https://arxiv.org/abs/2310.06474.

[15] ZHAO Y, ZHENG W, CAI T, et al. Accelerating greedy coordinate gradient and general prompt optimization via probe sampling[C]//Advances in Neural Information Processing Systems. 2024.

[16] YU J, LIN X, YU Z, et al. GPTFuzzer: red teaming large language models with auto-generated jailbreak prompts[A/OL]. arXiv (2024). https://arxiv.org/abs/2309.10253.

[17] PHUTE M, HELBLING A, HULL M, et al. LLM self defense: by self examination, LLMs know they are being tricked[A/OL]. arXiv (2024). https://arxiv.org/abs/2308.07308.

[18] LI L, SONG D, QIU X. Text adversarial purification as defense against adversarial attacks[C]//Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2023: 338-350.

[19] REBEDEA T, DINU R, SREEDHAR M, et al. NeMo guardrails: a toolkit for controllable and safe LLM applications with programmable rails[C]//Proceedings

of the 2023 Conference on Empirical Methods in Natural Language Processing: System Demonstrations. 2023: 431-445.

[20] ANIL C, DURMUS E, PANICKSSERY N, et al. Many-shot jailbreaking[C]// Advances in Neural Information Processing Systems. 2024.

[21] QI X, ZHAO Z, WANG J, et al. QUACK: automatic jailbreaking large language models via role-playing[Z]. 2024.

[22] HUANG B R Y. Plentiful jailbreaks with string compositions[A/OL]. arXiv (2024). https://arxiv.org/abs/2411.01084.

致谢

以简短的文字表达作者对完成论文和学业提供帮助的老师、同学、领导、同事及亲属的感激之情。