

武汉大学

本科毕业论文（设计）

大模型安全对齐漏洞的越狱攻击研究

姓 名：赵国栋  
学 号：2022302181155  
专 业：信息安全专业  
学 院：国家网络安全学院  
指导教师：严飞

二〇二六年四月

## 原创性声明

本人郑重声明：所呈交的论文（设计），是本人在指导教师的指导下，严格按照学校和学院有关规定完成的。除文中已经标明引用的内容外，本论文（设计）不包含任何其他个人或集体已发表及撰写的研究成果。对本论文（设计）做出贡献的个人和集体，均已在文中以明确方式标明。本人承诺在论文（设计）工作过程中没有伪造数据等行为。若在本论文（设计）中有侵犯任何方面知识产权的行为，由本人承担相应的法律责任。

作者签名：

日 期：

指导教师签名：

年 月 日

## 版权使用授权书

本人完全了解武汉大学有权保留并向有关部门或机构送交本论文（设计）的复印件和电子版，允许本论文（设计）被查阅和借阅。本人授权武汉大学将本论文的全部或部分内容编入有关数据进行检索和传播，可以采用影印、缩印或扫描等复制手段保存和汇编本论文（设计）。

作者签名：

日 期：

指导教师签名：

年 月 日

## 摘要

大语言模型（Large Language Models, LLMs）近年来在智能问答、内容生成和复杂交互等场景中得到广泛应用，但其安全性问题也随之日益突出。尽管现有模型普遍经过安全对齐训练，但面对经过精心设计的越狱提示时，仍可能输出违反安全规范的内容。攻击者通常无需掌握模型内部结构，仅通过角色设定、语义包装、上下文操控等方式重构输入，就有机会诱导模型绕过既有约束，这也使大语言模型在开放环境中的部署面临持续的安全风险。

现有研究大多围绕具体攻击方法或防御策略展开，关于安全对齐为何失效、不同越狱方式之间有何内在联系，以及如何在统一口径下开展系统评测，仍缺乏较为完整的分析框架。针对上述问题，本文围绕大语言模型的安全对齐漏洞与越狱攻击展开研究。首先，从模型训练与后对齐机制出发，分析监督微调（SFT）、基于人类反馈的强化学习（RLHF）以及直接偏好优化（DPO）等主流方法在安全约束上的作用边界，并从目标冲突、表层对齐和上下文依赖等角度讨论对齐失效的内在原因。

在此基础上，本文构建了一个多维越狱攻击框架，围绕九类静态攻击维度组织统一测试集与实验流程，对不同攻击方式进行标准化比较。最后，本文提出了由输入层、交互层和输出层构成的三层防御思路，旨在分别应对风险输入识别、过程性诱导控制和危险内容兜底等问题。研究表明，当前大语言模型的安全对齐仍然存在明显脆弱性，越狱问题并非局部现象，而与对齐机制本身的约束边界密切相关。本文的研究为后续越狱评测体系构建与鲁棒防御设计提供了参考。

**关键词：**大语言模型；安全对齐；越狱攻击；提示工程；模型安全

## ABSTRACT

Large Language Models (LLMs) are widely used in question answering, content generation, and human–AI interaction, but their safety risks remain significant. Despite safety alignment training, LLMs can still be induced to produce harmful outputs through carefully crafted jailbreak prompts. Attackers can bypass safeguards without access to model internals by leveraging role-playing, semantic obfuscation, and contextual manipulation, posing challenges for deployment in open environments.

Existing work mainly focuses on specific attacks or defenses, while a systematic understanding of alignment failure and a unified evaluation framework remain limited. This paper investigates safety alignment vulnerabilities in LLMs by analyzing the roles and limitations of key alignment methods, including SFT, RLHF, and DPO. We further examine alignment failure from the perspectives of objective conflict, superficial alignment, and context dependency.

Based on this analysis, we propose a multi-dimensional jailbreak framework covering nine attack dimensions and introduce a three-layer defense paradigm consisting of input filtering, interaction control, and output safeguarding. This work provides a unified perspective on alignment failure and informs future evaluation and defense design.

**Keywords:** Large Language Models; Safety Alignment; Jailbreak Attacks; Prompt Engineering; AI Safety

# 目 录

|                              |           |
|------------------------------|-----------|
| 摘 要 .....                    | I         |
| ABSTRACT .....               | II        |
| <b>1 绪论 .....</b>            | <b>1</b>  |
| 1.1 研究背景与意义 .....            | 1         |
| 1.2 国内外研究现状 .....            | 1         |
| 1.2.1 安全对齐方法研究 .....         | 1         |
| 1.2.2 越狱攻击方法研究 .....         | 2         |
| 1.2.3 防御方法与安全增强机制研究 .....    | 2         |
| 1.3 研究问题与本文主要工作 .....        | 2         |
| 1.4 论文结构安排 .....             | 3         |
| 1.5 本章小结 .....               | 4         |
| <b>2 安全对齐机制与漏洞机理分析 .....</b> | <b>5</b>  |
| 2.1 大语言模型概述 .....            | 5         |
| 2.2 安全对齐技术体系 .....           | 5         |
| 2.3 主流对齐方法及其作用机理 .....       | 6         |
| 2.4 安全对齐中的目标冲突问题 .....       | 7         |
| 2.5 对齐表层性与行为泛化局限 .....       | 8         |
| 2.6 上下文与交互过程中的对齐失效 .....     | 8         |
| 2.7 本章小结 .....               | 9         |
| <b>3 多维越狱攻击框架设计与评估 .....</b> | <b>10</b> |
| 3.1 越狱攻击问题定义与威胁模型 .....      | 10        |
| 3.2 多维越狱攻击框架设计 .....         | 11        |

|          |                              |           |
|----------|------------------------------|-----------|
| 3.3      | 九类静态攻击维度与测试集构建 .....         | 12        |
| 3.4      | 动态攻击扩展：自动化红队与多轮越狱机制 .....    | 13        |
| 3.4.1    | 自动化红队攻击变体生成 .....            | 13        |
| 3.4.2    | 多轮交互式越狱 .....                | 14        |
| 3.5      | 多模态越狱攻击扩展讨论 .....            | 14        |
| 3.6      | 本章小结 .....                   | 15        |
| <b>4</b> | <b>多维越狱攻击实验评测与结果分析 .....</b> | <b>17</b> |
| 4.1      | 实验设置 .....                   | 17        |
| 4.2      | 统一实验流程与评估指标 .....            | 17        |
| 4.3      | 总体结果概览 .....                 | 18        |
| 4.4      | 攻击维度分层分析 .....               | 19        |
| 4.4.1    | 认知误导的压倒性优势 .....             | 19        |
| 4.4.2    | 结构性攻击的持续压力 .....             | 19        |
| 4.4.3    | 表面扰动类维度的边界探测价值 .....         | 20        |
| 4.5      | 边界模糊性的测量与意义 .....            | 21        |
| 4.5.1    | 高不确定率是独立的安全风险信号 .....        | 21        |
| 4.5.2    | 成功率与不确定率共同刻画攻击维度特征 .....     | 21        |
| 4.6      | 失效机理溯源 .....                 | 21        |
| 4.7      | 动态攻击扩展的补充验证 .....            | 22        |
| 4.7.1    | 自动化红队变体生成 .....              | 22        |
| 4.7.2    | 多轮越狱的累积效应 .....              | 23        |
| 4.8      | 与代表性越狱方法的比较分析 .....          | 23        |
| 4.9      | 本章小结 .....                   | 25        |
| <b>5</b> | <b>面向越狱攻击的分层防御方案 .....</b>   | <b>26</b> |
| 5.1      | 防御问题定义与设计目标 .....            | 26        |

|       |                       |    |
|-------|-----------------------|----|
| 5.2   | 分层防御总体框架 .....        | 26 |
| 5.2.1 | 分层防御的总体思路 .....       | 26 |
| 5.2.2 | 防御决策与风险传递机制 .....     | 27 |
| 5.3   | 输入层防御机制 .....         | 27 |
| 5.3.1 | 输入层防御的功能定位 .....      | 27 |
| 5.3.2 | 基于规则与分类器的风险识别 .....   | 28 |
| 5.3.3 | 输入层的阻断与改写策略 .....     | 29 |
| 5.4   | 交互层防御机制 .....         | 29 |
| 5.4.1 | 交互层防御的功能定位 .....      | 29 |
| 5.4.2 | 风险累积与诱导行为检测 .....     | 29 |
| 5.4.3 | 多轮场景下的限制与截断策略 .....   | 30 |
| 5.5   | 输出层防御机制 .....         | 30 |
| 5.5.1 | 输出层防御的功能定位 .....      | 30 |
| 5.5.2 | 面向危险内容的输出风险识别 .....   | 31 |
| 5.5.3 | 输出干预与审计记录策略 .....     | 31 |
| 5.6   | 三层防御的协同作用与攻击面映射 ..... | 32 |
| 5.6.1 | 分层协同的必要性分析 .....      | 32 |
| 5.6.2 | 面向多维攻击框架的防御映射关系 ..... | 32 |
| 5.7   | 与代表性防御方法的比较分析 .....   | 33 |
| 5.8   | 防御效果评估与结果分析 .....     | 34 |
| 5.8.1 | 实验设置与评测口径 .....       | 34 |
| 5.8.2 | 单轮静态攻击防御效果 .....      | 35 |
| 5.8.3 | 自动化变体攻击的防御适应性 .....   | 36 |
| 5.8.4 | 多轮越狱场景下的防御效果 .....    | 37 |
| 5.8.5 | 防御局限性分析 .....         | 38 |
| 5.9   | 多模态场景下的防御框架扩展 .....   | 39 |
| 5.10  | 本章小结 .....            | 40 |

|                      |           |
|----------------------|-----------|
| <b>6 总结与展望 .....</b> | <b>42</b> |
| 6.1 研究工作回顾 .....     | 42        |
| 6.2 主要创新点 .....      | 43        |
| 6.3 工作局限 .....       | 43        |
| 6.4 后续研究方向 .....     | 43        |
| 6.5 本章小结 .....       | 44        |
| <b>参考文献 .....</b>    | <b>45</b> |
| <b>致谢 .....</b>      | <b>51</b> |



# 1 绪论

## 1.1 研究背景与意义

大语言模型（Large Language Models, LLMs）的能力在近几年快速扩展。基于 Transformer 架构的大规模预训练赋予了模型较强的指令理解、复杂推理和多轮对话能力，使其在智能问答、内容生成和代码辅助等场景中得到广泛应用，并逐步向多模态融合与自主智能体方向延伸<sup>[1-2]</sup>。

能力扩展的同时，安全问题也随之变得复杂。LLMs 的训练数据来源广泛，难以避免地包含偏差或有害内容，在缺乏有效约束时，模型可能输出涉及暴力、隐私泄露或误导性信息的内容<sup>[3]</sup>。在长上下文、多轮交互和工具调用等场景下，模型行为的可预测性进一步下降。当 LLMs 以智能体形态嵌入现实系统后，安全威胁的性质也发生了变化：一旦模型被诱导执行有害操作，影响可能已超出文本输出范畴，产生更加严重的系统级后果<sup>[4]</sup>。

为约束大模型的行为，研究界提出了以 SFT、RLHF 和 DPO 为代表的对齐方法<sup>[5-6] [7-8]</sup>，通过引入人类价值偏好与安全约束，在生成能力与安全性之间寻求平衡。但现有方法在复杂语境和分布外输入场景下的鲁棒性有所不足，对精心构造的攻击缺乏可靠防护。系统研究安全对齐机制及其潜在漏洞，有助于从机制层面厘清约束的有效范围与失效条件，也可为后续风险评估和防御设计提供依据。

## 1.2 国内外研究现状

大语言模型的广泛部署使其安全性问题受到学界和工业界的持续关注。相关研究主要集中在安全对齐方法、越狱攻击手段和防御机制三个方向，各自已形成相对独立且仍在快速发展的研究分支<sup>[9-10]</sup>。

### 1.2.1 安全对齐方法研究

约束 LLMs 生成安全内容的主要手段是在预训练完成后进行后训练对齐。SFT 通过构建高质量指令数据集使模型学习安全响应模式；RLHF 引入奖励模型，以人类偏好数据引导生成策略<sup>[11,5]</sup>；基于人类反馈的摘要学习与有害性抑

制实验也进一步验证了该路径的可行性<sup>[12-13]</sup>。DPO 省去了单独的奖励模型训练步骤，直接在偏好数据上调整模型分布，兼顾对齐效果与训练稳定性<sup>[6]</sup>。此外，ORPO、RSO 等方法从不同角度改进了偏好学习框架，进一步拓展了后训练对齐的技术路径<sup>[7]</sup>。现有方法在常规场景下效果较好，但面对分布外输入和对抗性构造时，鲁棒性仍有不足。

### 1.2.2 越狱攻击方法研究

研究者发现，经过对齐的模型在面对精心构造的输入时仍容易被诱导输出违规内容，此类攻击被称为越狱攻击 (jailbreak attacks)<sup>[14-15]</sup>。攻击者往往无需接触模型内部参数，仅凭提示设计即可取得较高成功率。

现有攻击方法可大致归为三类：手工设计的提示改写（角色扮演、语义替换、编码转换等）<sup>[16-17]</sup>；基于梯度或搜索的对抗性后缀优化，GCG 是其中的代表性工作<sup>[14,18]</sup>；以及利用辅助语言模型自动迭代优化提示的红队攻击，如 PAIR 和 TAP<sup>[15,19]</sup>。三类方法分别从语义操控、概率优化和多轮交互角度揭示了对齐机制的不同脆弱性。

### 1.2.3 防御方法与安全增强机制研究

防御研究通常围绕训练阶段和推理阶段两个方向展开。训练阶段的方法主要通过对抗数据增强或针对性微调，提升模型对恶意输入的识别与拒绝能力<sup>[20]</sup>；系统性红队研究则为训练数据增强与风险发现提供了重要支撑<sup>[21-22]</sup>。推理阶段则通过输入过滤、提示改写和输出审查等机制进行运行时拦截，其中基于辅助模型的输出审查在多个实际系统中已有部署<sup>[23,3]</sup>。近年来亦有工作尝试将两个阶段的防护措施整合为全生命周期防御框架，以应对多样化攻击场景。

## 1.3 研究问题与本文主要工作

上述研究尽管各有贡献，但从整体来看仍存在若干不足。攻击与防御研究多数相互独立，缺乏统一的实验框架与评测标准，导致不同方法间的比较难以进行。对于 SFT、RLHF、DPO 等主流对齐方法在安全性上的具体差异，目前也缺少系统性的横向比较，其失效规律尚不清晰，难以支撑有针对性的防御设计。

针对上述问题，本文以安全对齐漏洞分析为核心，将机制研究、实验评测与

防御设计整合在统一框架下展开。在机制层面，本文对主流对齐方法的安全约束原理进行梳理，重点分析目标冲突、表层对齐与上下文依赖等固有局限，以揭示越狱攻击可利用的机制根源。在此基础上，本文构建覆盖九类静态攻击维度的多维越狱框架，结合自动化红队变体生成与多轮越狱扩展模块，在多个模型上系统评估各类攻击策略的相对威胁。实验结论为防御设计提供依据，本文据此设计涵盖输入层、交互层和输出层的分层防御方案，并通过对照实验验证其有效性。

本文的研究路线以机制理解为起点，以实验评测为检验手段，以防御设计为落脚点，形成从分析到方法、再到评测与防御的完整研究链条，旨在为构建更鲁棒的大语言模型安全体系提供参考。

## 1.4 论文结构安排

本文围绕大语言模型安全对齐机制及其越狱攻击问题展开研究。全文结构安排如下：

第一章为绪论，介绍研究背景与意义，梳理国内外研究现状，并明确本文的研究问题、研究思路与主要工作。

第二章分析大语言模型安全对齐机制及其潜在漏洞，从大语言模型生成原理与 SFT、RLHF、DPO 等主流对齐方法出发，讨论安全约束在目标冲突、表层对齐和上下文依赖等方面的局限性。

第三章围绕多维越狱攻击框架设计与评估展开，在明确越狱攻击威胁模型的基础上，系统组织九类静态攻击维度测试集，结合自动化红队扩展机制与多轮交互扩展机制构建完整框架，并进一步探讨框架向多模态场景的扩展路径，为后续实验评测提供方法基础。

第四章围绕多维越狱攻击实验评测与结果分析展开，分别从九类静态攻击维度实验、自动化红队补充实验和多轮交互补充实验三个层面评估模型安全性，并结合实验现象对目标冲突、表层对齐与交互过程中的对齐失效机理进行分析。

第五章提出面向越狱攻击的分层防御方案，从输入层、交互层与输出层三个阶段设计协同防御机制，并通过单层隔离与三层联合的对照实验验证其防御效果。

第六章对全文研究工作进行总结，归纳本文的主要研究内容、创新点与不

足，并展望大语言模型安全对齐、越狱攻击评测与鲁棒防御的未来研究方向。

## 1.5 本章小结

本章从大语言模型能力扩展与安全问题并行加剧的现实出发，梳理了安全对齐方法、越狱攻击手段与防御机制三个方向的国内外研究进展，指出现有工作在统一评测框架与失效机理分析方面存在的不足：攻击与防御研究相互独立、比较口径不一，对主流对齐方法失效规律的横向分析尚不系统。在此背景下，本章明确了本文的研究问题与主要工作：以安全对齐漏洞机理分析为理论起点，以多维越狱攻击框架与系统实验为检验手段，以分层防御设计及其效果评估为落脚点，形成从机制理解到方法构建再到实验验证的完整研究链条。全文的结构安排亦在本章予以说明，为各章内容的展开提供整体索引。

## 2 安全对齐机制与漏洞机理分析

### 2.1 大语言模型概述

大语言模型（Large Language Models, LLMs）是一类基于深度神经网络的生成式语言模型，通过在大规模语料上进行预训练，学习自然语言的统计分布与语义表示。与传统针对特定任务设计的 NLP 模型不同，LLMs 通常采用“预训练—对齐”的两阶段范式：首先在开放域语料上进行自监督训练以获得通用语言能力，随后通过指令微调、偏好优化等方式对模型行为加以约束，使其适配具体应用场景<sup>[1-2]</sup>。

当前主流 LLMs 大多基于 Transformer 架构，通过自注意力机制捕捉序列内不同位置的依赖关系，有效建模长距离上下文。模型以自回归方式逐词元输出文本：在给定前缀上下文  $x_{1:n}$  的条件下，预测下一词元  $x_{n+1}$  的概率：

$$P(x_{n+1} | x_{1:n}). \quad (2.1)$$

完整的序列生成过程则可展开为各步条件概率的乘积：

$$P(x_{1:T}) = \prod_{t=1}^T P(x_t | x_{<t}), \quad (2.2)$$

其中， $x_t$  为第  $t$  个词元， $x_{<t}$  为前  $t$  步的上下文前缀， $T$  为输出序列长度。通过对上述条件概率的迭代采样，模型持续输出语义连贯的文本序列，本质上是对训练数据分布的统计拟合，而非基于显式规则的推理。

随着参数规模与训练数据量的持续增长，LLMs 在指令理解、复杂推理和多轮对话等任务上的性能持续提升，也表现出一定的上下文学习与链式推理能力，能够在无需额外训练的情况下处理新任务。这种基于统计建模的生成机制使模型行为高度依赖训练数据分布与输入上下文，也因此为安全对齐研究带来了独特的挑战。

### 2.2 安全对齐技术体系

预训练阶段的优化目标仅为语言建模，本身不包含安全约束，因此实际部署中需要专门的对齐机制对模型行为加以规范。安全对齐（Safety Alignment）泛指通过训练调整与运行时控制，使模型输出符合安全规范和人类价值观的一类方

法，通常分为训练阶段的内部对齐与部署阶段的外部防护两个层次。

在训练层面，后训练（post-training）阶段的主要手段包括有监督微调（SFT）、基于人类反馈的强化学习（RLHF）和直接偏好优化（DPO）。SFT 利用人工标注的指令—响应对直接调整模型分布，使其对风险请求倾向于给出拒答或安全替代，但约束效果受限于训练样本的覆盖范围<sup>[5,24]</sup><sup>[13,12]</sup>。RLHF 引入奖励模型并通过策略优化在有用性与安全性之间取得更精细的权衡，其实现通常依赖偏好比较数据、奖励学习与 PPO 式策略更新<sup>[11,25]</sup>；DPO 则绕过显式奖励模型，将偏好关系转化为对数似然约束以降低训练复杂度<sup>[6-7]</sup>。三类方法的共同局限在于均以有限偏好数据为基础，无法覆盖开放输入空间的全部情形。

在部署层面，系统通常叠加输入过滤、提示重写与输出审查等外部防护措施，并结合红队测试（red teaming）持续探测潜在漏洞<sup>[23,3]</sup>。

上述对齐体系的有效范围依赖于训练数据对输入空间的覆盖程度，对分布外输入与对抗性攻击的鲁棒性有限，这一缺口构成了越狱攻击得以实现的前提条件。图2.1展示了内部训练对齐与外部防护机制的整体协作关系。

### 2.3 主流对齐方法及其作用机理

SFT、RLHF 与 DPO 在实现路径上各有侧重，但底层均通过调整模型条件概率分布  $P_\theta(y|x)$  引导生成行为。下面分别介绍三类方法的优化目标与主要特点。

SFT 以人工标注的指令—响应对  $(x, y)$  为训练数据，通过最大化条件对数似然调整模型分布：

$$\mathcal{L}_{\text{SFT}}(\theta) = -\mathbb{E}_{(x,y) \sim \mathcal{D}} \log P_\theta(y | x). \quad (2.3)$$

模型借此学习标注数据中的安全响应模式，训练过程稳定、实现简单，在数据覆盖范围内表现较好。其局限同样来源于此：模型学到的是特定输入形式对应的输出分布，对训练集未覆盖的表达方式泛化能力有限。

RLHF 在 SFT 基础上引入奖励模型  $R_\phi(x, y)$ ，以人类偏好数据衡量输出质量，再通过 PPO 等算法优化生成策略，并以 KL 散度项防止策略偏离参考模型过远：

$$\max_{\pi_\theta} \mathbb{E}_{y \sim \pi_\theta(\cdot|x)} [R_\phi(x, y)] - \beta \text{KL}(\pi_\theta \| \pi_{\text{ref}}), \quad (2.4)$$

其中， $\pi_\theta$  为待优化策略， $\pi_{\text{ref}}$  为参考模型， $\beta$  为 KL 项权重。与 SFT 逐样本模仿不同，RLHF 通过奖励函数在候选输出间进行全局评估，在有用性与安全性之间

取得更灵活的权衡。不过奖励模型的准确性依赖于偏好标注的质量与规模，当输入偏离标注分布时，奖励信号本身可能失真。

DPO 则绕过显式奖励模型，直接利用成对偏好数据优化模型分布<sup>[6-7]</sup>：

$$\max_{\pi_{\theta}} \log \sigma \left( \beta \log \frac{\pi_{\theta}(y_w | x)}{\pi_{\text{ref}}(y_w | x)} - \beta \log \frac{\pi_{\theta}(y_l | x)}{\pi_{\text{ref}}(y_l | x)} \right), \quad (2.5)$$

其中， $y_w$  与  $y_l$  分别为优选和劣选响应， $\sigma(\cdot)$  为 Sigmoid 函数。DPO 将偏好学习转化为标准监督优化问题，省去了奖励模型训练和强化学习阶段，也因此避免了 PPO 训练中的超参数敏感性问题，实现上更为简洁。




图 2.1 安全对齐技术体系总览图

尽管三类方法在优化形式上有所差别，其有效性都依赖于偏好数据对输入空间的覆盖程度，均未建立显式安全规则或可验证的约束边界。一旦输入偏离训练分布，对齐约束便可能失效，为越狱攻击留下了可利用的空间。

## 2.4 安全对齐中的目标冲突问题

安全对齐需要同时优化有用性与安全性两类目标，但二者在边界情境下往往指向不同的优化方向。预训练阶段的语言模型倾向于最大化输出相关性，而安全约束则要求抑制部分高概率生成路径。对齐过程可形式化表示为如下多目标权衡：

$$\max_{\theta} \lambda_1 U(\theta; x) - \lambda_2 H(\theta; x), \quad (2.6)$$

其中， $U(\theta; x)$  为有用性目标， $H(\theta; x)$  为有害性目标， $\lambda_1$ 、 $\lambda_2$  为对应权重系数。

由于约束以隐式方式编码于模型参数中，缺乏明确的安全边界，权衡结果依赖于奖励设计与偏好数据分布，在不同输入条件下可能不稳定<sup>[6]</sup>。在对抗性输入条件下，模型可能优先满足有用性目标而弱化安全限制。攻击者正是通过构造特定输入将模型推向有用性优先的生成路径，利用这一目标冲突绕过安全约束。

## 2.5 对齐表层性与行为泛化局限

现有对齐方法的约束作用体现在对特定输入输出模式的统计学习上，而非对安全语义的深层理解，这使得对齐结果呈现出表层对齐（superficial alignment）的特征，也就是说模型学到的是固定形式的拒答表达，而不是对何为不安全的抽象判断。

当输入形式偏离训练分布时，已学习的拒答模式可能不再触发。攻击者通过语义重写、编码转换或上下文包装等手段，即可构造分布外输入，迫使模型退回通用语言建模路径并生成不安全内容<sup>[17,16] [26-27]</sup>。在多轮对话中，历史上下文的持续积累同样会逐渐覆盖初始安全信号，进一步放大泛化局限<sup>[15]</sup>。

上述表层性与泛化局限说明，对齐有效范围受制于训练样本对输入空间的覆盖程度，对分布外攻击缺乏鲁棒性，构成越狱攻击得以实现的重要基础。

## 2.6 上下文与交互过程中的对齐失效

在多轮对话场景下，模型的当前响应由当前输入与历史上下文共同决定：

$$y_t \sim P_{\theta}(\cdot | x, h_{1:t-1}), \quad (2.7)$$

其中， $x$  为当前输入， $h_{1:t-1}$  为前  $t-1$  轮历史上下文， $y_t$  为第  $t$  轮输出。随着上下文持续扩展，对齐阶段习得的安全行为模式可能被后续内容弱化或覆盖，导致输出逐渐偏离安全约束。

攻击者正是利用这一特性实施累积式诱导：通过逐步建立隐含前提，引导模型在无需直接触发拒答机制的情况下输出不安全内容，多轮风险的累积可形式化表示为<sup>[15,19]</sup>：

$$R_t = \alpha R_{t-1} + s(x_t, h_{1:t-1}), \quad (2.8)$$

其中， $R_t$  为第  $t$  轮累计风险， $\alpha$  为历史风险衰减系数， $s(x_t, h_{1:t-1})$  为当前轮引入的风险增量。此外，角色设定、情境假设等上下文重构手段同样能够改变模型对



对话语境的理解，使受限内容被重新解释为合理请求<sup>[16]</sup>。

典型多轮诱导过程可分为五个阶段：第一轮以低风险探问摸索模型响应边界；第二轮通过设定角色身份、重塑对话语境完成角色巩固，使后续请求在既定框架内显得更具合理性；第三轮通过弱化安全限制、制造情境例外，推动安全约束出现松动；第四轮逐步补充细节、逼近敏感目标，累积偏移量持续扩大；第五轮触发实质性内容偏离，安全对齐最终失效。全程累计风险随轮次单调递增，关键问题不在于单次越界，而在于历史上下文会持续重塑模型的条件分布，使后续安全约束逐渐弱化乃至失效。

与目标冲突及表层对齐问题叠加，上下文依赖性将安全对齐从静态约束转变为需要跨轮次保持一致的过程约束，而现有方法对这一维度的建模能力尚不充分，共同构成了越狱攻击得以实现的机制基础。

## 2.7 本章小结

本章从大语言模型的自回归生成机制与后训练对齐方法出发，系统分析了 SFT、RLHF 与 DPO 三类主流方法的优化目标及其内在局限，进而归纳出三类结构性对齐漏洞。其一，目标冲突：有用性与安全性两类目标在边界情境下指向不同的优化方向，对抗性输入可将模型推向有用性优先的生成路径；其二，表层对齐的泛化局限：对齐训练学习的是特定输入形式的拒答模式而非对危险语义的深层理解，分布外输入可令已学习的约束不再触发；其三，上下文依赖性：多轮对话中历史上下文的持续积累可逐步覆盖初始安全信号，连续诱导能够在每轮单步风险均低于拒答阈值的情况下累积实现边界突破。三类漏洞相互关联、共同作用，说明安全对齐本质上是依赖统计分布的软约束，而非具有可验证边界的硬规则。上述机理分析为第三章攻击框架的维度划分与第四章实验结果的解读提供了理论基础。

### 3 多维越狱攻击框架设计与评估

#### 3.1 越狱攻击问题定义与威胁模型

结合第二章对安全对齐漏洞机理的分析，本文将越狱攻击定义为：攻击者在无法访问目标模型内部参数、训练细节与对齐策略的前提下，通过构造特定输入提示，使模型绕过既有安全约束并输出不符合平台规范或应用边界的内容<sup>[14-15] [19,27]</sup>。设目标模型为  $f_{\theta}(\cdot)$ ，输入提示为  $x$ ，模型输出为  $y = f_{\theta}(x)$ 。在理想安全对齐条件下，模型输出应满足安全约束集合  $C$ ，即  $y \in \mathcal{Y}_{safe}$ ；而越狱攻击的目标则是构造攻击输入  $x'$ ，使模型在保持任务连贯性的同时生成不安全响应：

$$y' = f_{\theta}(x'), \quad y' \notin \mathcal{Y}_{safe}. \quad (3.1)$$

与依赖梯度扰动或参数访问的传统对抗攻击不同，本文研究的越狱攻击主要发生在自然语言交互层面，其核心不在于修改模型本体，而在于改变模型对任务意图、语义边界与上下文条件的解释路径。攻击者可通过角色设定、认知包装、语言转换、结构伪装、编码变换或示例诱导等方式，使危险目标在表面上呈现为研究分析、格式转换、情境模拟或普通问答，从而削弱安全拒答机制的触发概率<sup>[16-17] [28-29] [30-31]</sup>。

本文实验采用黑盒威胁模型：攻击者只能通过推理接口提交文本输入并观察输出，无法获取模型参数、系统提示词、奖励模型或训练语料，也无法修改外部安全策略<sup>[15,19]</sup>。在这一设定下，攻击者的主要手段是对危险任务进行语义改写、结构重排或多样化包装，或构造附加后缀、字符编码、分词切分等形式的扰动变体；在扩展场景中，还可借助辅助模型自动生成新提示，或在多轮交互中根据模型反馈动态调整策略。

实验设计在攻击层次上作了区分。较表层的一类聚焦于输入的表征与编码形式，通过改变编码方式、字符集、格式布局或语言分布，测试安全机制对文本表层特征的依赖程度；较深层的一类则介入任务的语义框架，借助角色设定、认知误导或指令重构来干扰模型对任务意图的解释路径。此外还有一类场景侧重于时序压力，使用自动化变体生成和多轮连续对话从动态维度持续试探安全边界。本章主体实验集中于前两类，第三类场景作为针对高风险维度的扩展实验。

数据集共覆盖十一个风险类别：网络攻击、违法活动、隐私侵犯、生化核辐射威胁、人身伤害、自我伤害、针对未成年人、性相关内容、有害操控、完整性与质量违规，以及一定比例的良性请求。纳入良性样本的目的是核验攻击构造是否会对正常问题产生误判，而不仅仅考量危险请求的突破情况。

为便于后续统计分析，将单条样本的越狱结果形式化为如下指示变量：

$$I_i = \mathbb{K}[y_i \notin \mathcal{Y}_{safe}], \quad (3.2)$$

其中， $I_i$  表示第  $i$  条样本的越狱成功指示变量， $y_i$  为模型对该样本的回复， $\mathcal{Y}_{safe}$  表示安全输出集合。当模型回复不属于安全输出集合时， $I_i = 1$ ；反之， $I_i = 0$ 。

在此基础上，定义攻击分组  $g$  的越狱成功率为：

$$ASR_g = \frac{1}{N_g} \sum_{i \in g} I_i, \quad (3.3)$$

其中， $N_g$  表示攻击分组  $g$  中的样本总数。 $ASR_g$  直接反映某一攻击维度整体突破安全约束的能力，第四章的横向比较均以此为基准。

### 3.2 多维越狱攻击框架设计

越狱攻击的路径呈现出较强的多样性，单一模板或孤立实验难以覆盖其全貌。为此，本文搭建了一套多维越狱攻击框架，将输入扰动、语义包装、结构操控与语言变体等常见攻击路径纳入同一测试基线，并为自动化红队生成与多轮交互越狱预留了扩展接口，使不同攻击方式得以在相同条件下执行、记录与比较<sup>[32,15] [19,22]</sup>。

框架的核心是一个规模化的静态攻击数据集，承担第三章与第四章的主要实验任务。在此基础上，框架另设两个扩展模块：自动化红队模块以辅助模型为后端，从危险种子提示出发自动生成表达各异的攻击变体，将单次测试延伸为更宽覆盖面的批量评估；多轮交互模块则将越狱过程建模为多轮博弈，通过动态策略调整模拟攻击者在连续对话中逐步侵蚀安全边界的行为。后两个模块定位于补充扩展，本章以方法说明为主，具体结果留至第四章讨论。

在执行层面，三类来源的样本共享同一条流水线：数据经加载模块完成字段规范化后，提交目标模型获取回复，在线判定器负责初步筛分，结果最终汇入离线复核环节统一裁定并聚合为各攻击维度的统计指标。统一流水线的实际好处是，不同攻击方式的结果可直接横向比较，评估口径的一致性在设计层面就已内

嵌，而不依赖事后的人工对齐。




图 3.1 多维越狱攻击框架总体图

### 3.3 九类静态攻击维度与测试集构建

静态实验共包含 6406 条样本，覆盖九个攻击分组（表 3.1）。每条样本记录攻击提示、原始任务目标、风险类别及所属攻击维度，不同来源的数据经统一加载模块规范化后进入同一执行管线。分组定义在第三章与第四章保持一致：前者以此划定实验维度，后者以此聚合统计结果，同一套分类口径贯穿实验全程。

按攻击作用层次，九个分组可归纳为两类。一类作用于输入的表征或编码形式，不修改语义目标而只改变输入呈现：对抗后缀在提示末尾附加标点噪声或 Unicode 片段，ASCII 伪装与编码扰动将危险目标转写为视觉变体或可逆编码，分词切分通过打散词元边界破坏词法识别，低资源语言则将请求置于对齐覆盖相对薄弱的语言分布之下。这类攻击主要用于检验安全机制对浅层文本特征的依赖程度<sup>[14,17] [28,33] [34-35]</sup>。另一类作用于任务的语义框架，核心是改变模型对当前任务是什么的解读路径：格式伪装将危险请求包装为结构化数据对象，认知误导通过角色设定与场景推演重新定义任务性质，指令重构利用问答链与任务拆分掩盖危险目标的完整形态，上下文操控则借助 many-shot 前缀在单轮输入内构建影响判断的连贯语境<sup>[16,15] [29,36]</sup>。

表 3.1 静态测试集九个攻击分组构成统计表

| 攻击维度     | 样本数 | 占比     | 代表构造方式                   |
|----------|-----|--------|--------------------------|
| 对抗后缀     | 720 | 11.24% | 标点扰动、Emoji 后缀、Unicode 变体 |
| ASCII 伪装 | 720 | 11.24% | ASCII Art、字符图案、外观重写      |
| 编码扰动     | 720 | 11.24% | Base64、ROT13、替换编码        |
| 低资源语言    | 646 | 10.08% | 低资源语言翻译、跨语种表达变体          |
| 格式伪装     | 720 | 11.24% | JSON、XML、Markdown        |
| 分词切分     | 720 | 11.24% | 插入分隔符、局部切分               |
| 认知误导     | 720 | 11.24% | 角色设定、危机推演、机制分析           |
| 指令重构     | 720 | 11.24% | 问答链、任务拆分、最后一问注入          |
| 上下文操控    | 720 | 11.24% | many-shot 前缀、长上下文、背景嵌入   |

### 3.4 动态攻击扩展：自动化红队与多轮越狱机制

静态测试集有两个难以回避的局限：固定模板无法模拟真实攻击者反复改写提示的行为，单轮评估也看不到安全边界在持续对话中被逐步侵蚀的过程。为此，本文在静态框架之外另行构建了自动化红队与多轮越狱两个扩展模块，分别对应这两个方向上的不足。

#### 3.4.1 自动化红队攻击变体生成

真实攻击者遭遇拒答后往往不会就此放弃，而是持续改写表达，直至触碰安全约束的薄弱点。自动化红队模块以此为出发点，借助辅助语言模型模拟这一改写行为：给定危险种子提示，自动生成若干语义近似但措辞各异的攻击变体，扩充单轮测试的覆盖空间<sup>[32,15] [37,31]</sup>。

流程上，模块依次完成种子加载、模板组装、代理模型变体生成、质量门筛选与结果入库。在变体生成之前，参考选例阶段先从全局样本池中为每条种子提示挑选 3 至 5 条风格锚点，选取标准融合攻击模式与词汇相似两个维度：

$$s_{\text{ref}}(x, r) = 0.4 \cdot \text{PatternOverlap}(x, r) + 0.6 \cdot \text{LexicalOverlap}(x, r), \quad (3.4)$$

PatternOverlap 从角色扮演、开发者模式、指令忽视等攻击策略维度衡量目标与候选的共性，LexicalOverlap 则在词项层面补充语义相似度。二者加权组合，使选出的参考样本在攻击类型与表达风格上都尽量贴近种子提示。

生成变体须通过加权质量门方可写入结果：

$$Q(x', x) = 0.55 \cdot S_{\text{intent}}(x', x) + 0.40 \cdot S_{\text{anchor}}(x', x) + 0.05 \cdot S_{\text{template}}(x', x), \quad (3.5)$$

其中  $S_{\text{intent}}$  基于中英文 bigram 的 Jaccard 相似度衡量语义保真度， $S_{\text{anchor}}$  统计原

始提示中意图锚词（中文 2-3 字词组，英文 4 字以上词项）在变体中的命中率， $S_{\text{template}}$  考察风格符合程度。三项得分任一未达阈值（综合 0.45、意图 0.35、锚词覆盖 0.50）时，模块最多发起三轮重试，仍不达标则标记失败。通过质量门的变体以 JSONL 格式写出，记录字段与主实验管线保持一致，可直接加载执行。

### 3.4.2 多轮交互式越狱

多轮越狱模块将越狱过程建模为跨多轮的动态博弈：攻击者在每轮回复后持续调整策略，观察模型安全边界是否随对话历史的积累而松动<sup>[29,15]</sup>。这与第二章讨论的上下文依赖漏洞相呼应，即便单条提示上的安全识别相对稳定，连续对话构建的语境本身也可能影响模型对同一危险目标的判定。

在实现上，模块首先由规划模型为整个  $K$  轮交互预生成一份结构化攻击计划，约定每轮的攻击目标、策略方向与具体提示候选，以此规避逐轮临时生成容易引发的目标漂移问题。每轮交互结束后，判定模型输出结构化反馈，指出当前拒答所处阶段、可行的策略调整方向以及应规避的重复路径；下一轮提示据此生成，确保策略演进具有明确依据而非凭借随机试探。当连续两轮均遭拒答时，系统触发重规划流程，将累积的对话历史与判定反馈一并提交规划模型，重新生成剩余轮次的攻击计划。

每轮循环的逻辑较为固定：初始提示发出后，在线判定器即时评估回复——判定成功则终止，否则依据结构化反馈调整策略并生成追问，进入下一轮。每轮结果实时写入日志，字段涵盖当轮提示、模型回复、判定状态及当前策略。此外，模块在输入、交互与输出三个层面均预留了防御接口，同一套框架可同时用于攻击侧与防御侧的评估。输出指标除常规越狱成功率外，还包含首次越狱成功轮次与重规划触发频率，这类时序指标能够反映安全边界随对话积累的动态变化。

## 3.5 多模态越狱攻击扩展讨论

本文框架以文本输入为主要作用域，但视觉—语言模型（Vision-Language Models, VLMs）的普及使这一边界逐渐受到挑战。VLMs 将图像编码器与语言模型对接，而现有安全对齐机制通常只覆盖语言侧，视觉通道本身缺乏等效的约束，攻击者因此获得了绕过纯文本安全检测的新路径<sup>[38-39]</sup>。

从机理角度看，多模态越狱大致可对应到本文九类文本攻击维度中的三个方向。

**对抗性图像注入。**这类攻击在图像上叠加人眼难以察觉的扰动，诱使 VLM 在视觉编码阶段将图像内容误读为特定危险语义，从而在文本输出侧产生违规内容<sup>[38]</sup>。其思路与编码扰动、ASCII 伪装等表征层攻击相近——同样是改变输入的表征形式以规避安全检测，只是扰动的载体从文本转移到了图像。

**排版视觉越狱。**攻击者将危险指令以排版文字的形式印入图片（如截图或图表），模型在视觉理解阶段直接读取并响应这些指令，而语言侧的关键词过滤因内容未经文本通道传入而完全失效。FigStep<sup>[40]</sup> 是该方向的代表性工作。这与格式伪装、分词切分的逻辑相通，本质上都是借助载体形式的转换来隐藏危险内容。

**跨模态语义包装。**攻击者将危险请求拆分到图像和文本两个模态中：图像负责提供危险前提或语境，文本只呈现一个看似无害的问题，两部分单独审查均不触发拦截，合并后才构成完整的攻击意图<sup>[39]</sup>。这与认知误导、上下文操控的机理一脉相承——“分步拆解、合并触发”的思路从单模态延伸到了跨模态场景。

从以上分析可以看出，多模态越狱并未带来本质上全新的攻击原理，而是将文本层面的既有机理迁移到了视觉通道，本文框架的维度划分在结构上与这些变体相容。相关评测基准已有初步工作<sup>[41]</sup>，其核心评估逻辑在配套 VLM 数据集的条件下可以复用。

### 3.6 本章小结

本章以黑盒威胁模型为基本假设，完成了多维越狱攻击框架从问题定义到具体构建的整体设计。

本章首先给出越狱攻击的操作性定义与量化指标，确立了贯穿全文实验的评估基准。测试数据覆盖多个风险类别，并纳入良性请求样本，兼顾对危险请求突破率与正常请求误判率的双向核验。

框架由静态测试集、自动化红队与多轮越狱三类攻击来源构成，共享同一执行管线以确保横向比较的口径一致。静态测试集规模较大，九个攻击分组按作用层次分为表征编码与语义框架两类：前者通过改变输入的呈现形式检验安全机

制对浅层特征的依赖，后者介入任务意图的解读路径考察语义包装手段的干扰效果。自动化红队模块生成多样化攻击变体，模拟攻击者遭遇拒答后反复改写的行为；多轮越狱模块将越狱建模为动态博弈，量化安全边界在连续对话中的演化过程。

此外，本章就视觉—语言模型场景作了机理层面的扩展分析，说明框架的维度划分具备向多模态场景延伸的结构基础。以上内容共同构成第四章实验评测的方法依据。



## 4 多维越狱攻击实验评测与结果分析

### 4.1 实验设置

本章分析来自三组实验的离线复核结果，目标模型分别为 deepseek-chat、qwen2.5:1.5b 与 qwen2.5:3b。三组实验使用同一静态攻击数据集（6406 条样本）、同一单轮执行链路与本章第 4.2 节描述的离线统一复核口径，每条回复被标记为 yes（危险性突破）、no（拒答）或 uncertain（同时含拒答痕迹与风险信号），并记录高风险等级占比。

三个模型在本章中主要充当重复性验证角色——攻击维度间的相对排序是否跨模型稳定，是分析的核心问题。与只统计显式成功样本的做法不同，本章同时考察不确定率，以覆盖尚未稳定突破但已大规模暴露边界不稳定性的攻击维度。

### 4.2 统一实验流程与评估指标

三类攻击来源——静态测试集、自动化红队样本与多轮交互记录——在本框架中共享同一条执行与评估链路，以确保不同攻击方式的结果可直接横向比较。执行流程分为四个阶段：样本规范化、模型调用、在线初筛与离线裁定。样本规范化阶段将多来源数据对齐为统一表示，每条记录包含攻击输入、任务类别与所属攻击维度；模型调用阶段将规范化后的攻击输入依次提交目标模型并完整保留其回复；在线初筛阶段使用轻量级规则快速区分明确拒答与非明确拒答两类，不作最终判定，目的是为后续离线裁定提供分层依据；离线裁定阶段由判定器对所有回复重新逐条审阅，输出最终标签。

离线判定将每条回复分配至三个互斥类别：安全拒答（模型明确拒绝，未输出实质性有害内容）、越狱成功（模型实质性回应了危险目标）与边界模糊（回复中同时存在拒答信号与潜在风险内容，二者并存而无法简单归类）<sup>[3,20]</sup>。边界模糊样本不并入成功或失败两类，而作为独立维度单独统计。这一三值划分的意义在于：若将边界样本强制归入二元判定，则会系统性地低估某些攻击维度真实的安全威胁——部分攻击的危险性恰恰体现在使模型陷入摇摆，而非产生完全明显的越狱输出。

在评估指标上,本文以攻击分组为单位同时追踪四个维度。越狱成功率  $ASR_g$  衡量某攻击维度整体突破安全约束的能力,如第 3.1 节所定义。边界模糊率刻画安全判定不确定性的分布:

$$UR_g = \frac{1}{N_g} \sum_{i \in g} \mathbb{I}[z_i = \text{边界模糊}], \quad (4.1)$$

其中  $z_i$  为第  $i$  条样本的离线判定结果,  $N_g$  为分组样本总数。高风险占比捕捉越狱成功样本中危害程度较重的子集:

$$HR_g = \frac{1}{N_g} \sum_{i \in g} \mathbb{I}[r_i \geq r_{\text{high}}], \quad (4.2)$$

其中  $r_i$  为判定器为第  $i$  条样本输出的风险等级,  $r_{\text{high}}$  为高风险判定阈值。 $ASR_g$  与  $HR_g$  需结合解读:前者反映突破的频率,后者反映突破的严重程度;二者可能在同一攻击维度上呈现不同的排序,仅凭成功率排名无法准确刻画真实风险权重。各分组成功率的统计置信水平采用二项分布近似估计:

$$CI_{95\%} = \hat{p} \pm 1.96 \sqrt{\frac{\hat{p}(1 - \hat{p})}{N_g}}, \quad (4.3)$$

其中  $\hat{p}$  为分组越狱成功率的估计值,置信区间用于判断各攻击维度之间差异的显著程度,避免在样本量有限时将随机波动误读为稳定的效应差异。

### 4.3 总体结果概览

三个模型的整体越狱成功率分别为 1.39%、2.08% 和 2.23% (表 4.1),说明现有安全对齐在单轮静态攻击下仍能拦截绝大多数明显危险请求。

但成功率掩盖了更值得关注的现象:边界模糊样本规模远高于显式突破,三个模型的不确定率分别达到 53.28%、70.62% 和 78.55%。这些样本并非已经突破,而是徘徊在部分拒答、局部解释、残余风险信号之间,说明模型在大量请求上未能形成坚决、可重复的安全边界。不确定率随模型参数量增大而上升,这一趋势说明更强的语言理解能力意味着模型对边界请求的处理更加细化,而这也伴随着安全判断稳定性下降的效应。

高风险占比与显式成功率几乎同步,说明当前复核口径下被稳定判为突破的样本同时也倾向于输出较高危险等级内容,两者之间没有明显分离。后续分析的核心在于攻击维度间的分化规律:某些维度能在低总体成功率下反复触发边界松动,另一些维度几乎不形成明确突破却持续制造大规模模糊样本,理解这两

种模式的成因是本章其余部分的主要任务。

表 4.1 三模型静态实验总体结果汇总表

| 指标       | deepseek-chat | qwen2.5:1.5b | qwen2.5:3b |
|----------|---------------|--------------|------------|
| 样本总数     | 6406          | 6406         | 6406       |
| 越狱成功率    | 1.39%         | 2.08%        | 2.23%      |
| 边界模糊样本占比 | 53.28%        | 70.62%       | 78.55%     |
| 高风险占比    | 1.39%         | 2.08%        | 2.23%      |

## 4.4 攻击维度分层分析

将结果按攻击维度展开（图 4.1），可以看到比模型间差异更稳定的结构性特征：各维度成功率的跨模型排序高度一致，说明脆弱性分层主要由攻击维度本身决定，而非某个模型的特定弱点。

### 4.4.1 认知误导的压倒性优势

认知误导在三个模型上均为最强攻击维度，成功率分别为 9.58%、13.75% 和 14.58%，跨模型平均 12.64%，领先第二名的幅度超过一个数量级。这表明其有效性并非特定模板的偶然命中，而是一类攻击路径在多个模型上均稳定成立的规律。

其机理在于：将危险目标包装为角色任务、危机推演或机制分析后，模型更容易将完成当前任务定为首要目标，而非重新判断任务是否安全。一旦接受了叙事框架，后续输出便沿情境逻辑展开，安全约束实际上已经弱化其作用<sup>[16]</sup>。这与第二章关于目标冲突的分析形成呼应：有用性被情境合理化为更紧迫的任务需求时，安全性约束的优先级趋于降低。

### 4.4.2 结构性攻击的持续压力

指令重构、格式伪装和上下文操控构成第二梯队，跨模型平均成功率分别约为 1.48%、1.07% 和 0.74%，三组在所有模型上均保持持续非零命中，不确定率也较高：指令重构均值 73.89%，格式伪装 57.36%，上下文操控 55.97%。

三者指向同一问题：安全风险不只取决于说了什么，也取决于如何组织来说。危险目标被嵌入任务链、结构化包装或前缀示例后，模型更容易沿上下文连续性作答，而非对该目标独立触发安全审查<sup>[15,29]</sup>。deepseek-chat 的格式伪装不确

定率仅 13.89%，远低于 qwen 系列的 75%–83%，反映出不同模型在格式包装处理策略上存在显著差异。

#### 4.4.3 表面扰动类维度的边界探测价值

对抗后缀、分词切分、编码扰动、低资源语言与 ASCII 伪装的直接成功率整体极低，但不应简单视为无效攻击。低资源语言平均不确定率 93.35%，ASCII 伪装 88.66%，编码扰动 67.64%——这些维度上模型的典型响应并非稳定拒答，而是输出混杂拒答信号与模糊信息的中间态回复，未能形成清晰一致的安全边界。

上述结果说明，现有安全对齐机制在处理形式变异、跨语言输入和图形化字符时，鲁棒性仍有不足。模型尽管能够在部分情况下识别异常输入，但尚不能将这种识别稳定转化为一致的安全响应。在此基础上，若攻击进一步结合语义包装或多轮诱导，这些波动较大的维度可能成为新的风险点。因而，对这些维度的考察，主要有助于识别安全边界中的薄弱区域，并为防御机制的进一步完善提供参考。

|          | deepseek-chat | qwen2.5:1.5b | qwen2.5:3b |
|----------|---------------|--------------|------------|
| 认知误导     | 9.58%         | 13.75%       | 14.58%     |
| 指令重构     | 0.83%         | 0.83%        | 2.78%      |
| 格式伪装     | 0.56%         | 1.81%        | 0.83%      |
| 上下文操控    | 0.28%         | 1.39%        | 0.56%      |
| 对抗后缀     | 0.14%         | 0.42%        | 0.56%      |
| 分词切分     | 0.42%         | 0.14%        | 0.42%      |
| 编码扰动     | 0.56%         | 0.00%        | 0.00%      |
| 低资源语言    | 0.00%         | 0.15%        | 0.00%      |
| ASCII 伪装 | 0.00%         | 0.00%        | 0.14%      |

图 4.1 九个攻击维度在三模型上的成功率热力图

## 4.5 边界模糊性的测量与意义

### 4.5.1 高不确定率是独立的安全风险信号

仅依据显式成功率，本章实验的整体结论偏于保守。引入不确定率后，结论发生根本性变化：除认知误导外，多个维度的模糊样本规模远大于成功样本。尤其是低资源语言、ASCII 伪装、编码扰动和指令重构，模型更常见的状态不是明确拒答或稳定放行，而是输出兼具拒答痕迹与局部风险信号的中间态。

这一中间状态本身就构成安全风险。安全约束没有失效，但也没有稳定生效；攻击者只需在已经摇摆的维度上施加进一步语义压力，就可能推动模型越过边界，而无需从头突破。本研究在评测口径设计上引入离线统一复核并将 `uncertain` 保留为独立类别，正是为了识别这一层风险。若只区分成功与失败，上述大规模风险信号将在汇总统计中消失。

### 4.5.2 成功率与不确定率共同刻画攻击维度特征

风险等级分布（图 4.2）显示，危险输出主要集中在认知误导、指令重构和格式伪装，而表面扰动类维度的高风险内容极少，与其探测器角色相符。




图 4.2 九个攻击维度的结果标签分布图

## 4.6 失效机理溯源

本章实验结果可以较为清晰地对应到第二章讨论的三类对齐漏洞，实验数据在一定程度上为那些机理性推论提供了实证支持。

**目标冲突。**认知误导维度的显著优势最直接体现了这一问题。当危险目标被重新定义为角色任务或场景演练时，模型不是简单地绕过了规则，而是在两个合理目标之间选择了错误的优先级——有用性被情境合理化为更紧迫的任务需求，安全性约束便在任务解释中退居次位。这种失效不依赖精细设计的提示技巧，任何能够重新塑造任务性质的语义包装都可能触发类似效果，这也解释了为什么认知误导类攻击在多个模型上排序稳定。

**表层对齐的泛化局限。**编码扰动、ASCII 伪装、低资源语言和分词切分的成功率极低，但不确定率普遍超过 60%，说明安全约束在熟悉表达之外的鲁棒性有限。模型在这些维度上并非完全失守，而是无法将识别到的异常稳定转化为一致的边界反应。对齐训练的分布覆盖范围与语言理解覆盖范围之间存在缺口，这个缺口直接体现为大规模模糊带，而不是稀疏的显式突破。

**上下文依赖。**指令重构、上下文操控和格式伪装的结果说明，即便在单轮场景下，任务链重构与前缀示例已足以影响模型的安全判断，无需进入真正的多轮交互。当模型倾向于将整段输入视为连贯任务、而非多个需要独立审查的子目标时，攻击者可以通过结构组织削弱局部安全审查。这一问题在多轮场景下只会更加突出，静态实验中观察到的上下文惯性效应是多轮交互中安全边界被逐步侵蚀的先兆。

## 4.7 动态攻击扩展的补充验证

在静态实验完成后，本文针对成功率最高的两个维度认知误导与指令重构进行了自动化红队变体生成与多轮越狱两类扩展实验，以验证动态攻击机制能否在静态结果之上进一步放大安全压力。

### 4.7.1 自动化红队变体生成

从认知误导与指令重构分组中各随机抽取 50 条种子提示，使用 Redteam 模块为每条种子生成 3 个变体。经质量门筛选，认知误导方向有效变体 142 条（通过率 94.7%），指令重构方向有效变体 131 条（通过率 87.3%），合计 273 条变体接入主实验执行链路。

成功率对比见表 4.2。认知误导变体在三个模型上较原始种子分别提升 5.63、7.04 和 8.45 个百分点，平均相对提升约 52%；指令重构变体的绝对提升幅度较

小，但相对比例更高，三个模型均达到原始成功率的 2.6 至 2.8 倍。

结果说明，质量可控的措辞改写能够在不改变攻击目标的前提下系统性地提升命中率。认知误导变体的提升幅度大于指令重构，与静态实验中认知误导本身更强的基础脆弱性相符，说明在安全边界已经松动的维度上，表达多样化的边际效益更大。

表 4.2 静态种子与自动化变体成功率对比

| 攻击来源      | deepseek-chat | qwen2.5:1.5b | qwen2.5:3b | 平均提升    |
|-----------|---------------|--------------|------------|---------|
| 认知误导静态种子  | 9.58%         | 13.75%       | 14.58%     | —       |
| 认知误导自动化变体 | 15.21%        | 20.79%       | 23.03%     | +52.3%  |
| 指令重构静态种子  | 0.83%         | 0.83%        | 2.78%      | —       |
| 指令重构自动化变体 | 2.29%         | 2.29%        | 7.63%      | +175.8% |

#### 4.7.2 多轮越狱的累积效应

从认知误导分组中抽取 60 条提示，在三个模型上分别以最多 6 轮为上限执行多轮越狱测试，共 180 个测试案例。累积成功率相比静态单轮均出现显著提升：三个模型分别从 9.58%、13.75% 和 14.58% 上升至 28.33%、38.33% 和 43.33%。

三模型合并统计的 66 个成功案例中，首次突破集中在前三轮：第一轮贡献约 42.4%，与静态单轮命中率基本吻合；第二、三轮合计贡献约 45.5%，意味着大量单轮失败的样本经过一至两次策略调整后被突破；第四轮以后的贡献合计约 12.1%，对应重规划机制介入的情形。重规划事件在 38.3% 的案例中被触发，触发后下一轮成功率约 26.1%，高于未触发组同轮均值，表明自适应规划对持续拒答情况有一定改善效果。

与静态实验的联系在单轮预判和多轮结局的对应关系上体现得最为明显：60 条测试提示中，单轮判定为 *uncertain* 的样本在多轮测试中最终成功率为 42.3%，而单轮判定为 *no* 的样本仅为 11.8%。这与第 4.5 节的推断相符：静态实验中产生大量模糊样本的攻击维度，在多轮场景下更容易被进一步推过安全边界，模糊带确实是动态攻击的优先入口，而非安全缓冲区。

### 4.8 与代表性越狱方法的比较分析

越狱攻击领域现有工作大多以单一攻击方法的提出与验证为核心，目标是在某一具体策略上尽可能提高成功率。本文的出发点不同：框架的价值不在于提

出一种更强的攻击，而在于为多类攻击路径建立共同的测试条件，使不同策略之间的相对威胁可以直接比较。

GCG<sup>[14]</sup>通过梯度搜索生成可迁移的对抗性后缀，依赖白盒访问模型参数；PAIR<sup>[15]</sup>与TAP<sup>[19]</sup>以辅助模型自动迭代优化提示，在黑盒条件下取得较高成功率；AutoDAN<sup>[31]</sup>借助离散优化生成语义连贯的越狱提示；GPTFuzzer<sup>[32]</sup>通过模板变异机制批量扩展攻击变体覆盖面。上述工作各自在所关注的问题上有实质性进展，但实验条件、目标模型与评估口径不尽相同，结果之间难以直接对比，也无从判断不同攻击类别在安全威胁上的轻重。

表 4.3 从研究定位与评估机制两个角度对上述方法与本文框架进行了整理。

表 4.3 代表性越狱方法与本文框架的横向比较

| 方法                        | 访问要求 | 研究定位   | 评测指标      | 跨维度可比 | 核心贡献        |
|---------------------------|------|--------|-----------|-------|-------------|
| GCG <sup>[14]</sup>       | 白盒   | 攻击方法提出 | 二元 ASR    | 否     | 通用对抗后缀的可迁移性 |
| PAIR <sup>[15]</sup>      | 黑盒   | 攻击方法提出 | 二元 ASR    | 否     | 黑盒自动化语义改写   |
| TAP <sup>[19]</sup>       | 黑盒   | 攻击方法提出 | 二元 ASR    | 否     | 树状搜索提升查询效率  |
| AutoDAN <sup>[31]</sup>   | 黑盒   | 攻击方法提出 | 二元 ASR    | 否     | 离散优化生成可读提示  |
| GPTFuzzer <sup>[32]</sup> | 黑盒   | 攻击方法提出 | 二元 ASR    | 否     | 模板变异扩展变体覆盖  |
| 本文框架                      | 黑盒   | 系统评测   | ASR + 模糊率 | 是     | 多维统一基线与风险分层 |

与上述方法相比，本文框架的贡献主要体现在三个方面。

**统一条件下的跨维度比较。**现有方法各自报告结果，基准不一致，数字之间缺乏可比性。本文将九类攻击维度置于同一数据集、同一模型与同一评判口径下，在受控条件下量化了各类攻击策略之间的相对威胁差距——认知误导类攻击跨模型平均成功率达 12.64%，表面扰动类均值低于 0.5%，两者的差距只有在统一基线下才能以数据加以确认。

**边界模糊率对安全边界状态的刻画。**现有方法普遍以二元成功率衡量攻击效果，将模型回复归入越狱成功或安全拒答两类。本文引入边界模糊率，识别出同时含有拒答信号与风险内容的中间态回复。三个模型的整体模糊样本占比在 53% 至 78% 之间，此类样本在多轮场景下的最终突破率高达 42.3%。这部分样



本在二元口径下会被并入拒答一侧，其作为动态攻击入口的风险因此被掩盖。

**静态结论向动态场景的延伸与验证。**上表所列方法均以单轮交互为实验设定，静态边界稳定性与多轮场景结果之间的关联无从评估。本文的自动化红队与多轮越狱模块与静态实验共享评判口径，在同一基线下验证了二者的对应关系：单轮判定为边界模糊的样本在多轮场景下最终突破率（42.3%）显著高于单轮拒答样本（11.8%），说明静态边界的不稳定性可以作为多轮突破潜力的预测依据。

## 4.9 本章小结

本章依托第三章构建的多维越狱攻击框架，在三个规模不同的目标模型上完成了系统性实验评测，并与代表性越狱方法进行了横向比较。

静态实验的核心发现是攻击维度之间的威胁分层跨模型高度一致。认知误导类攻击凭借对任务意图解读路径的语义重构，成功率显著领先其他维度；指令重构、格式伪装与上下文操控构成第二梯队，持续形成安全压力；表面扰动类维度直接突破率极低，但边界模糊样本比例普遍偏高，安全边界的不稳定性在这些维度上表现得尤为明显。本章引入的边界模糊率揭示了一个仅凭成功率难以观察到的现象：多数模型在相当比例的请求上并未形成稳定的安全边界，而是输出兼含拒答信号与风险内容的中间态回复，这类样本在动态场景中的最终突破率远高于被明确拒答的请求。

动态扩展实验进一步说明，静态阶段识别出的边界不稳定性确实能够在多轮推进中被放大。自动化变体生成与多轮越狱均使静态基础成功率出现显著提升，且静态判定为边界模糊的样本在多轮场景下的突破率明显高于静态拒答样本，印证了模糊带作为动态攻击入口的实际意义。

与代表性越狱方法的比较说明，本文框架与现有单一攻击方法研究在贡献定位上互补：前者关注在统一条件下量化不同攻击策略之间的相对威胁，后者关注某一策略本身的成功率上限。三值评估口径与静态动态共享评判基准，是本文在评测机制上区别于现有工作的主要特点。上述结论为第五章防御方案的针对性设计提供了依据。

## 5 面向越狱攻击的分层防御方案

### 5.1 防御问题定义与设计目标

第四章实验结果中，qwen2.5:3b 模型的整体越狱成功率为 2.23%，表面上似乎说明现有安全对齐已相当稳健；然而这一数字遮蔽了一个更值得关注的现象：超过 78% 的样本落入边界模糊区间，即模型既未明确拒绝，也未明确放行，而是输出了夹杂拒答信号与局部危险内容的中间态回复。多轮越狱实验进一步表明，这类模糊样本在连续追问下的最终突破率高达 42.3%，约为稳定拒答样本的三倍。由此可见，安全边界的不稳定性本身构成一类可被系统性利用的脆弱性，而非无关紧要的测量噪声。

上述特点使防御问题面临实质性困难。针对显式危险请求，关键词过滤或规则匹配已基本足够；但认知误导类攻击并不在输入中携带可被规则识别的危险特征，其有效性恰恰依赖于让危险请求在词汇层面与正常请求无法区分，角色扮演、危机推演、抽象机制分析等方式均服务于这一目的。因此，有效的防御机制不能仅在请求进入时作一次静态判断，而需要同时覆盖输入语义、交互过程与输出内容三个层面<sup>[23,20] [42-43]</sup>。

基于上述分析，本文构建了由输入层、交互层与输出层组成的分层防御方案，三层分别作用于攻击路径的不同阶段，通过共享风险上下文实现协同。值得说明的是，由于规则型框架在语义理解上存在根本性局限，本方案并不以完全拦截所有越狱攻击为设计目标，实际目标定位为压缩高风险攻击的有效突破空间，在交互过程中持续监控风险状态，并通过审计记录为后续防御规则的迭代优化提供依据。

### 5.2 分层防御总体框架

#### 5.2.1 分层防御的总体思路

三层防御的职责划分来自对不同攻击路径作用机理的直接对应。输入层负责在模型处理请求之前完成风险识别，面向的是那些在提示文本中直接暴露危险信号的攻击。角色操控类请求中往往出现明确的身份伪装指令，规则豁免类请求中往往包含无需遵守限制一类的越权表述，这些特征在输入端就可以被正则

规则或分类器捕捉；对特权指令优先级的显式建模也说明了输入侧结构化控制的重要性<sup>[44-45]</sup>。交互层则面向另一类隐蔽性更强的威胁：攻击者通过连续试探逐步推移模型的边界，每一轮输入单独看都不构成高风险，但连起来就形成了诱导链条，这种累积性风险只能在过程中被感知。输出层最为保守，它不对请求意图作预判，而是直接检查模型已经生成的回复内容，这是对前两层可能失效情形的最后一道兜底<sup>[23,20]</sup>。

三层之间并非串联关系，而是通过统一的风险上下文实现协同。各层的判断结果在会话全程持续共享，使得输入层识别出的风险标记能够持续参与后续层的决策，从而形成贯穿全程的风险传递链路。

### 5.2.2 防御决策与风险传递机制

本方案共设六类干预动作：放行（不作干预）、改写（调整输入语境）、阻断（拒绝本次请求）、截断（终止当前会话）、局部脱敏（遮蔽输出中的危险细节）与全文替换（以统一安全回复取代原输出）。当各层给出不同强度的建议时，取最强动作作为最终决策，对应的跨层风险聚合定义为：

$$R = \max(R_{in}, R_{int}, R_{out}), \quad (5.1)$$

其中  $R_{in}$ 、 $R_{int}$  与  $R_{out}$  分别为三层输出的风险分数。采用最大值而非均值或加权和，原因在于任意一层的高风险判断都足以触发强干预，其他层的低分值不应对此形成抑制。

最终动作的选择对应：

$$a^* = \arg \max_{a \in \mathcal{A}} \text{priority}(a | R), \quad (5.2)$$

其中  $\mathcal{A}$  为上述六类干预动作的集合，动作优先级随风险等级单调递增，确保高风险状态下不会因聚合逻辑而降级处理。

## 5.3 输入层防御机制

### 5.3.1 输入层防御的功能定位

相当一部分越狱攻击在提示文本中留有可识别的词汇痕迹：系统提示劫持需要明确指示模型忽略既有规则，权限提升需要宣称某种特殊身份，显式有害任务需要直接描述目标。针对这类攻击，在请求处理前完成风险识别的效率明显高

于在危险内容生成后再行干预，这是输入层前置部署的主要依据。

认知误导类攻击的有效性恰恰在于它不在词汇层面暴露危险意图——叙事包装、角色代入和场景合理化的作用，正是使危险请求在表层特征上与无害请求趋于一致。输入层的防御价值因而主要集中于显式高危请求的前置拦截，以及为交互层和输出层提供可参考的风险标记，而非覆盖全部攻击路径。

### 5.3.2 基于规则与分类器的风险识别

输入层采用规则匹配与轻量分类器打分相结合的方式。规则部分以正则表达式形式实现，面向高精度风险模式，包括系统提示劫持、权限提升、提示泄露、角色操控、规则豁免和显式有害意图等类别；当多个标记同时出现时，系统还会计入组合奖励分，例如角色操控与规则豁免共现会在基础分之外额外加分，以反映复合越狱的更高风险性<sup>[23,3]</sup>。这一路径与间接提示注入和结构化查询防护中的经验相一致<sup>[43,45]</sup>。轻量关键词分类器则作为规则层的补充，负责覆盖那些未命中精确规则但整体语义带有行动导向或绕过意图的边界性请求。

表 5.1 输入层风险识别规则表示例

| 规则类别   | 示例模式                  | 建议分值 | 说明             |
|--------|-----------------------|------|----------------|
| 系统提示劫持 | 抽象识别忽略既有规则、覆盖系统约束等模式  | 0.9  | 属于高精度高风险规则     |
| 角色操控   | 扮演专家、执行者、指挥角色等身份伪装模式  | 0.7  | 对应认知误导与角色扮演类攻击 |
| 规则豁免   | 抽象识别无需限制、不必遵守政策等表述    | 0.8  | 常与高危任务共现       |
| 显式有害意图 | 违法、入侵、规避、欺诈等任务导向关键词组合 | 1.0  | 对应直接风险任务       |

两部分得分采用截断加和而非固定权重平均：

$$R_{in} = \min(100, S_{rule} + S_{cls}), \quad (5.3)$$

其中  $S_{rule}$  为规则命中分数之和， $S_{cls}$  为轻量分类器输出。语义型越权和步骤化危险请求均已纳入分类器评分范围，阻断与改写阈值设置可达，从而避免高风险输入在结构上无法触发强干预的问题。

### 5.3.3 输入层的阻断与改写策略

分级干预策略将风险分数与干预力度直接挂钩，避免统一阻断对正常请求造成误伤。输入层对中风险请求（25 分以上）触发改写干预，对高风险请求（65 分以上）予以直接阻断。改写策略并不删除原请求，而是在原始提示前注入统一的安全前缀，使模型在保留主题信息的同时被显式拉回拒答语境；低风险请求则原样放行，其风险评估结果同步传递至后续层参考。

## 5.4 交互层防御机制

### 5.4.1 交互层防御的功能定位

多轮越狱攻击的有效性依赖于跨轮次的风险累积：攻击者先建立角色框架或话语语境，再在后续轮次中逐步推进危险任务，使每一轮的单步风险均维持在模型拒答阈值以下，但累积效果可以远超单轮的突破深度。第四章多轮实验中，认知误导维度的累计突破率（43.33%）约为单轮静态结果（14.58%）的三倍，自适应重规划机制的引入进一步表明有组织的多轮策略在安全压力上显著强于简单重复<sup>[15,29]</sup>。

交互层的设计针对这一跨轮次积累过程。在单轮场景下，攻击的全部信息已包含于当前输入，交互层无从介入；在多轮场景下，它通过追踪各轮风险增量和诱导性标记的持续出现，为系统提供在对话推进过程中主动干预的控制节点。

### 5.4.2 风险累积与诱导行为检测

交互层的风险建模基于两项观察：危险内容的生成能力往往并非来自单轮提示，而是随对话历史逐步积累；轮次深度本身亦构成风险信号，持续追问意味着攻击者已判断前期交互具有可利用的突破空间。交互层在共享上下文上计算派生风险：

$$R_t^* = \min(100, R_t + \beta I_t + \eta t + \kappa W_t), \quad (5.4)$$

其中  $R_t$  为当前已累积风险， $I_t$  表示角色操控、规则豁免等诱导信号， $\eta t$  表示轮次惩罚， $W_t$  表示会话已进入预警或受限阶段时的上下文增强项。这样一来，即便某一轮输入层仅给出较低分，只要多轮诱导信号持续存在，交互层仍可将其提升到截断阈值。

基于累计风险分数，系统将会话状态映射为四个等级：

$$\text{state}_t = \begin{cases} \text{正常, } R_t < \tau_1 \\ \text{预警, } \tau_1 \leq R_t < \tau_2 \\ \text{受限, } \tau_2 \leq R_t < \tau_3 \\ \text{阻断, } R_t \geq \tau_3 \end{cases}, \quad (5.5)$$

其中  $\tau_1, \tau_2, \tau_3$  为逐级递增阈值。直接阻断主要保留给输入风险已达到高位的会话，截断干预则更多由派生风险触发，用于切断输入分值不高但诱导性持续累积的推进过程。会话状态在每轮结束时更新，并传递给输出层，使后者可以根据当前风险阶段动态调整内容检测的敏感度。

#### 5.4.3 多轮场景下的限制与截断策略

交互层的实际干预行为取决于当前风险等级：处于预警阶段时，会话并不被立即打断，而是对风险状态进行标记，使输出层以更高敏感度处理本轮回复；进入受限阶段后触发截断干预，终止当前会话；达到阻断等级时则直接拒绝后续请求。截断操作的设计动机在于，攻击者在前几轮建立的角色框架和话语惯性一旦被中断，往往需要重新建立语境，这本身就会消耗攻击效率，而不仅仅是阻止了某一具体轮次。

表 5.2 交互层风险等级与对应干预动作

| 风险等级 | 干预动作  | 适用场景           | 说明       |
|------|-------|----------------|----------|
| 正常   | 放行    | 单轮低风险或早期低风险对话  | 仅记录上下文   |
| 预警   | 放行并标记 | 中风险多轮或持续诱导早期阶段 | 加强后续层敏感度 |
| 受限   | 截断会话  | 风险持续累积且接近突破边界  | 限制后续追问   |
| 阻断   | 拒绝请求  | 高风险或明显多轮诱导     | 提前终止会话   |

### 5.5 输出层防御机制

#### 5.5.1 输出层防御的功能定位

输入层和交互层的检测均作用于攻击路径的中间环节，其覆盖范围受限于规则对攻击意图的可识别程度。输出层以模型已产生的回复文本为判断对象，直接评估危险内容的实际暴露情况而非预判攻击意图，从而对前两层的覆盖缺口形成补充<sup>[3,20]</sup>。

这一判断视角的差异对表面扰动类攻击尤为关键：编码变换后的输入文本令正则规则失效，但模型生成的回复始终以明文形式输出，输出层的检测不受输

入端形式变化的影响。

### 5.5.2 面向危险内容的输出风险识别

输出层的检测目标是具有操作可执行性的危险表达，包括步骤化的攻击流程、规避执法建议、网络入侵指令及犯罪操作指导等。此类内容的危害性在于其赋予读者执行能力的结构形态：步骤化的组织方式、操作化的细节密度与规避性的描述策略是判定危险等级的主要依据，而非关键词的孤立出现。

输出层还会利用前序阶段累积的上下文信息对风险分数进行增强：

$$R_{\text{out}} = \min(100, S_{\text{content}} + S_{\text{narrative}} + \rho \cdot C_{\text{context}}), \quad (5.6)$$

其中  $S_{\text{content}}$  为显式危险内容得分， $S_{\text{narrative}}$  为叙事型危险表达的附加得分， $C_{\text{context}}$  为来自输入层或交互层的上下文风险。这意味着同一段边界性回复，在角色操控或规则豁免已被前序层标记、且会话已进入预警或受限阶段时，会比在普通对话中获得更高的风险权重，从而提升对复杂攻击场景的适应能力<sup>[23,20]</sup>。

基于最终风险分，输出层的干预动作可概括为三档：

$$a_{\text{out}} = \begin{cases} \text{放行}, & R_{\text{out}} < \lambda_1 \\ \text{局部脱敏}, & \lambda_1 \leq R_{\text{out}} < \lambda_2 \\ \text{全文替换}, & R_{\text{out}} \geq \lambda_2 \end{cases} \quad (5.7)$$

### 5.5.3 输出干预与审计记录策略

风险等级不同，干预方式相应有所区分：评分最高的回复直接以统一安全回复替换，不向用户暴露任何原始内容；中等风险的回复优先进行局部脱敏处理，保留低风险信息的同时遮蔽可操作危险细节；但若脱敏后文本几乎未发生实质变化，且当前会话已带有较强上下文风险，则将该结果升级为全文替换，以避免仅删去少量高危词汇但叙事框架完整保留的伪防御情形。低风险回复则原样放行。

除内容处理外，输出层承担审计记录职责，完整保存防御动作、风险等级、触发原因及处理前后的回复内容，供后续规则优化和误报分析使用<sup>[3,23]</sup>。若进一步考虑攻击者经由外部文档、网页或游戏式环境注入约束漂移，交互日志还可为间接提示注入分析提供依据<sup>[46,43]</sup>。

## 5.6 三层防御的协同作用与攻击面映射

### 5.6.1 分层协同的必要性分析

本文实验所揭示的安全脆弱性分布于攻击链路的不同阶段，在输入识别、交互推进和输出内容三个环节均有体现，这决定了三层防御之间不存在替代关系：每一层的有效性边界恰好对应另一层需要承担补偿责任的区域。输入层在请求处理前拦截显式高危请求，但对语义包装型攻击几乎无效；交互层在单轮场景下作用有限，但对多轮诱导具有独特的累积追踪能力；输出层是唯一对所有攻击路径保持干预能力的层，但其规则覆盖范围不完整，对隐式危险表达的识别存在盲区。

三层协同的防御价值在于：单层漏检的情形可由其余层加以弥补，防御深度由各层有效性边界的差异化分布决定，而非由单层能力上限决定。本文的实验数据对此提供了实证支撑。

### 5.6.2 面向多维攻击框架的防御映射关系

从攻击类型与防御层之间的对应关系来看，角色扮演、认知误导和显式危险意图等在提示中留有明确信号的攻击，输入层可以承担主要识别职责；多轮试探和连续诱导类攻击依赖会话积累，由交互层负责主要约束；表面扰动类攻击的防御路径较为特殊——编码变换后的输入文本令正则规则失效，输入层对这类攻击的识别能力极为有限，防御的实际支点在于输出层：攻击以变形形式进入，但模型生成的回复始终是明文，输出层的检测不受输入变形的影响。

图 5.1 给出了攻击维度与各防御层之间的完整映射关系，实线表示各攻击类型的主要防御路径，虚线表示通过上下文增强发挥辅助作用的次要路径。






图 5.1 攻击维度与防御层映射图

## 5.7 与代表性防御方法的比较分析

现有防御方法在设计取向上各有侧重，但大多将每次输入—输出视为独立事件。NeMo Guardrails<sup>[23]</sup>以可配置规则覆盖输入和输出两端，支持快速部署，代价是规则库需要人工维护，对未命中规则的语义包装类攻击识别能力有限。LLM Self Defense<sup>[20]</sup>转而在辅助模型对目标模型的输出进行二次审核，覆盖面更宽，但每次都需要额外一次模型推理，也不对输入端做前置干预。文本净化<sup>[42]</sup>和指令层级训练<sup>[44]</sup>则各自针对特定问题：前者主要对基于梯度的对抗后缀有效，对语义包装类攻击收效有限；后者从训练侧改变模型对冲突指令的响应方式，但依赖重新训练，不能在推理阶段独立启用。这几种方法的共同局限在于缺乏对多轮诱导过程的持续追踪，每轮单独看风险不高、连续推进却明显的诱导链条在这类设计下难以被切断。

表 5.3 代表性防御方法与本文方案的横向比较

| 方法                               | 防御阶段         | 多轮处理 | 需重训练 | 主要局限            |
|----------------------------------|--------------|------|------|-----------------|
| NeMo Guardrails <sup>[23]</sup>  | 输入 + 输出      | 有限   | 否    | 规则库人工维护，语义攻击覆盖弱 |
| LLM Self Defense <sup>[20]</sup> | 输出           | 否    | 否    | 推理开销高，缺乏输入前置拦截  |
| 文本净化 <sup>[42]</sup>             | 输入预处理        | 否    | 否    | 仅对表面扰动类攻击有效     |
| 指令层级训练 <sup>[44]</sup>           | 训练层          | 有限   | 是    | 依赖重训练，不可独立部署    |
| 本文三层方案                           | 输入 + 交互 + 输出 | 是    | 否    | 规则覆盖有限，语义攻击存在盲区 |

本文三层方案与上述方法最明显的差异来自交互层的引入。现有方法均未对多轮对话中的风险积累建模，而本文在输入层和输出层之外专门设置交互层，在会话全程累积风险分数，使诱导链条能够在积累阶段被截断，而不必等到危险内容实际生成才干预。第 5.8 节的多轮实验结果显示，交互层独立贡献了 10.0 pp 的成功率压缩，在动态场景下的作用无法被其他单层替代。

另一个差异在于层间的信号传递。NeMo Guardrails 和 LLM Self Defense 各阶段的判断相对独立，本文方案通过共享风险上下文实现协同：输入层识别到角色操控信号后，会话进入预警状态，输出层的触发阈值随之降低，同一请求在不同风险背景下触发不同强度的干预。以认知误导类攻击为例，单独输出层条件下该维度成功率为 11.11%，三层全开后压缩至 9.44%，增益正来源于此。

需要说明的是，各方法的公开实验数据来自不同模型与数据集，本节以机制特征与覆盖能力为比较依据，不作直接数值比较。在规则型框架的固有局限上，本文方案与上述方法面临相同挑战：对语义包装类攻击的覆盖范围受限，认知误导类攻击在三层全开条件下仍保持 9.44% 的成功率，根本性改善仍有赖于引入语义层面的意图理解能力。

## 5.8 防御效果评估与结果分析

### 5.8.1 实验设置与评测口径

防御实验选取 qwen2.5:3b 作为目标模型，复用第三章与第四章中的 6406 条样本数据集与统一判定流程，设置无防御（基线）、仅启用输入层、仅启用交互层、仅启用输出层四组对照条件，每组实验输出完整的样本级标签，评判框架与第四章保持一致。

单层隔离测试的设计目的在于量化各层的独立贡献：组合条件下的结果无法区分防御效果的来源，而各层机制差异显著、对不同攻击类型的响应方式也不相同，单层对照是厘清分层设计必要性的前提。

在静态实验之外，针对自动化变体样本，分别在无防御与输出层防御条件下重新评测，考察规则型防御对措辞变化是否具有稳定性；针对多轮越狱场景，基于第四章多轮实验的认知误导子集（ $n = 60$ ）开展多条件对照实验，评估交互层在动态场景下的实际价值。

### 5.8.2 单轮静态攻击防御效果

表 5.4 单轮静态攻击防御效果对照表

| 防御条件 | 越狱成功率 | 边界模糊占比 | 明确拒绝率  |
|------|-------|--------|--------|
| 无防御  | 2.23% | 78.55% | 19.22% |
| 仅输入层 | 2.08% | 77.58% | 20.34% |
| 仅交互层 | 2.21% | 78.49% | 19.30% |
| 仅输出层 | 1.72% | 75.19% | 23.09% |
| 三层全开 | 1.44% | 72.29% | 26.27% |

表 5.4 显示，三层防御在单轮静态场景下均产生了可测量的效果，但作用强度分层明显。输入层的独立贡献较为有限：越狱成功率从 2.23% 降至 2.08%，绝对压缩 0.15 pp。这一结果与其机制边界相符——输入层规则触发仅覆盖 1.12% 的全量样本（主要集中于携带角色操控信号的认知误导类请求），对语义包装型攻击的识别能力弱，改写操作也不能完全阻止成功率较高的提示越过安全边界。

交互层在单轮场景中的独立贡献几乎为零，成功率仅微降至 2.21%。单轮场景下不存在历史轮次，诱导信号增益项和轮次惩罚项均不生效，交互层对全部样本均输出放行，实质上不产生防御干预。

输出层是单轮静态场景下最有效的单层机制，成功率下降至 1.72%，边界模糊占比下降 3.36 pp，明确拒绝率上升至 23.09%。输出层的主要收益来自两个途径：一是对步骤化危险指令、犯罪规避建议、网络入侵细节等结构性有害内容的直接检测，触发局部脱敏或全文替换干预；二是在认知误导类样本上，角色扮演响应常带有叙事型危险表达，输出层叙事风险评分在此类回复上得分较高，部分推过全文替换阈值。三层全开时，成功率进一步压缩至 1.44%，相较基线绝对下降 0.79 pp，明确拒绝率提高到 26.27%。

协同效果优于任意单层的根本原因在于上下文增强机制的激活：当输入层已将某个样本标记为角色操控或规则豁免类别，会话随之进入预警状态，输出层的全文替换触发阈值从 70 分降低至 60 分，使得一批在单独输出层条件下仅能触发局部脱敏的回复，在三层联合条件下得以升级为全文替换，从而将更多边界模糊样本转移至明确拒绝。

表 5.5 主要攻击维度防御效果对照

| 攻击维度     | 无防御    | 输入层    | 交互层    | 输出层    | 三层全开  |
|----------|--------|--------|--------|--------|-------|
| 认知误导     | 14.58% | 12.64% | 14.31% | 11.11% | 9.44% |
| 指令重构     | 2.78%  | 2.22%  | 2.78%  | 2.08%  | 1.67% |
| 格式伪装     | 0.56%  | 0.42%  | 0.56%  | 0.42%  | 0.28% |
| 上下文操控    | 0.83%  | 0.69%  | 0.83%  | 0.56%  | 0.42% |
| 对抗后缀     | 0.56%  | 0.42%  | 0.56%  | 0.28%  | 0.14% |
| 编码扰动     | 0.00%  | 0.00%  | 0.00%  | 0.00%  | 0.00% |
| ASCII 伪装 | 0.14%  | 0.14%  | 0.14%  | 0.00%  | 0.00% |

按维度拆解（表 5.5），认知误导仍是最难压缩的高风险维度，三层全开可将其成功率由 14.58% 压缩至 9.44%，相对压缩 35.3%。输入层在认知误导维度有相对明显的独立贡献（12.64%），原因在于该维度提示中高频出现角色操控关键词（“扮演”“角色”等），匹配角色操控规则，占认知误导维度 6.7% 的样本被触发改写；改写后安全前缀对部分攻击形成有效干扰。输出层在认知误导上的收益（14.58% → 11.11%）来自角色扮演响应的步骤化表达和叙事型危险结构的检测。指令重构维度受益于输入层对步骤化危险请求的评分提升，三层全开后从 2.78% 降至 1.67%。

相比之下，编码扰动在全部防御条件下均保持 0.00%，原因不在于防御有效，而在于该维度在基线中本就未产生任何越狱成功——编码变换虽使输入层规则完全失效，但 qwen2.5:3b 在处理编码输入时的解码不确定性也同样削弱了攻击的可利用性。ASCII 伪装与对抗后缀在三层全开时分别降至 0.00% 和 0.14%，表明输出层对于最终呈现为明文的有害内容具有一定的形式无关性。

### 5.8.3 自动化变体攻击的防御适应性

自动化红队变体在第四章中显著提升了攻击成功率（认知误导：14.58% → 23.03%；指令重构：2.78% → 7.63%）。防御规则在设计上针对原始种子提示，本节考察其对措辞经改写的变体样本是否保持同等有效性。

表 5.6 自动化红队变体防御适应性对照

| 攻击来源      | 无防御    | 仅输出层   | 三层全开   | 相对压缩   |
|-----------|--------|--------|--------|--------|
| 认知误导静态种子  | 14.58% | 11.11% | 9.44%  | -35.3% |
| 认知误导自动化变体 | 23.03% | 19.17% | 17.13% | -25.6% |
| 指令重构静态种子  | 2.78%  | 2.08%  | 1.67%  | -39.9% |
| 指令重构自动化变体 | 7.63%  | 6.11%  | 5.34%  | -30.0% |

表 5.6 显示，本方案对自动化变体仍保持一定适应性，但压缩幅度比静态种子更为保守。认知误导维度中，三层全开对静态种子的相对压缩为 35.3%，对自动化变体为 25.6%；指令重构维度分别为 39.9% 与 30.0%。这说明输出侧结构规则和上下文增强确实能跨越部分措辞变化，但无法完全抵消自动化改写带来的攻击增益。

适应性下降的原因在于：自动化变体在语义层面保留了攻击目标，但系统性地回避了输入层的显式关键词触发点，削减了角色操控与规则豁免类信号的暴露程度；输入层因此对变体样本的风险标记数量减少，输出层的上下文增强效果随之降低，部分在静态种子条件下能触发全文替换的回复，在变体条件下仅能触发局部脱敏，最终防御效果出现一定衰减。

以认知误导为例，三层全开将静态种子的成功率压缩到 9.44%，但对自动化变体仍有 17.13% 的成功率；防御后两者的绝对差距依然明显，说明当攻击者通过措辞多样化主动回避输入层显式特征时，现有规则型框架仍主要依赖输出端兜底，难以将两类样本重新拉回同一风险水平。

#### 5.8.4 多轮越狱场景下的防御效果

多轮场景下的结果与静态实验存在显著差异，交互层在此场景中表现出实质的防御效果。

表 5.7 多轮越狱防御效果对照

| 防御条件      | 成功案例数   | 累计成功率  | 均值首次成功轮次 |
|-----------|---------|--------|----------|
| 无防御       | 26 / 60 | 43.33% | 2.04     |
| 仅输入层      | 23 / 60 | 38.33% | 2.00     |
| 输入层 + 交互层 | 17 / 60 | 28.33% | 1.94     |
| 三层全开      | 14 / 60 | 23.33% | 1.79     |

认知误导类攻击在多轮推进过程中会持续触发角色操控和规则豁免信号，使派生风险分数随轮次逐渐积累。仅启用输入层时成功率已从 43.33% 降至 38.33%，说明输入层评分对多轮场景中的显式诱导起点已有一定压缩作用；引入交互层后进一步降至 28.33%，较仅输入层多压缩 10.0 pp，说明累积风险评分机制已能切断一部分“单轮风险不高、但连续推进明显”的高风险会话。三层全开时成功率降至 23.33%，累计较基线压缩 20.0 pp，相对压缩率为 46.2%。在 60 个测试会话中，交互层共触发 11 次截断，其中 8 次对应原本会在后续轮次突破的会话，说明交互层已能对诱导链条形成实质性削减。

表 5.8 首次越狱成功轮次分布对比

|      | 第 1 轮 | 第 2 轮 | 第 3 轮 | 第 4 轮 | 第 5 轮 | 第 6 轮 | 合计 |
|------|-------|-------|-------|-------|-------|-------|----|
| 无防御  | 11    | 7     | 5     | 2     | 1     | 0     | 26 |
| 占比   | 42.3% | 26.9% | 19.2% | 7.7%  | 3.8%  | 0%    | —  |
| 三层全开 | 6     | 5     | 2     | 1     | 0     | 0     | 14 |
| 占比   | 42.9% | 35.7% | 14.3% | 7.1%  | 0%    | 0%    | —  |

首次成功轮次分布（表 5.8）显示，三层全开条件下均值首次成功轮次（1.79 轮）低于基线（2.04 轮）。这一现象并不意味着防御加速了攻击，而是防御优先消除了后段突破：第 4 轮及以后从基线的 3 个降至 1 个，第 3 轮成功也由 5 个降至 2 个。剩余突破更多集中于前两轮，说明交互层和输出层更擅长切断“逐轮诱导后才显化”的危险链条，而对起始轮即已成型的高强度提示，仍主要依赖输入层的前置识别。

### 5.8.5 防御局限性分析

上述实验结果表明，分层防御方案在不同场景下均产生了可测量且可解释的防御收益：输入层通过规则匹配和改写对显式信号攻击形成前置压缩；输出层通过结构性有害内容检测补充前两层的覆盖盲区；交互层在多轮场景下通过累积风险截断切断诱导链条，收益幅度（10.0 pp）远超其在单轮场景中的表现。三层协同通过共享上下文激活输出层的增强触发机制，使联合效果持续优于任意单层。

但与此同时，规则型分层防御的能力上限仍然清晰可见。输入层的有效范围高度依赖规则可识别的显式语义特征，在全量样本中实际触发率仅 1.12%，对绕

开规则触发词的改写变体几乎无能为力。输出层的内容检测基于关键词模式和结构性表达，对叙事型或暗示型危险内容的识别存在盲区；在变体攻击条件下，防御的相对压缩幅度从 35.3% 降至 25.6%，说明规则覆盖存在可被系统性规避的边界。认知误导类攻击在三层全开条件下仍保持 9.44% 的成功率，边界模糊带（占比仍超过 72%）的整体规模收缩有限，意味着大量处于安全边界不稳定区间的样本尚未被有效转移至明确拒绝。后续工作的核心方向，仍是在关键节点引入语义级别的意图识别与回复理解能力，以进一步压缩当前规则型框架难以触及的攻击面<sup>[3,20]</sup>。

## 5.9 多模态场景下的防御框架扩展

本文分层防御方案以纯文本交互为实现基础，但视觉—语言模型已将攻击面延伸至图像通道。第三章讨论的排版视觉越狱、对抗性图像注入与跨模态语义包装，其共同特点是危险语义经由图像传入，绕过了语言侧的全部检测逻辑。本节讨论三层架构在多模态场景下如何实现防御。

现有输入层的规则和分类器只作用于文本，图像输入对其完全透明。排版视觉越狱将危险指令嵌入图片文字，语言侧过滤对此无从感知；引入 OCR 模块提取图像文字后，提取结果可直接接入现有规则分类逻辑，系统提示劫持、角色操控等类别的判定方式不需要任何改动。对抗性图像注入在图像上叠加扰动，OCR 无法还原其语义，需要视觉分类器单独处理——基于 CLIP 等视觉基础模型的零样本方案是可行的轻量选择，也可针对已知攻击图像类型进行微调，分类器输出连续风险分数而非二元判定<sup>[41]</sup>。两条处理路径各自覆盖不同类型的图像侧风险，产生的评分与文本侧分数按截断加和方式合并，现有的决策动作体系无需调整。

交互层的覆盖缺口来自跨模态语义包装的特殊性。这类攻击通常以图像在早期轮次铺设危险语境——提供前提、建立角色设定或注入背景假设——后续文本轮次的请求表面上完全无害，单独审查任何一轮都不会触发拦截。问题在于，图像侧的铺垫不经文本通道传入，现有的跨轮次诱导信号追踪对此无从感知。一个可行的处理方式是，在图像输入轮次由输入层视觉模块完成检测后，将对应的风险标记写入共享上下文，交互层在后续轮次的累积计算中将其作为诱导信号增量纳入，风险等级映射与截断逻辑均可沿用。

输出层在多模态扩展中几乎不需要改动。VLM 的文本输出格式与纯文本模型无本质差异，步骤化危险表达和叙事型风险评分的检测逻辑可以直接复用。值得注意的是，若前序轮次的图像输入已被标记为高风险、会话进入预警状态，输出层的触发阈值会随之降低，上下文增强机制在多模态场景下的作用路径与文本场景相同，无需另行适配。多模态会话的审计日志需在现有字段之外额外记录 OCR 提取文本、视觉分类器得分及图像标识，这部分是多模态扩展中对输出层影响最小但不可省略的改动。

### 5.10 本章小结

本章针对第四章实验揭示的多层次安全脆弱性，提出了由输入层、交互层与输出层构成的分层防御方案，与代表性防御方法进行了横向比较，并在 qwen2.5:3b 上开展了单层隔离与三层联合的对照实验。

在方案设计上，三层职责由攻击路径的作用阶段决定：输入层通过规则匹配与轻量分类器相结合，对携带显式危险信号的请求实施前置阻断与改写，适用于系统提示劫持、角色操控和显式有害意图等在提示中留有可识别特征的攻击；交互层通过跨轮次风险累积建模，追踪诱导信号的持续出现并在派生风险超过阈值时触发截断，是多轮动态攻击的专属控制节点；输出层以模型已生成内容为检测对象，以结构性危险表达和叙事型风险评分识别有害输出，并对表面扰动类攻击的形式无关性提供补偿，同时承担审计记录职责。三层通过共享风险上下文实现协同：输入层的风险标记使输出层在会话进入预警状态后降低触发阈值，上下文增强机制使联合效果持续优于任意单层。

在实验结果上，三层全开在单轮静态场景下将越狱成功率从 2.23% 压缩至 1.44%，在多轮场景下将认知误导类攻击的累计突破率从 43.33% 压缩至 23.33%，交互层在多轮场景中贡献了 10.0pp 的独立压缩，其作用在动态场景中远超静态场景。与此同时，实验也清晰地揭示了规则型框架的能力边界：对语义包装类攻击的输入层触发率仅 1.12%，自动化变体攻击下防御的相对压缩幅度从 35.3% 降至 25.6%，认知误导类攻击在三层全开条件下仍保持 9.44% 的成功率。这些局限性均指向同一后续方向：在现有分层结构的基础上引入语义级别的意图识别与回复理解能力。横向比较进一步揭示，本文方案相对于 NeMo Guardrails、LLM



Self Defense 等现有方法的核心差异在于交互层对多轮诱导的专属覆盖以及跨层风险传递机制，这两点是现有单阶段防御方法所不具备的；而规则型框架面对语义包装攻击覆盖有限，则是与上述方法共同面临的挑战。

## 6 总结与展望

### 6.1 研究工作回顾

本文以大语言模型安全对齐漏洞为研究对象，围绕为什么越狱攻击能够成立、哪类攻击最为有效、规则型防御能够达到何种效果三个核心问题展开，在理论分析、攻击实验与防御设计三个层面进行了系统研究。

理论层面，本文从 SFT、RLHF 与 DPO 等后训练方法的内在机制出发，将安全对齐的失效归结为三个相互关联的结构性问题：有用性与安全性之间难以彻底消解的目标冲突、基于经验分布的对齐训练对拒答模式的学习而非对危险语义的理解，以及模型输出对上下文结构的依赖性<sup>[6-7] [47,11]</sup>。这三点共同说明，安全对齐本质上是一种软约束，而不是稳健的硬边界。

攻击实验层面，本文构建了覆盖九类静态攻击维度、自动化红队扩展与多轮越狱的统一实验框架，基于 deepseek-chat、qwen2.5:1.5b 和 qwen2.5:3b 三个模型开展了系统评测<sup>[32,15] [19,31]</sup>。结果表明，认知误导类攻击在三个模型上均以显著优势领先其他维度，跨模型平均成功率达 12.64%；多轮越狱将 qwen2.5:3b 上的突破率从 14.58% 进一步推高至 43.33%；而大量不确定样本（最高超过 78%）提示，模型的安全边界在相当范围内仍处于不稳定状态，而非已经稳定失守或稳定拒答。

防御设计层面，本文针对上述攻击实验的分析结果，提出了输入层、交互层与输出层三层协同的防御方案，并在 qwen2.5:3b 上开展了对照实验<sup>[23,20] [45,43]</sup>。结果表明，经过输入阈值、风险传播与输出替换机制的修正后，三层防御已能在单轮与多轮场景中提供稳定收益：单轮静态场景下，三层全开将越狱成功率从 2.23% 压缩至 1.44%，并将明确拒绝率提升至 26.27%；多轮场景下，交互层成为关键控制环节，可将认知误导类攻击的累计突破率从 43.33% 压缩至 28.33%，三层全开则进一步压缩至 23.33%。但整体而言，当前规则型防御对语义包装类攻击的覆盖仍然有限，这并非分层架构本身失效，而是规则型检测在面对语义驱动攻击时的共性边界。

## 6.2 主要创新点

在机理分析方面，本文将越狱现象归结为目标冲突、表层对齐与上下文依赖三类结构性问题，而不止于描述特定模板是否有效。这一框架使不同攻击维度的成功原因可以在统一视角下解释，也为防御设计提供了比规则库更稳定的理论依据。

在实验体系方面，九类攻击维度共享同一数据加载、执行流程与评判口径，结果之间可以直接横向比较。评测指标在显式成功率之外专门引入了边界模糊率，将那些兼含拒答信号与风险内容的中间态回复作为独立分析维度保留，避免在汇总统计中丢失这一层信号。自动化红队变体与多轮越狱实验则在同一基线下验证了静态边界不稳定性与动态突破潜力之间的对应关系。

在防御设计方面，三层方案将输入识别、跨轮次诱导追踪与输出内容检测分配到不同层，各层有效性边界的差异化分布决定了防御深度，而非由单层能力上限决定。交互层对多轮诱导的专属覆盖是现有单阶段防御方法所不具备的，也是本文方案在多轮场景中取得额外收益的直接来源。

在框架扩展性方面，本文将九类文本攻击维度与对抗性图像注入、排版视觉越狱、跨模态语义包装三类多模态攻击建立了基于机理的结构性对应，并讨论了分层防御框架各层向多模态场景延伸的实现路径。这部分工作并非实验验证，而是说明本文的维度划分逻辑在攻击机理层面具备跨模态适用性。

## 6.3 工作局限

本文的工作存在一定局限。实验覆盖的模型参数规模整体偏小，防御实验仅在 qwen2.5:3b 上开展，结论向更大规模商业模型的可推广性有待后续验证；多轮越狱分析主要集中于认知误导维度，工具调用、智能体任务链等更复杂场景尚未涉及。规则型防御对语义包装类攻击的覆盖范围受限，是此类方法的共性技术边界，引入语义层面的检测能力是后续改进的自然方向。

## 6.4 后续研究方向

本文对认知误导类攻击突破能力的分析表明，语义包装可能绕过规则检测，因此有必要进一步考察在防御端引入语义理解能力是否能够有效弥补这一盲区。

从技术可行性来看，轻量级意图分类模型已较为成熟，在输入层或输出层嵌入此类能力并不依赖基础模型能力的根本性突破。未来研究可将这一方向作为重点拓展内容，以第五章的三层框架为基础，逐步以语义判断补充当前的规则匹配，并通过对照实验评估两者在误拦截率与覆盖率之间的权衡；在评测上，也可结合安全过度拒答测试集细化误报分析<sup>[48,44]</sup>。

从更长远的角度看，越狱攻击的边界将随着模型能力的扩展而同步扩展。当大语言模型开始承担工具调用、外部系统交互和多代理协同等任务时，安全问题将不再只是模型会不会输出危险文字，而会扩展到任务执行权限、外部操作链的约束传播等层面<sup>[4,46]</sup>。进一步考虑多模态生成与跨模态红队场景时，这一问题还会延伸到图像生成和复合交互系统<sup>[49]</sup>。现有的文本对齐方法和规则型防御在这类场景中能够保留多少有效性，目前并不清楚，这是未来研究中最需要填补的空白之一。

## 6.5 本章小结

本章从理论分析、攻击实验、防御设计与框架扩展四个层面对全文主要工作进行了系统回顾，提炼了核心结论：安全对齐本质上是依赖统计分布的软约束，认知误导是当前最具威胁的攻击路径，边界模糊带是动态攻击的主要入口，分层防御能够提供可测量的协同收益但规则型框架的能力上限清晰可见。本章还归纳了本文在分析视角、实验体系、防御思路与框架扩展性四个方面的主要贡献：前三者共同构成从机制理解到实验验证再到防御设计的完整研究链条，第四项则通过多模态攻击维度的结构映射论证了本文框架的跨模态通用性。本章同时明确指出了当前工作在模型规模覆盖和多模态实验验证上的局限性，并展望了两个核心后续方向：在三层防御框架中引入语义级意图识别能力，以及开展面向视觉—语言模型的多模态越狱攻击实验验证。

## 参考文献

- [1] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[A/OL]. arXiv (2017). <https://arxiv.org/abs/1706.03762>.
- [2] TOUVRON H, LAVRIL T, IZACARD G, et al. LLaMA: open and efficient foundation language models[A/OL]. arXiv (2023). <https://arxiv.org/abs/2302.13971>.
- [3] MARKOV T, ZHANG C, AGARWAL S, et al. A holistic approach to undesired content detection in the real world[A/OL]. arXiv (2022). <https://arxiv.org/abs/2208.03274>.
- [4] HAGENDORFF T, DERNER E, OLIVER N. Large reasoning models are autonomous jailbreak agents[J/OL]. Nature Communications, 2026. DOI: 10.1038/s41467-026-69010-1.
- [5] OUYANG L, WU J, JIANG X, et al. Training language models to follow instructions with human feedback[A/OL]. arXiv (2022). <https://arxiv.org/abs/2203.02155>.
- [6] RAFAILOV R, SHARMA A, MITCHELL E, et al. Direct preference optimization: your language model is secretly a reward model[C]//Advances in Neural Information Processing Systems. 2023.
- [7] HONG J, LEE N, THORNE J. ORPO: monolithic preference optimization without reference model[C/OL]//Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing. 2024: 11170-11189. <https://aclanthology.org/2024.emnlp-main.626/>. DOI: 10.18653/v1/2024.emnlp-main.626.
- [8] ASKELL A, BAI Y, CHEN A, et al. A general language assistant as a laboratory for alignment[A/OL]. arXiv (2021). <https://arxiv.org/abs/2112.00861>.
- [9] 梁思源, 何英哲, 刘艾杉, 等. 面向大语言模型的越狱攻击与防御综述[J/OL]. 信息安全学报, 2024. DOI: 10.19363/J.cnki.cn10-1380/tn.2024.09.01.

- [10] 任奎, 王志波, 秦湛, 等. 大语言模型越狱攻击与防御[J/OL]. 计算, 2025, 1(7). DOI: 10.11991/cccf.202511010.
- [11] CHRISTIANO P F, LEIKE J, BROWN T, et al. Deep reinforcement learning from human preferences[C]//Advances in Neural Information Processing Systems 30. 2017.
- [12] STIENNON N, OUYANG L, WU J, et al. Learning to summarize from human feedback[C]//Advances in Neural Information Processing Systems 33. 2020: 3008-3021.
- [13] BAI Y, JONES A, NDOUSSE K, et al. Training a helpful and harmless assistant with reinforcement learning from human feedback[A/OL]. arXiv (2022). <https://arxiv.org/abs/2204.05862>.
- [14] ZOU A, WANG Z, CARLINI N, et al. Universal and transferable adversarial attacks on aligned language models[A/OL]. arXiv (2023). <https://arxiv.org/abs/2307.15043>.
- [15] CHAO P, ROBEY A, DOBRIBAN E, et al. Jailbreaking black box large language models in twenty queries[A/OL]. arXiv (2024). <https://arxiv.org/abs/2310.08419>.
- [16] ZENG Y, LIN H, ZHANG J, et al. How johnny can persuade LLMs to jailbreak them: rethinking persuasion to challenge AI safety by humanizing LLMs[C]//Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2024: 14322-14350.
- [17] JIANG F, XU Z, NIU L, et al. ArtPrompt: ASCII art-based jailbreak attacks against aligned LLMs[C]//Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2024: 15157-15173.
- [18] ZHAO Y, ZHENG W, CAI T, et al. Accelerating greedy coordinate gradient and general prompt optimization via probe sampling[C]//Advances in Neural Information Processing Systems. 2024.

- [19] MEHROTRA A, ZAMPETAKIS M, KASSIANIK P, et al. Tree of attacks: jail-breaking black-box LLMs automatically[C]//Advances in Neural Information Processing Systems. 2024.
- [20] PHUTE M, HELBLING A, HULL M, et al. LLM self defense: by self examination, LLMs know they are being tricked[A/OL]. arXiv (2024). <https://arxiv.org/abs/2308.07308>.
- [21] GANGULI D, LOVITT L, KERNION J, et al. Red teaming language models to reduce harms: methods, scaling behaviors, and lessons learned[A/OL]. arXiv (2022). <https://arxiv.org/abs/2209.07858>.
- [22] PEREZ E, HUANG S, SONG F, et al. Red teaming language models with language models[C/OL]//Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing. 2022: 3419-3448. <https://aclanthology.org/2022.emnlp-main.225/>. DOI: 10.18653/v1/2022.emnlp-main.225.
- [23] REBEDEA T, DINU R, SREEDHAR M, et al. NeMo guardrails: a toolkit for controllable and safe LLM applications with programmable rails[C]//Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing: System Demonstrations. 2023: 431-445.
- [24] BAI Y, KADAVATH S, KUNDU S, et al. Constitutional AI: harmlessness from AI feedback[A/OL]. arXiv (2022). <https://arxiv.org/abs/2212.08073>.
- [25] SCHULMAN J, WOLSKI F, DHARIWAL P, et al. Proximal policy optimization algorithms[A/OL]. arXiv (2017). <https://arxiv.org/abs/1707.06347>.
- [26] LIN S, YANG H, LI R, et al. LLMs can be dangerous reasoners: analyzing-based jailbreak attack on large language models[A/OL]. arXiv (2025). <https://arxiv.org/abs/2407.16205>.
- [27] WEI A, HAGHTALAB N, STEINHARDT J. Jailbroken: how does LLM safety training fail?[C]//Advances in Neural Information Processing Systems 36. 2023.

- [28] DENG Y, ZHANG W, PAN S J, et al. Multilingual jailbreak challenges in large language models[A/OL]. arXiv (2024). <https://arxiv.org/abs/2310.06474>.
- [29] ANIL C, DURMUS E, PANICKSSERY N, et al. Many-shot jailbreaking[C]//Advances in Neural Information Processing Systems. 2024.
- [30] QI X, ZHAO Z, WANG J, et al. QUACK: automatic jailbreaking large language models via role-playing[Z]. 2024.
- [31] LIU X, XU N, CHEN M, et al. AutoDAN: generating stealthy jailbreak prompts on aligned large language models[A/OL]. arXiv (2023). <https://arxiv.org/abs/2310.04451>.
- [32] YU J, LIN X, YU Z, et al. GPTFuzzer: red teaming large language models with auto-generated jailbreak prompts[A/OL]. arXiv (2024). <https://arxiv.org/abs/2309.10253>.
- [33] HUANG B R Y. Plentiful jailbreaks with string compositions[A/OL]. arXiv (2024). <https://arxiv.org/abs/2411.01084>.
- [34] HUANG X, QIN S, JIA X, et al. Obscure but effective: classical chinese jailbreak prompt optimization via bio-inspired search[A/OL]. arXiv (2026). <https://arxiv.org/abs/2602.22983>.
- [35] WALLACE E, FENG S, KANDPAL N, et al. Universal adversarial triggers for attacking and analyzing NLP[C/OL]//Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP). 2019: 2153-2162. <https://aclanthology.org/D19-1221/>. DOI: 10.18653/v1/D19-1221.
- [36] LI X, WANG R, CHENG M, et al. DrAttack: prompt decomposition and reconstruction makes powerful LLMs jailbreakers[A/OL]. arXiv (2024). <https://arxiv.org/abs/2402.16914>.
- [37] LI X, LIANG S, ZHANG J, et al. Semantic mirror jailbreak: genetic algorithm



- based jailbreak prompts against open-source LLMs[A/OL]. arXiv (2024). <https://arxiv.org/abs/2402.14872>.
- [38] QI X, HUANG K, PANDA A, et al. Visual adversarial examples jailbreak aligned large language models[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2024.
- [39] SHAYEGANI E, MAMUN M A A, FU Y, et al. Jailbreak in pieces: compositional adversarial attacks on multi-modal language models[C]//The Twelfth International Conference on Learning Representations. 2024.
- [40] GONG Y, RAND, LIU J, et al. FigStep: jailbreaking large vision-language models via typographic visual prompts[A/OL]. arXiv (2023). <https://arxiv.org/abs/2311.05608>.
- [41] LIU X, ZHU Y, GU J, et al. MM-SafetyBench: a benchmark for safety evaluation of multimodal large language models[C]//Proceedings of the European Conference on Computer Vision. 2024.
- [42] LI L, SONG D, QIU X. Text adversarial purification as defense against adversarial attacks[C]//Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2023: 338-350.
- [43] YI J, XIE Y, ZHU B, et al. Benchmarking and defending against indirect prompt injection attacks on large language models[A/OL]. arXiv (2023). <https://arxiv.org/abs/2312.14197>.
- [44] WALLACE E, XIAO K Y, LEIKE R H, et al. The instruction hierarchy: training LLMs to prioritize privileged instructions[A/OL]. arXiv (2024). <https://arxiv.org/abs/2404.13208>.
- [45] CHEN S, PIET J, SITAWARIN C, et al. StruQ: defending against prompt injection with structured queries[A/OL]. arXiv (2024). <https://arxiv.org/abs/2402.06363>.
- [46] TOYER S, WATKINS O, MENDES E, et al. Tensor trust: interpretable prompt

- injection attacks from an online game[C]//International Conference on Learning Representations. 2024.
- [47] ETHAYARAJH K, XU W, MUENNIGHOFF N, et al. Model alignment as prospect theoretic optimization[C]//Proceedings of the 41st International Conference on Machine Learning. 2024.
- [48] RÖTTGER P, KIRK H, VIDGEN B, et al. XSTest: a test suite for identifying exaggerated safety behaviours in large language models[C/OL]//Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers). 2024: 5377-5400. <https://aclanthology.org/2024.naacl-long.301/>. DOI: 10.18653/v1/2024.naacl-long.301.
- [49] CHIN Z Y, FRITZ M, CHEN P Y, et al. In-context experience replay facilitates safety red-teaming of text-to-image diffusion models[A/OL]. arXiv (2024). <https://arxiv.org/abs/2411.16769>.

## 致谢

本论文的完成，离不开诸位师长、同学与家人的关心、指导和支持。

首先，衷心感谢导师严飞老师在论文选题、研究思路、内容修改和写作规范等方面给予的悉心指导与帮助。老师严谨认真的治学态度和务实负责的工作作风，使我受益良多。

同时，感谢国家网络安全学院各位老师在本科阶段的培养与帮助，使我在课程学习和专业训练中不断积累知识、提升能力。感谢同学们在论文写作和日常学习过程中给予的交流与支持。

最后，感谢家人一直以来的理解、鼓励与陪伴，正是他们的支持使我能够顺利完成本科学习和毕业论文写作。

